LEAD

Modelado matemático

BCD5105 — III Cuatrimestre 2026

Actividad grupal clase 5

Regresión clásica y regularizada

Ficha de la actividad

Fecha de asignación:	Jueves 8 de octubre de 2026 (clase 5)
Modalidad:	Grupal, en salas reducidas, con los grupos estables del proyecto integrador
Valor:	Tarea moral: no se entrega ni se califica
Duración estimada:	40 minutos en clase; lo que quede pendiente se termina durante la semana
Producto:	Un notebook de Colab (Python) compartido por el grupo

¿Qué es esta actividad?

Es la práctica que cierra la sesión sobre regresión. Tiene dos propósitos: calcular a mano una recta, su R^2 y el efecto de Ridge, y usar Python para responder preguntas reales de modelado: ¿qué explica el consumo eléctrico de un hogar?, ¿ayuda regularizar?, ¿cómo se ve una validación tramposa?

Punto importante

Esta actividad es tarea moral: no se entrega ni tiene nota. Aun así, conviene tomarla en serio: la regresión entra en la prueba parcial grupal (se asigna en la semana 7) y una regresión bien validada ya cumple el requisito de primer modelo del avance del proyecto (semana 8).

Conexión con el resto del curso

Lo que practican hoy	Dónde vuelve a aparecer	Semana
Recta, R^2 y residuos	Avance del proyecto: primer modelo	8
Validación sin fuga de datos	Series temporales y validación temporal	6 y 7
Ridge como penalización L2	Weight decay y AdamW	11
Selección de variables con Lasso	Prueba parcial grupal	7 a 8

Estructura de la actividad

Distribución del tiempo (40 minutos en total)

Parte 0. Organización (3 minutos)

- Abrir un notebook de Colab, compartirlo con el grupo y asignar quién lidera cada parte.

Parte 1. Miniexploración a mano (9 minutos)

- La recta de cuatro tiendas, su R^2 y el encogimiento de Ridge.

Parte 2. Consumo eléctrico con statsmodels (9 minutos)

- Ajustar e interpretar una regresión múltiple y revisar sus residuos.

Parte 3. ¿Ayuda regularizar? (9 minutos)

- Comparar OLS, Ridge, Lasso y Elastic Net con validación cruzada.

Parte 4. La fuga de datos en vivo (7 minutos)

- Ver cómo una validación tramposa encuentra un modelo donde no hay nada.

Parte 5. Reflexión (3 minutos)

- Celda de texto final con las conclusiones del grupo.

Parte 1: Miniexploración a mano

Tiempo sugerido: 9 minutos

Esta parte es a mano, con calculadora y sin computadora. Uno de los integrantes trabaja en su iPad o cuaderno; los demás verifican. Al final, pasan las conclusiones a una celda de texto del notebook.

Situación: una cadena de cuatro tiendas registró su inversión en publicidad del mes (x, en cientos de miles de colones) y sus ventas (y, en millones de colones):

Tienda	1	2	3	4
x (publicidad)	1	2	3	4
y (ventas)	3	5	6	8

Tareas:

1. Con la tablita de la clase, calculen $\bar{x}$, $\bar{y}$, S_{xy} y S_{xx}, y obtengan $\hat{\beta}_1$ y $\hat{\beta}_0$.
2. Interpreten la pendiente en una frase de negocio.
3. Calculen las predicciones, los residuos, RSS, TSS y R^2.
4. Calculen la pendiente de Ridge, $\hat{\beta}_1^{\text{ridge}} = S_{xy}/(S_{xx} + \lambda)$, para $\lambda = 1$, 5 y 15. ¿Qué pasa con la pendiente?

Verificación

$\bar{x} = 2.5$, $\bar{y} = 5.5$, $S_{xy} = 8$ y $S_{xx} = 5$: la recta es $\hat{y} = 1.5 + 1.6x$. Cada cien mil colones de publicidad se asocian con 1.6 millones más de ventas. Los residuos son -0.1, 0.3, -0.3 y 0.1; RSS $= 0.2$, TSS $= 13$ y $R^2 \approx 0.985$. Con Ridge, la pendiente baja a 1.33, 0.80 y 0.40.

Parte 2: Consumo eléctrico con statsmodels

Tiempo sugerido: 9 minutos

Simulamos 400 hogares con su consumo eléctrico mensual (kWh). Como en la clase, conocemos la verdad: el consumo se construyó con 35 kWh por persona, 0.8 por metro cuadrado, 70 por tener aire acondicionado y 3 por grado de temperatura media. Las habitaciones casi repiten la información de los metros cuadrados, y hay seis variables de puro ruido.

1. Corran la celda de datos y revisen las primeras filas.
2. Ajusten con statsmodels el modelo con personas, metros cuadrados, aire y temperatura. ¿Los intervalos de 95 % contienen los valores verdaderos?
3. Interpreten el coeficiente de `aire` en una frase.
4. Revisen el gráfico de residuos contra ajustados y la prueba de Breusch-Pagan.

```
import numpy as np, pandas as pd, matplotlib.pyplot as plt
import statsmodels.formula.api as smf
from statsmodels.stats.api import het_breuschpagan

rng = np.random.default_rng(2026)
n = 400
personas = rng.integers(1, 7, n).astype(float)
m2 = rng.normal(110, 35, n).clip(40, 300)
habitaciones = (m2 / 35 + rng.normal(0, 0.4, n)).round().clip(1, 7)
aire = (rng.random(n) < 0.3).astype(float)
temp = rng.normal(25, 3, n)
ruidos = rng.normal(0, 1, (n, 6))
kwh = 60 + 35*personas + 0.8*m2 + 70*aire + 3*temp + rng.normal(0, 30, n)
df = pd.DataFrame({"kwh": kwh, "personas": personas, "m2": m2,
                   "habitaciones": habitaciones, "aire": aire, "temp": temp
                      })
for j in range(6):
    df[f"ruido{j+1}"] = ruidos[:, j]

mod = smf.ols("kwh ~ personas + m2 + aire + temp", data=df).fit()
print(mod.params.round(3))
# personas 33.469, m2 0.740, aire 67.144, temp 3.288
print(mod.conf_int().round(3)) # aire: 60.730 a 73.557
print(round(mod.rsquared, 3))  # 0.847

plt.scatter(mod.fittedvalues, mod.resid, s=10)
plt.axhline(0, color="black", ls="--"); plt.show()
bp = het_breuschpagan(mod.resid, mod.model.exog)
print(round(bp[1], 3))         # 0.638
```

Pregunta para discutir en el grupo

Los cuatro intervalos contienen el valor verdadero. El aire acondicionado suma unos 67 kWh al mes, con el resto fijo, y Breusch-Pagan ($p = 0.638$) no da evidencia de heterocedasticidad. ¿Por qué no incluimos `habitaciones`? Agréguenla y miren el error estándar de `m2`.

Parte 3: ¿Ayuda regularizar?

Tiempo sugerido: 9 minutos

Ahora usamos las once variables, incluidas las habitaciones y los seis ruidos.

1. Antes de correr: ¿cuál de los cuatro modelos creen que va a predecir mejor?
2. Comparen OLS, Ridge, Lasso y Elastic Net con validación cruzada de 5 partes, siempre dentro de un Pipeline.
3. Ajusten el Lasso con todos los datos: ¿qué variables apagó?

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression, RidgeCV, LassoCV,
    ElasticNetCV
from sklearn.model_selection import KFold, cross_val_score

X = df.drop(columns="kwh").values
y = df["kwh"].values
cv = KFold(n_splits=5, shuffle=True, random_state=42)
modelos = {"OLS": LinearRegression(),
           "Ridge": RidgeCV(alphas=np.logspace(-3, 3, 50)),
           "Lasso": LassoCV(cv=5, random_state=0),
           "ElasticNet": ElasticNetCV(l1_ratio=[.1, .5, .9, 1], cv=5,
                                      random_state=0)}
for nombre, est in modelos.items():
    pipe = make_pipeline(StandardScaler(), est)
    rmse = -cross_val_score(pipe, X, y, cv=cv,
                            scoring="neg_root_mean_squared_error")
    print(f"{nombre:10s} RMSE CV = {rmse.mean():.2f}")
# OLS 30.06 | Ridge 30.07 | Lasso 29.90 | ElasticNet 29.90

lasso = make_pipeline(StandardScaler(), LassoCV(cv=5, random_state=0)).fit(
    X, y)
for nombre, c in zip(df.columns[1:], lasso[-1].coef_):
    print(f"{nombre:13s} {c:+.2f}")
```

Para discutir

Los cuatro modelos quedan prácticamente empatados (RMSE entre 29.9 y 30.1 kWh, cuando el ruido verdadero tiene desviación 30). Con 400 hogares y solo 11 variables, OLS ya no sobreajusta y regularizar casi no cambia la predicción. El Lasso apagó `habitaciones` y `ruido2`, pero dejó los otros cinco ruidos con coeficientes pequeños. ¿En qué situación esperarían que la regularización sí gane con claridad? Pista: la colinealidad de la clase y la ENAHO simulada.

Parte 4: La fuga de datos en vivo

Tiempo sugerido: 7 minutos

Generamos 100 filas con 1000 variables y una y, todo ruido puro: no hay nada que predecir.

1. Versión tramposa: seleccionar las 10 variables más correlacionadas con y usando todos los datos y después hacer validación cruzada.
2. Versión honesta: la misma selección, pero dentro del Pipeline, para que se haga solo con el entrenamiento de cada pliegue.
3. Comparen el R^2 de validación cruzada de ambas.

```
from sklearn.feature_selection import SelectKBest, f_regression

rng2 = np.random.default_rng(2026)
Xr = rng2.normal(size=(100, 1000))
yr = rng2.normal(size=100)

# Tramposa: la seleccion ve todos los datos, incluidos los examenes
Xmal = SelectKBest(f_regression, k=10).fit_transform(Xr, yr)
r2_mal = cross_val_score(LinearRegression(), Xmal, yr, cv=cv, scoring="r2")

# Honesta: la seleccion vive dentro del Pipeline
pipe_bien = make_pipeline(SelectKBest(f_regression, k=10), LinearRegression
    ())
r2_bien = cross_val_score(pipe_bien, Xr, yr, cv=cv, scoring="r2")

print(f"R2 con fuga: {r2_mal.mean():.2f}")    # 0.26
print(f"R2 honesto:  {r2_bien.mean():.2f}")   # -0.78
```

Comparación

Con fuga, el modelo "explica" un 26 % de la variación de puro ruido. La validación honesta da $R^2 = -0.78$: predecir con ese modelo es peor que predecir siempre el promedio, que es la verdad. Es la regla de oro de la clase: todo lo que se aprende de los datos, incluida la selección de variables, se aprende solo con el entrenamiento.

Parte 5: Reflexión

Tiempo sugerido: 3 minutos

Agreguen una celda de texto final con:

- **Una observación matemática:** ¿qué les sorprendió del empate de la parte 3?
- **Una observación técnica:** ¿por qué la selección de variables va dentro del Pipeline?
- **Una pregunta abierta:** en su proyecto, ¿cuál sería la y y cuáles las x?

Qué hacer con el notebook

No se entrega, pero se guarda

1. Desde Colab: Archivo → Guardar una copia en Drive, o en el GitHub personal de cada integrante.
2. Usen un nombre reconocible, por ejemplo `Clase5_Regresion_NombreDelGrupo.ipynb`, y listen a los integrantes en la primera celda.
3. Lo que no terminen en clase, complétenlo durante la semana.

Consejos para que la actividad fluya

Sobre el entorno

Esta actividad no necesita instalar nada: NumPy, pandas, statsmodels y scikit-learn ya vienen en Colab. Si una versión vieja de Colab da resultados distintos en los decimales, actualicen con `!pip install -U scikit-learn statsmodels`.

Sobre los resultados

Con la semilla 2026 y las celdas en orden, sus números deben coincidir con los comentarios del código. Si corren una celda dos veces, el generador avanza y los datos cambian: vuelvan a correr desde la celda de datos.

Sobre el uso de inteligencia artificial

Pueden consultar asistentes de IA con dos condiciones: entender cada línea que copien y escribir ustedes los comentarios que expliquen el código. Rige el Protocolo sobre el uso de la inteligencia artificial de Lead University.

Importante

- Esta actividad es tarea moral: no se entrega ni se califica.
- Al terminar las salas habrá una plenaria breve para la puesta en común.

Lead University — III Cuatrimestre 2026
¿Dudas? Escríbanme a jordy.alfaro@ulead.ac.cr