LEAD UNIVERSITY

Modelado matemático

BCD5105 — III Cuatrimestre 2026

Actividad grupal clase 6

Series temporales clásicas

Ficha de la actividad

Fecha de asignación:	Jueves 15 de octubre de 2026 (clase 6)
Modalidad:	Grupal, en salas reducidas, con los grupos estables del proyecto integrador
Valor:	Tarea moral: no se entrega ni se califica
Duración estimada:	40 minutos en clase; lo que quede pendiente se termina durante la semana
Producto:	Un notebook de Colab con entorno de R, compartido por el grupo

¿Qué es esta actividad?

Es la práctica que cierra la sesión sobre series temporales clásicas. Tiene dos propósitos: hacer a mano las restas y las lecturas que la computadora automatiza (diferencias y ACF), y recorrer en R el flujo completo de fpp3 con una serie nueva: la demanda eléctrica mensual de un país pequeño, simulada.

Punto importante

Esta actividad es tarea moral: no se entrega ni tiene nota. Aun así, conviene tomarla en serio: las series temporales entran en la prueba parcial grupal, que se asigna en la semana 8 (después del repaso) y se entrega en la semana 9. Además, una serie bien validada ya cumple el primer modelo del avance del proyecto, que se entrega en la semana 8.

Conexión con el resto del curso

Lo que practican hoy	Dónde vuelve a aparecer	Semana
Descomponer y diferenciar	Prophet y modelos modernos	7
Validar contra un ingenuo con MASE	Comparar modelos clásicos y modernos	7
El flujo completo de fpp3	Repaso y prueba parcial grupal	8 y 9
Una serie del proyecto	Avance del proyecto: primer modelo	8

Estructura de la actividad

Distribución del tiempo (40 minutos en total)

Parte 0. Organización (3 minutos)

- Abrir un notebook con entorno de R (Entorno de ejecución → Cambiar tipo de entorno → R), compartirlo y correr de inmediato `install.packages("fpp3")`.

Parte 1. Miniexploración a mano (8 minutos)

- Diferencias de una serie trimestral y lectura de tres ACF.

Parte 2. La serie y su receta (9 minutos)

- Construir el tsibble, mirar el patrón estacional y descomponer con STL.

Parte 3. ARIMA automático (9 minutos)

- Ajustar, leer los coeficientes y diagnosticar los residuos.

Parte 4. ¿Le gana al ingenuo? (8 minutos)

- Separar un año de prueba y comparar SARIMA con SNAIVE en MASE.

Parte 5. Reflexión (3 minutos)

- Celda de texto final con las conclusiones del grupo.

Parte 1: Miniexploración a mano

Tiempo sugerido: 8 minutos

Esta parte es a mano, sin computadora. Uno de los integrantes trabaja en su iPad o cuaderno; los demás verifican. Al final, pasan las conclusiones a una celda de texto del notebook.

Situación A. Una cooperativa registró sus colocaciones trimestrales (en millones de colones) durante dos años:

Trimestre	2024 T1	T2	T3	T4	2025 T1	T2	T3	T4
y	20	26	18	24	23	29	21	27

1. Calculen la primera diferencia $y_t - y_{t-1}$. ¿Desapareció el patrón trimestral?
2. Calculen la diferencia estacional $y_t - y_{t-4}$. ¿Qué queda y qué significa?

Situación B. Tres ACF, descritas en palabras:

(i) Todas las barras dentro de la franja azul.

(ii) Barras altas que bajan muy despacio, rezago tras rezago.

(iii) Barras altas en los rezagos 12, 24 y 36, y negativas cerca de 6, 18 y 30.

3. Asignen a cada ACF una de estas series: casos semanales de un evento al azar, ventas mensuales de helados, población del país año a año.
4. ¿Cuál de las tres necesita una diferencia estacional?

Verificación

Primera diferencia: $6, -8, 6, -1, 6, -8, 6$; el crecimiento se va, pero el patrón trimestral sigue ahí. Diferencia estacional: $3, 3, 3, 3$; queda una constante: las colocaciones crecen 3 millones por año sobre un patrón trimestral fijo. En la situación B: (i) evento al azar, (ii) población, (iii) helados; la (iii) necesita la diferencia estacional.

Parte 2: La serie y su receta

Tiempo sugerido: 9 minutos

Simulamos ocho años de demanda eléctrica mensual (en GWh) con una tendencia creciente y un patrón estacional: más consumo en la época seca y caliente, menos a final de la época lluviosa.

1. Corran la celda de datos y grafiquen la serie.
2. Con `gg_season`, identifiquen el mes de mayor y de menor demanda.
3. Descompongan con STL y midan la fuerza de la tendencia y de la estacionalidad.

```
library(fpp3)
set.seed(2026)
n <- 96; t <- 1:n
patron <- c(0.98, 0.97, 1.04, 1.06, 1.05, 1.00,
            0.99, 1.00, 0.97, 0.98, 0.97, 0.99)
demanda <- (900 + 2.5 * t) * patron[((t - 1) %% 12) + 1] *
           (1 + rnorm(n, 0, 0.012))
energia <- tsibble(Mes = make_yearmonth(2018, 1) + 0:(n - 1),
                   GWh = round(demanda, 1), index = Mes)

energia |> autoplot(GWh)
energia |> gg_season(GWh)
energia |> model(STL(GWh ~ season(window = "periodic"), robust = TRUE)) |>
  components() |> autoplot()
energia |> features(GWh, feat_stl)
# trend_strength 0.981, seasonal_strength_year 0.917
# seasonal_peak_year 4 (abril), seasonal_trough_year 9 (setiembre)
```

Pregunta para discutir en el grupo

La tendencia (0.98) y la estacionalidad (0.92) son fuertes, en una escala de 0 a 1. El pico cae en abril y el valle en setiembre. ¿Qué explicación física le darían a ese patrón en un país tropical? ¿La serie se ve aditiva o multiplicativa?

Parte 3: ARIMA automático

Tiempo sugerido: 9 minutos

1. ¿Cuántas diferencias recomienda KPSS? Anoten su predicción del modelo antes de ajustarlo.
2. Ajusten `ARIMA(GWh)` y lean el modelo elegido con `report()`.
3. Interpreten la constante: ¿qué tiene que ver con el 2.5 de la simulación?
4. Revisen los residuos con `gg_tsresiduals()` y Ljung-Box.

```
energia |> features(GWh, unitroot_nsdiffs)   # 1
fit <- energia |> model(ARIMA(GWh))
report(fit)
# ARIMA(0,0,0)(0,1,1)[12] w/ drift
#          sma1  constant
#       -0.6802   30.4857
fit |> gg_tsresiduals()
augment(fit) |> features(.innov, ljung_box, lag = 24, dof = 1)
# lb_stat 16.7   lb_pvalue 0.824
```

Para discutir

El algoritmo eligió una diferencia estacional con deriva, la misma estructura que el turismo de la clase. La constante, cerca de 30, es lo que crece la demanda de un año al siguiente: aproximadamente $12 \times 2.5 = 30$ GWh. Ljung-Box da $p = 0.82$: los residuos se comportan como ruido blanco.

Parte 4: ¿Le gana al ingenuo?

Tiempo sugerido: 8 minutos

1. Entrenen con 2018 a 2024 y dejen 2025 como prueba.
2. Ajusten SNAIVE y ARIMA, pronostiquen 12 meses y comparen con `accuracy()`.
3. Grafiquen ambos pronósticos sobre los datos reales de 2025.

```
entreno <- energia |> filter(Mes < make_yearmonth(2025, 1))
modelos <- entreno |> model(snaive = SNAIVE(GWh), sarima = ARIMA(GWh))
modelos |> forecast(h = 12) |> accuracy(energia) |>
  select(.model, RMSE, MAPE, MASE) |> arrange(MASE)
#   .model  RMSE  MAPE  MASE
# 1 sarima  15.5  1.09 0.393
# 2 snaive  34.0  2.72 0.982

modelos |> forecast(h = 12) |>
  autoplot(energia |> filter(Mes >= make_yearmonth(2023, 1)), level = NULL)
```

Comparación

El SARIMA comete menos de la mitad del error del ingenuo (MASE 0.39 contra 0.98). Con solo el entrenamiento, el algoritmo eligió un modelo algo distinto, ARIMA(0,0,0)(2,1,1)[12] con deriva: con menos datos, la búsqueda puede cambiar de modelo. ¿Por qué SNAIVE queda tan cerca de 1? ¿Qué parte de la serie no puede capturar?

Parte 5: Reflexión

Tiempo sugerido: 3 minutos

Agreguen una celda de texto final con:

- **Una observación matemática:** ¿qué les dijo la diferencia estacional de la parte 1 que no se veía en la serie original?
- **Una observación técnica:** ¿por qué no se debe validar un pronóstico con un K-fold barajado?
- **Una pregunta abierta:** ¿la serie de su proyecto tiene estacionalidad? ¿Con qué período?

Qué hacer con el notebook

No se entrega, pero se guarda

1. Desde Colab: Archivo → Guardar una copia en Drive, o en el GitHub personal de cada integrante.
2. Usen un nombre reconocible, por ejemplo `Clase6_Series_NombreDelGrupo.ipynb`, y listen a los integrantes en la primera celda.
3. Lo que no terminen en clase, complétenlo durante la semana.

Consejos para que la actividad fluya

Sobre el entorno de R

`install.packages("fpp3")` tarda varios minutos en Colab: córranlo apenas abran el notebook, mientras otro integrante trabaja la parte 1. Si reinician el entorno, hay que volver a instalar.

Sobre los resultados

Con `set.seed(2026)` y las celdas en orden, sus números deben coincidir con los comentarios del código. Si una versión distinta de fable elige otro modelo, no es un error: comparen los MASE, que es lo que importa.

Sobre el uso de inteligencia artificial

Pueden consultar asistentes de IA con dos condiciones: entender cada línea que copien y escribir ustedes los comentarios que expliquen el código. Rige el Protocolo sobre el uso de la inteligencia artificial de Lead University.

Importante

- Esta actividad es tarea moral: no se entrega ni se califica.
- Al terminar las salas habrá una plenaria breve para la puesta en común.

Lead University — III Cuatrimestre 2026
¿Dudas? Escríbanme a jordy.alfaro@ulead.ac.cr