LEAD UNIVERSITY

Regresión clásica y regularizada

Semana 5: de la recta a la creencia previa, con Python

BCD5105 · Modelado matemático
Profesor: Jordy Alfaro Brenes
Lead University · III cuatrimestre 2026 · Modalidad virtual

Jueves 8 de octubre de 2026 · 4:00 a 7:00 p. m.

Ruta de la sesión

Dos mitades: primero a mano, después en Python

Al terminar la sesión usted podrá

- Calcular a mano la recta de mínimos cuadrados y usarla para predecir.
- Juzgar una recta con R^2 y con sus residuos.
- Explicar qué hacen Ridge, Lasso y Elastic Net, y cuándo usar cada uno.
- Elegir la fuerza de la regularización con validación cruzada, sin fuga de datos.
- Leer una regresión bayesiana y ver la regularización como un prior.

Bloques y tiempos estimados

1	La recta de mínimos cuadrados	20 min
2	¿Qué tan buena es la recta?	15 min
3	Regularización: Ridge, Lasso y Elastic Net	20 min
4	Validación cruzada	15 min
	Receso	10 min
5	Python: OLS, diagnóstico y regularización	30 min
6	Python: validación y regresión bayesiana	30 min
7	Actividad en salas	40 min

LEAD

LEAD UNIVERSITY

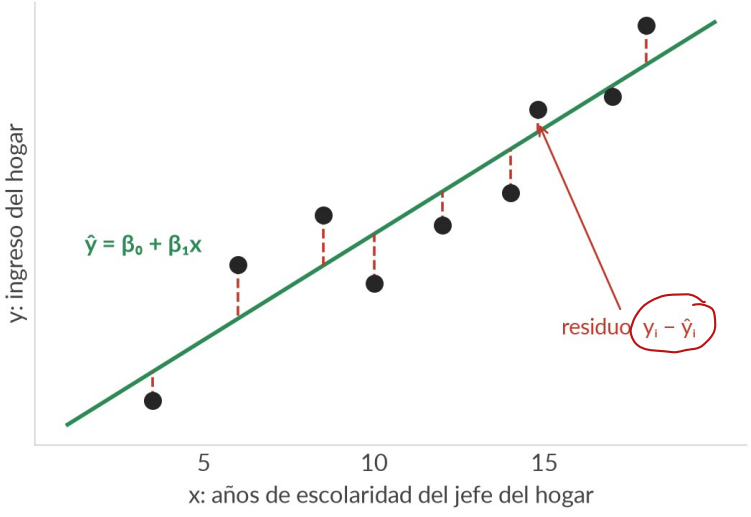
Parte 1

Regresión, a mano

Trabajo conceptual en la pizarra: cómo se elige la mejor recta, cómo se juzga, por qué a veces conviene frenarla y cómo saber si predice bien.

Adivinar el ingreso de un hogar

Una encuesta, dos variables y una recta



Intercepto

Pendiente

Error

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Símbolo	Qué es
y_i	Ingreso del hogar i
x_i	Años de escolaridad del jefe del hogar i
β_0	Intercepto
β_1	Pendiente
ε_i	Error: lo que la recta no explica

Las líneas rojas son los residuos: lo que la recta se equivoca con cada hogar.

LEAD

Mínimos cuadrados

La mejor recta es la que se equivoca menos, al cuadrado

$$RSS(\beta_0, \beta_1) = \Sigma\,(y_i - \beta_0 - \beta_1 x_i)^2 \quad \rightarrow \quad \text{minimizar}$$

$$\hat{\beta}_1 = Sxy / Sxx = \Sigma(x_i - \bar{x})(y_i - \bar{y}) / \Sigma(x_i - \bar{x})^2$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\,\bar{x}$$

¿Por qué al cuadrado?

Para que los errores hacia arriba y hacia abajo no se cancelen, y para castigar más los errores grandes.

Sxy: ¿se mueven juntas?

Positivo si los hogares con más escolaridad que el promedio tienden a tener más ingreso que el promedio.

La recta pasa por el centro

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$ obliga a la recta a pasar por el punto $(\bar{x}, \bar{y})$.

LEAD

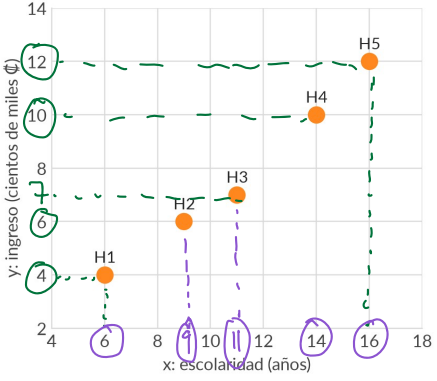
Micro ejemplo: cinco hogares

x = escolaridad del jefe (años) · y = ingreso (cientos de miles de colones)

Recta de regresión

$y = 0.8x - 1.15$

12



Paso 2: la tablita

Hogar	x	y	x − x̄	y − ȳ	Producto	(x − x̄)²
1	6	4	−5.2	−3.8	19.76	27.04
2	9	6	−2.2	−1.8	3.96	4.84
3	11	7	−0.2	−0.8	0.16	0.04
4	14	10	2.8	2.2	6.16	7.84
5	16	12	4.8	4.2	20.16	23.04
				Suma	50.2	62.8

Paso 1: promedios

$\bar{x} = \frac{6+9+11+14+16}{5} = 11.2$

$\bar{y} = \frac{4+6+7+10+12}{5} \simeq 7.8$

Pasos 3 y 4: coeficientes y predicción

$\hat{\beta}_1 = Sxy / Sxx = \frac{50.2}{62.8} \approx 0.8$

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x} = 7.8 - 0.8 \cdot 11.2 \simeq -1.15$

Hogar con 12 años de escolaridad: $\hat{y} = 0.8 \cdot 12 - 1.15 \approx 8.43$

LEAD

LEAD UNIVERSITY

Ejemplos

Resolvemos juntos en la pizarra

La recta de mínimos cuadrados

Ejemplo 1

Cuatro hogares: x = 8, 10, 12, 14 años de escolaridad; y = 5, 6, 8, 9 (cientos de miles).

a) Calcule $\bar{x}$, $\bar{y}$, Sxy y Sxx con la tablita.

b) Obtenga $\hat{\beta}_1$ y $\hat{\beta}_0$.

c) Prediga el ingreso de un hogar con 13 años.

Ejemplo 2

Una tienda estima $\hat{y} = 2.1 + 0.45x$, con y = ventas (millones) y x = publicidad (cientos de miles).

a) Interprete la pendiente en una frase de negocio.

b) Prediga las ventas con x = 20.

c) ¿Tiene sentido interpretar el intercepto?

Intercepto

Pendiente

Por cada 100000 en publicidad obtenemos 450000 en ventas

$\hat{y} = 2.1 + 0.45 \cdot 20 = 11.1$

Espacio de trabajo

La recta de mínimos cuadrados

Ejemplo 1

Ejemplo 2

LEAD UNIVERSITY

Ejercicios

Tarea moral · resuélvalos durante la semana

La recta de mínimos cuadrados

Ejercicio 1

Horas de estudio x = 2, 4, 6, 8 y nota y = 60, 70, 75, 85.

a) Obtenga la recta.

b) Prediga la nota con 5 horas.

c) ¿Y con 20 horas? ¿Le cree?

Ejercicio 2

En un modelo de ingreso por persona contra tamaño del hogar, la pendiente sale −0.6.

Interprétela. ¿Implica que tener más hijos causa menos ingreso?

Ejercicio 3

¿Por qué no se minimiza la suma de los residuos sin elevarlos al cuadrado?

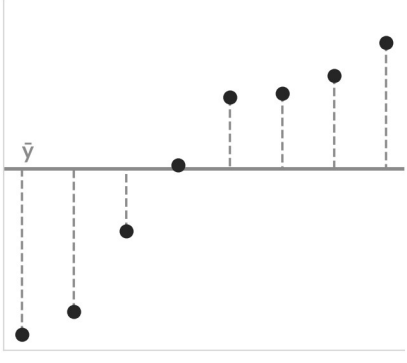
Pruebe con una recta horizontal en $\bar{y}$: ¿cuánto suman sus residuos?

¿Qué tan buena es la recta?

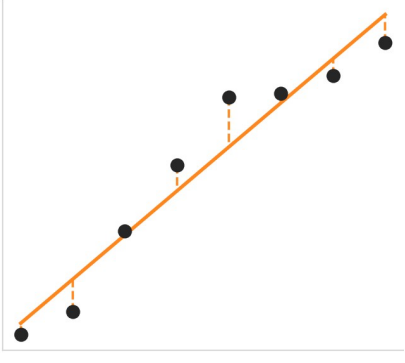
R^2: cuánto mejora la recta frente a predecir siempre el promedio

$$R^2 = 1 - \frac{RSS}{TSS}$$

TSS: distancias al promedio



RSS: distancias a la recta



$R^2 = 1 - RSS / TSS$

$R^2 = 1$

Ajuste perfecto: todos los puntos sobre la recta.

$R^2 = 0$

La recta no mejora al promedio.

Cómo se lee

TSS mide cuánto varía y alrededor de su promedio; RSS, cuánto queda sin explicar después de la recta. R^2 es la fracción de la variación que la recta explica.

Un R^2 alto no prueba causalidad ni que los supuestos se cumplan.

LEAD

Regresión múltiple

Más de una variable explicativa a la vez

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p + \varepsilon$$

$$y = X \cdot \beta + \varepsilon$$

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

→ coeficientes.

La matriz X

Una fila por hogar, una columna por variable, más una columna de unos para el intercepto.

Ceteris paribus

β_1 es el cambio en y cuando x_1 sube una unidad y las demás variables se quedan fijas.

La misma idea

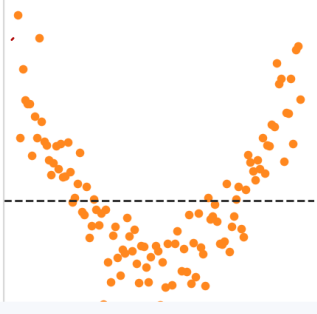
Es la fórmula de la pizarra en versión matricial: con una sola x, vuelve a dar Sxy/Sxx.

LEAD

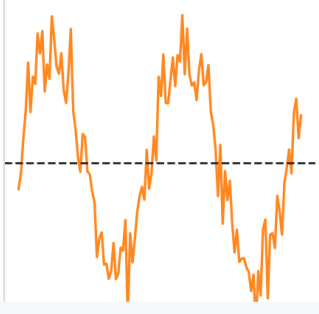
Los supuestos: LINE

Lo que hay que revisar antes de creerle a la recta

Linealidad
patrón en U



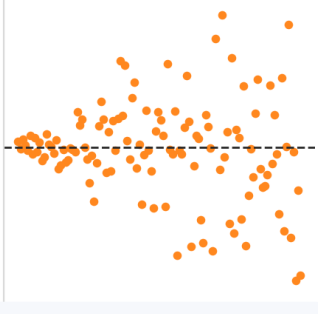
Independencia
residuos con memoria



Normalidad
muy asimétricos



Homocedasticidad
forma de embudo



Linealidad

La relación es una recta, no una curva.

Independencia

El error de un hogar no informa sobre el de otro.

Normalidad

Los errores siguen una campana; importa para los intervalos.

Homocedasticidad

Los errores tienen la misma dispersión en todo el rango.

LEAD

LEAD UNIVERSITY

Ejemplos

Resolvemos juntos en la pizarra

¿Qué tan buena es la recta?

Ejemplo 1

Con la recta del ejemplo 1 del bloque anterior ($\hat{y} = -0.7 + 0.7x$, datos $x = 8, 10, 12, 14$ y $y = 5, 6, 8, 9$):

a) Calcule las predicciones y los residuos.

b) Calcule RSS y TSS.

c) Obtenga R^2 e interprételo.

Ejemplo 2

¿Qué supuesto falla en cada caso?

a) Los residuos del gasto en comida se abren como embudo en los hogares más ricos.

b) Las ventas diarias de una tienda tienen residuos parecidos días seguidos.

c) Los residuos forman una U contra la edad.

Espacio de trabajo

¿Qué tan buena es la recta?

Ejemplo 1

Ejemplo 2

LEAD UNIVERSITY

Ejercicios

Tarea moral · resuélvalos durante la semana

¿Qué tan buena es la recta?

Ejercicio 1

Calcule R^2 para la recta del ejercicio de las horas de estudio.

Interprételo en una frase.

Ejercicio 2

Un modelo de ingreso con escolaridad tiene $R^2 = 0.30$.

¿Es un mal modelo? ¿Para qué podría seguir sirviendo?

Ejercicio 3

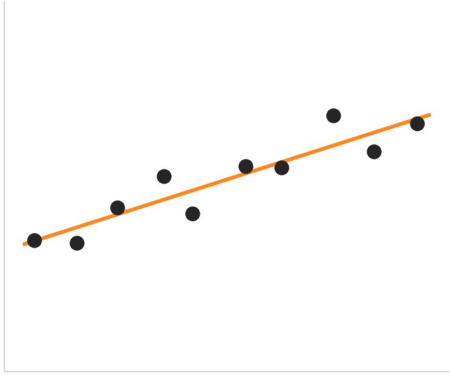
Dé un ejemplo de su proyecto donde el supuesto de independencia probablemente falle.

¿Qué haría?

Cuando el modelo memoriza

Sobreajuste y colinealidad, los dos enemigos de hoy

Recta: aprende la tendencia



Polinomio de grado 9: memoriza



La solución de hoy: ponerle una correa a los coeficientes para que no crezcan sin necesidad. Eso es regularizar.

Sobreajuste

Demasiada flexibilidad: el modelo aprende el ruido de estos datos y falla con datos nuevos.

Colinealidad

Dos variables casi iguales (escolaridad del jefe y de su pareja): los coeficientes se vuelven enormes e inestables.

LEAD

Ridge: una correa para los coeficientes

Mínimos cuadrados más una penalización por coeficientes grandes

$$\hat{\beta}_{ridge} = \text{argmin} \sum (y_i - \hat{y}_i)^2 + \lambda \sum \beta_j^2$$

λ: la fuerza de la correa

λ = 0 es mínimos cuadrados. Si λ crece, los coeficientes se encogen hacia cero, sin llegar nunca a cero.

El costo

Aceptamos un poco de sesgo a cambio de mucha menos varianza: predice mejor con datos nuevos.

Regresión simple: $\hat{\beta}_{ridge} = Sxy / (Sxx + \lambda)$

Cómo leer la fórmula simple

Es la pendiente de la pizarra con algo extra en el denominador: λ "frena" la pendiente.

LEAD

Micro ejemplo: Ridge con los cinco hogares

Mismo Sxy y Sxx del micro ejemplo anterior

Sxy (del micro ejemplo) = 50.2

Sxx (del micro ejemplo) = 62.8

λ	Sxx + λ	$\hat{\beta}_1 = Sxy / (Sxx + \lambda)$
0	62.8	$\hat{\beta}_1 = \frac{50.2}{62.8} = 0.8$ ✓
20	82.8	$\hat{\beta}_1 = \frac{50.2}{82.8} = 0.61$
100	162.8	$\hat{\beta}_1 = \frac{50.2}{162.8} = 0.31$

Para pensar mientras calculamos

- ¿Qué le pasa a la pendiente cuando λ crece?
- ¿Llega a cero alguna vez?
- ¿Qué λ elegiría y con qué criterio?

Bosquejo: $\hat{\beta}_1$ contra λ

LEAD

Lasso y Elastic Net

Otra correa, y la mezcla de ambas

$$\hat{\beta}_{lasso} = \text{argmin} \sum (y_i - \hat{y}_i)^2 + \lambda \sum |\beta_j|$$

Lasso apaga variables

Con el valor absoluto, algunos coeficientes llegan a cero exacto: el modelo elige variables solo.

Ridge solo encoge

Con el cuadrado, todos los coeficientes se achican pero ninguno se apaga.

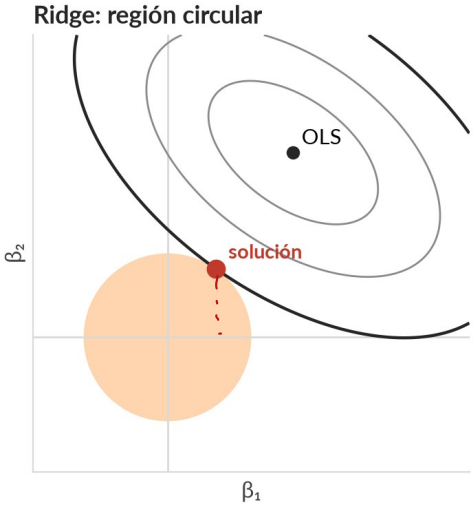
$$\text{Elastic Net: } \sum (y_i - \hat{y}_i)^2 + \lambda_1 \sum |\beta_j| + \lambda_2 \sum \beta_j^2$$

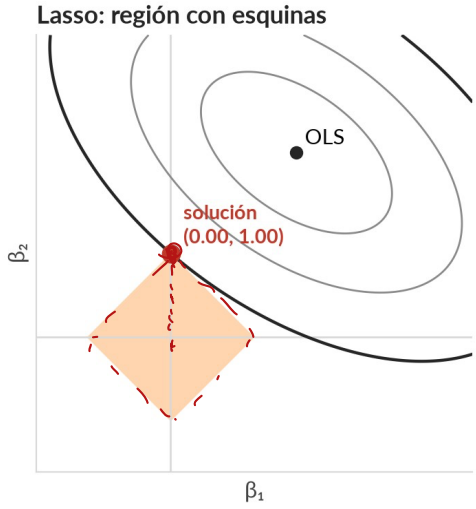
Elastic Net mezcla ambas: selecciona como Lasso y reparte el efecto entre variables correlacionadas como Ridge.

LEAD

Por qué Lasso apaga: el círculo y el rombo

La geometría de las dos correas





Las elipses

Son las curvas de nivel del error. La solución es el primer punto donde tocan la región permitida.

Ridge

El círculo no tiene esquinas: el toque cae en un punto con ambos β distintos de cero.

Lasso

El rombo tiene esquinas sobre los ejes: el toque suele caer ahí, con un β exactamente en cero.

LEAD

LEAD UNIVERSITY

Ejemplos

Resolvemos juntos en la pizarra

Regularización: Ridge, Lasso y Elastic Net

Ejemplo 1

Con los datos del ejemplo 1 del bloque 1 (Sxy = 14, Sxx = 20):

a) Calcule $\hat{\beta}_{ridge}$ para $\lambda = 0$, 5 y 20.

b) ¿Qué pasa si $\lambda \to \infty$?

c) ¿Qué valor de λ devuelve mínimos cuadrados?

Ejemplo 2

¿Ridge, Lasso o Elastic Net? Justifique:

a) 200 variables de un censo y se sospecha que solo unas 10 importan.

b) Escolaridad del jefe y de la pareja, muy correlacionadas, y se quiere conservar ambas.

c) Grupos de variables correlacionadas y no se sabe cuáles importan.

Espacio de trabajo

Regularización: Ridge, Lasso y Elastic Net

Ejemplo 1

Ejemplo 2

LEAD UNIVERSITY

Ejercicios

Tarea moral · resuélvalos durante la semana

Regularización: Ridge, Lasso y Elastic Net

Ejercicio 1

Con Sxy = 30 y Sxx = 50, calcule $\hat{\beta}_{ridge}$ para $\lambda = 0, 10, 50$ y 150.

Grafique $\hat{\beta}$ contra λ.

Ejercicio 2

Una variable está en colones y otra en años.

¿Por qué hay que estandarizarlas antes de aplicar Ridge? Piense en el tamaño de cada coeficiente.

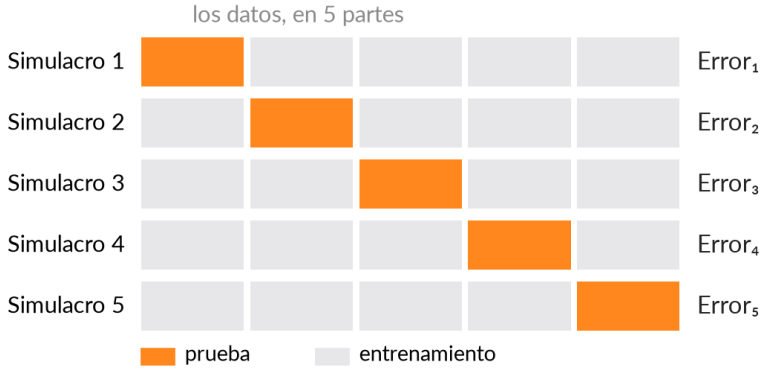
Ejercicio 3

Dibuje el círculo y el rombo con una elipse cuyo centro esté sobre el eje β_1.

¿Qué solución da cada correa?

Validación cruzada: simulacros de examen

Cómo saber si el modelo predice bien datos que no vio



El error en los datos de entrenamiento siempre engaña a favor del modelo. Solo el examen con datos no vistos dice la verdad.

$$\text{Error CV} = (1/K)\ \Sigma\ \text{Error}_k$$

La receta

Partir los datos en K partes. Cada parte sirve una vez de examen y el resto de entrenamiento.

Para elegir λ

Se calcula el error CV para varios λ y se elige el que da menor error.

LEAD

Tres formas de hacer trampa sin querer

La fuga de datos: el examen se filtró antes de tiempo

FUGA

1. Estandarizar antes de partir

Si la media y la desviación se calculan con todos los datos, el examen ya influyó en el entrenamiento.

FUGA

2. Elegir λ mirando la prueba

Si se prueban muchos λ contra el mismo conjunto de prueba, ese conjunto deja de ser un examen honesto.

FUGA

3. Barajar una serie de tiempo

Con datos fechados, un K-fold barajado usa el futuro para predecir el pasado.

Regla de oro: todo lo que se aprende de los datos (medias, λ, selección de variables) se aprende solo con la parte de entrenamiento. En Python, eso es un Pipeline.

LEAD

LEAD UNIVERSITY

Ejemplos

Resolvemos juntos en la pizarra

Validación cruzada

Ejemplo 1

Validación cruzada de 5 partes; RMSE de cada parte:

λ = 1: 2.1, 1.8, 2.4, 2.0, 1.7

λ = 10: 1.9, 1.9, 2.0, 1.8, 1.9

a) Calcule el error CV de cada λ.

b) ¿Cuál elige?

c) ¿Qué dice la dispersión entre partes?

Ejemplo 2

¿Es honesta cada validación? Explique:

a) Se estandariza todo el conjunto y luego se hace K-fold.

b) Para pronosticar el tipo de cambio se usa K-fold barajado.

c) Se elige λ con CV en entrenamiento y se reporta el error en una prueba nunca usada.

Espacio de trabajo

Validación cruzada

Ejemplo 1

Ejemplo 2

LEAD UNIVERSITY

Ejercicios

Tarea moral · resuélvalos durante la semana

Validación cruzada

Ejercicio 1

Con 100 hogares y K = 10:

a) ¿Cuántos hogares hay en cada examen?

b) ¿Cuántas veces se entrena el modelo para un solo λ?

c) ¿Y para 50 valores de λ?

Ejercicio 2

Dejar uno fuera (LOOCV) es K-fold con K = n.

Con n = 5, ¿cuántos modelos se ajustan? ¿Qué ventaja y qué costo tiene?

Ejercicio 3

Diseñe la validación para pronosticar la demanda eléctrica mensual del ICE.

¿Qué no puede hacer?

LEAD UNIVERSITY

Parte 2

Regresión en Python

Comprobar con código lo que hicimos a mano y llevarlo a donde la pizarra no alcanza: muchas variables, colinealidad e incertidumbre.

El stack de la semana

Vigente a octubre de 2026

scikit-learn 1.9

Predecir y regularizar: Pipeline, StandardScaler, RidgeCV, LassoCV, ElasticNetCV.

statsmodels 0.15

Inferir: errores estándar, p-valores, intervalos y diagnósticos de residuos.

PyMC 6 y Bambi

Regresión bayesiana. Bambi acepta fórmulas estilo R y arma el modelo de PyMC.

ArviZ 1.x

Diagnóstico y comparación de modelos con LOO. WAIC ya no está disponible.

	Inferir y explicar	Predecir
Pregunta	¿Cuánto afecta la escolaridad al ingreso?	¿Cuál será el ingreso de un hogar nuevo?
Herramienta	statsmodels	scikit-learn
Métrica reina	Intervalos y significancia	Error en datos no vistos (CV)

```
!pip install -q "pymc>=6" nutpie bambi      # scikit-learn y statsmodels ya vienen en Colab
```

LEAD

¿Para qué sirve la regresión hoy?

El modelo más viejo del curso sigue siendo de los más usados

BANCA

Scoring de crédito

Los modelos lineales regularizados son interpretables, auditables y rápidos: el punto de partida típico en riesgo de crédito.

POLÍTICA SOCIAL

Proxy-means test

Predecir el ingreso de un hogar con pocas variables observables para focalizar programas sociales: regresión con selección de variables.

ENERGÍA Y PRECIOS

Demanda y tarifas

Demanda eléctrica según clima y calendario, elasticidades de precio y costos: regresión múltiple con validación temporal.

APRENDIZAJE AUTOMÁTICO

El modelo de referencia

Antes de una red neuronal, una regresión regularizada bien validada. Muchas veces gana y se queda en producción.

Al final de hoy: la penalización de Ridge es el weight decay con que se entrenan las redes neuronales grandes.

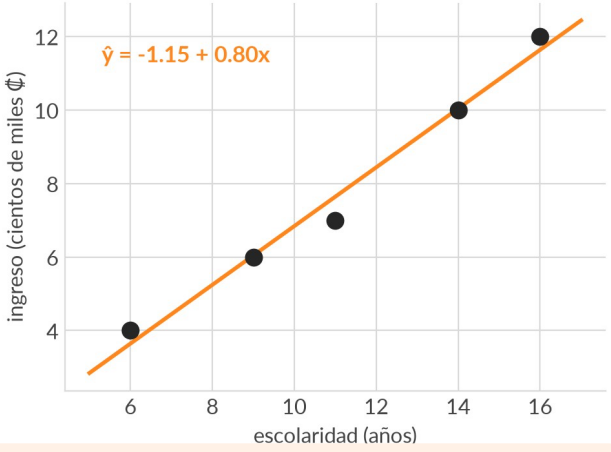
Los cinco hogares en scikit-learn

La máquina contra lo que calculamos a mano

```
import numpy as np
from sklearn.linear_model import LinearRegression

X = np.array([[6], [9], [11], [14], [16]])
y = np.array([4, 6, 7, 10, 12])
ols = LinearRegression().fit(X, y)

print(f"pendiente:  {ols.coef_[0]:.4f}")
print(f"intercepto: {ols.intercept_:.4f}")
print(f"R2: {ols.score(X, y):.3f}")
## pendiente:  0.7994
## intercepto: -1.1529
## R2: 0.984
```



Los mismos 0.80 y −1.15 de la tablita. La computadora no cambia la matemática: solo no se equivoca en la aritmética, y escala a miles de hogares.

Los datos de hoy: 300 hogares simulados

Una ENAHO de bolsillo en la que conocemos la verdad

```
import pandas as pd
rng = np.random.default_rng(2026)
n = 300
escolaridad  = rng.normal(11, 3.5, n).clip(0, 22)
tamano_hogar = rng.integers(1, 8, n).astype(float)
edad_jefe    = rng.normal(48, 13, n).clip(18, 90)
esc_pareja   = escolaridad + rng.normal(0, 1.2, n)  # casi gemela
ruido1, ruido2, ruido3 = rng.normal(0, 1, (3, n))   # no afectan
ingreso = (2.0 + 0.75*escolaridad - 0.9*tamano_hogar
           + 0.02*edad_jefe + rng.normal(0, 1.8, n))
df = pd.DataFrame({"ingreso": ingreso, "escolaridad": escolaridad,
    "tamano_hogar": tamano_hogar, "edad_jefe": edad_jefe,
    "esc_pareja": esc_pareja, "ruido1": ruido1,
    "ruido2": ruido2, "ruido3": ruido3})
X = df.drop(columns="ingreso").values
y = df["ingreso"].values
```

Por qué simulados

Sabemos la verdad: 0.75 por año de escolaridad, −0.9 por miembro del hogar, 0.02 por año de edad y tres variables de puro ruido.

Ingreso en cientos de miles

Igual que los cinco hogares. La escolaridad de la pareja tiene correlación 0.95 con la del jefe.

statsmodels: cuando la pregunta es inferir

Coeficientes con error estándar e intervalo de confianza

```
import statsmodels.formula.api as smf
modelo = smf.ols("ingreso ~ escolaridad + tamano_hogar",
                 data=df).fit()
print(modelo.summary())
##                 coef  std err       t  P>|t|  [0.025  0.975]
## Intercept     3.0330    0.414   7.325  0.000   2.218   3.848
## escolaridad   0.7350    0.029  25.586  0.000   0.678   0.792
## tamano_hogar -0.8726    0.054 -16.164  0.000  -0.979  -0.766
## R-squared: 0.765   Adj. R-squared: 0.763
```

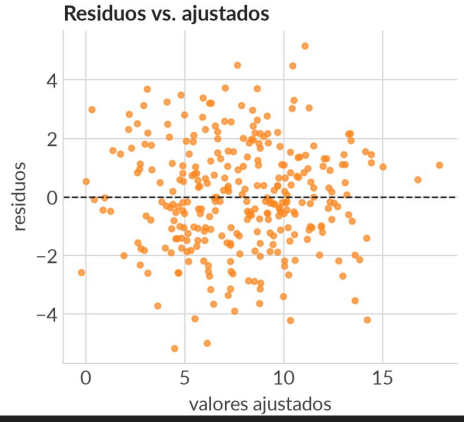
Cómo se lee

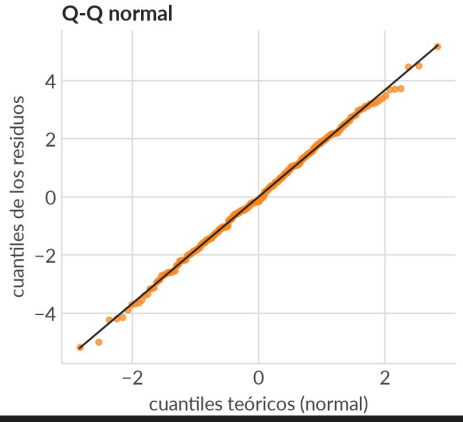
Cada año de escolaridad suma unos 73 500 colones al ingreso, con el tamaño del hogar fijo. El valor verdadero (0.75) cae dentro del intervalo de 95 % (0.678 a 0.792).

scikit-learn no da errores estándar, p-valores ni intervalos. Regla práctica: statsmodels para el informe que explica, scikit-learn para el sistema que predice.

El modelo confiesa en sus residuos

Los supuestos de la pizarra, revisados con datos






```
from statsmodels.stats.api import het_breuschpagan
bp = het_breuschpagan(modelo.resid, modelo.model.exog)
print(f"Breusch-Pagan p-valor: {bp[1]:.3f}")
## Breusch-Pagan p-valor: 0.017
```

Lo que se ve

Nube sin patrón y puntos sobre la diagonal del Q-Q: linealidad y normalidad se ven bien.

Lo que dice la prueba

p = 0.017 < 0.05: la prueba detecta una heterocedasticidad leve que a simple vista no se nota.

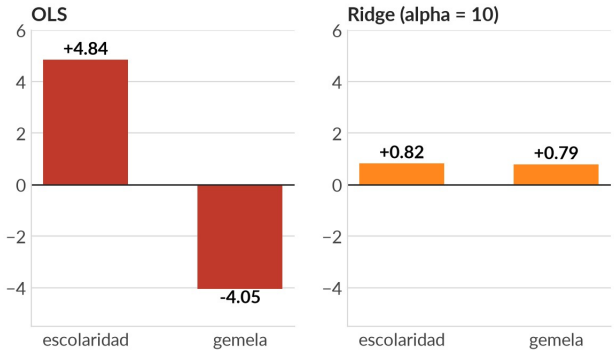
Colinealidad en consola

Una gemela casi exacta de la escolaridad y solo 25 hogares

```
from sklearn.linear_model import Ridge
from sklearn.preprocessing import StandardScaler

esc_gemela = escolaridad + rng.normal(0, 0.1, n)
X2 = np.column_stack([escolaridad, esc_gemela])[:25]
y25 = y[:25]

LinearRegression().fit(X2, y25).coef_.round(2)
## array([ 4.84, -4.05])
Xs2 = StandardScaler().fit_transform(X2)
Ridge(alpha=10).fit(Xs2, y25).coef_.round(2)
## array([0.82, 0.79])
```



OLS inventa coeficientes enormes de signo opuesto que se cancelan. Ridge suma λI a X^TX, $\hat{\beta} = (X^TX + \lambda I)^{-1}X^Ty$, y los obliga a repartirse el efecto.

LEAD

El patrón correcto: Pipeline

Estandarizar y regularizar sin fuga de datos

```
from sklearn.pipeline import make_pipeline
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42)

pipe = make_pipeline(StandardScaler(), Ridge(alpha=1.0))
pipe.fit(X_train, y_train)
print(f"R2 en prueba: {pipe.score(X_test, y_test):.3f}")
## R2 en prueba: 0.845
```

Por qué estandarizar

La penalización depende de las unidades. Con media 0 y desviación 1, castiga a todas las variables por igual.

Por qué dentro del Pipeline

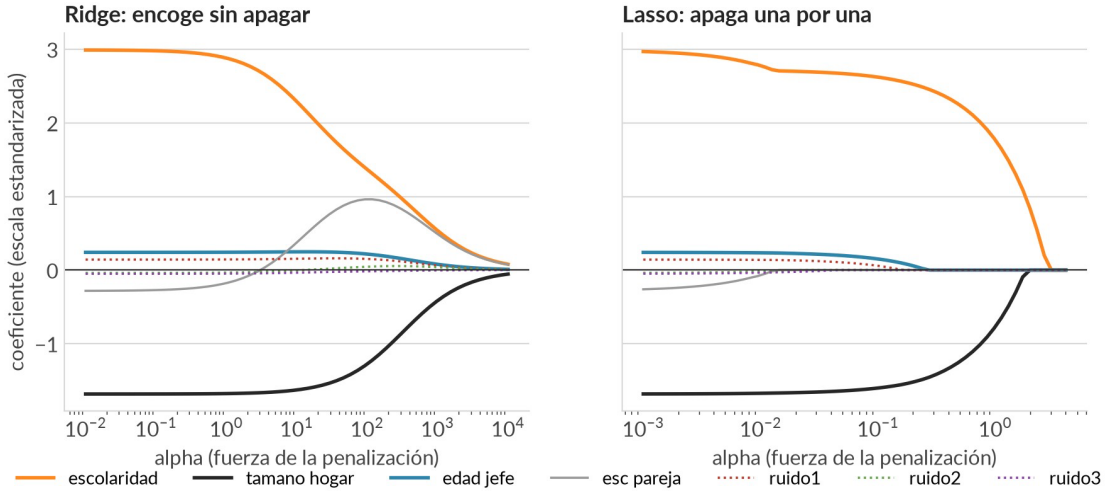
El scaler aprende solo del entrenamiento: la trampa 1 de la pizarra queda resuelta.

En tutoriales viejos aparece Ridge(normalize=True). Esa opción ya no existe en scikit-learn: la forma actual es StandardScaler dentro del Pipeline.

LEAD

Las rutas de los coeficientes

Apretar la correa y ver qué pasa con cada variable



Es la tabla del micro ejemplo de Ridge, para 7 variables a la vez. Ridge baja todo suavemente; Lasso lleva variables a cero exacto, una por una.

LEAD

Lasso: variables que se apagan

LassoCV elige λ con validación cruzada

```
from sklearn.linear_model import LassoCV
lasso = make_pipeline(StandardScaler(),
        LassoCV(cv=10, random_state=0)).fit(X, y)
l = lasso[-1]
print(f"alpha elegido: {l.alpha_:.3f}")
for nombre, c in zip(df.columns[1:], l.coef_):
    print(f"{nombre:14s} {c:+.3f}")
## alpha elegido: 0.056
## escolaridad    +2.664
## tamano_hogar   -1.636
## edad_jefe      +0.192
## esc_pareja     +0.000
## ruido1         +0.098
## ruido2         -0.000
## ruido3         -0.000
```

Lo que acertó

Apagó la escolaridad de la pareja (redundante) y dos de los tres ruidos.

Lo que no

ruido1 sobrevivió con un coeficiente pequeño.

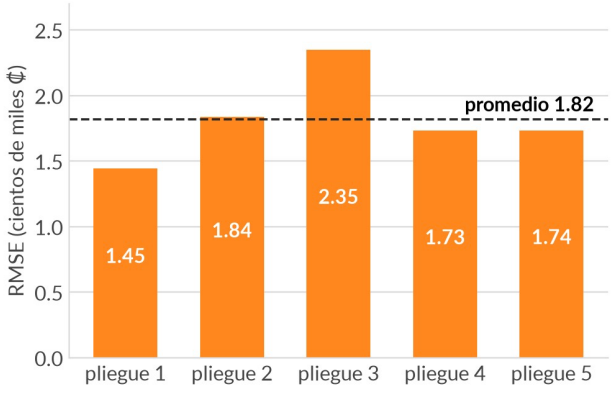
Elastic Net

ElasticNetCV con l1_ratio de 0.1 a 1 eligió 1: Lasso puro, porque los ruidos son inútiles.

Validación cruzada en código

Los simulacros de examen, automatizados

```
from sklearn.model_selection import cross_val_score, KFold
cv = KFold(n_splits=5, shuffle=True, random_state=42)
rmse = -cross_val_score(pipe, X, y, cv=cv,
         scoring="neg_root_mean_squared_error")
print(rmse.round(3), round(rmse.mean(), 3))
## [1.447 1.837 2.349 1.732 1.736] 1.82
```

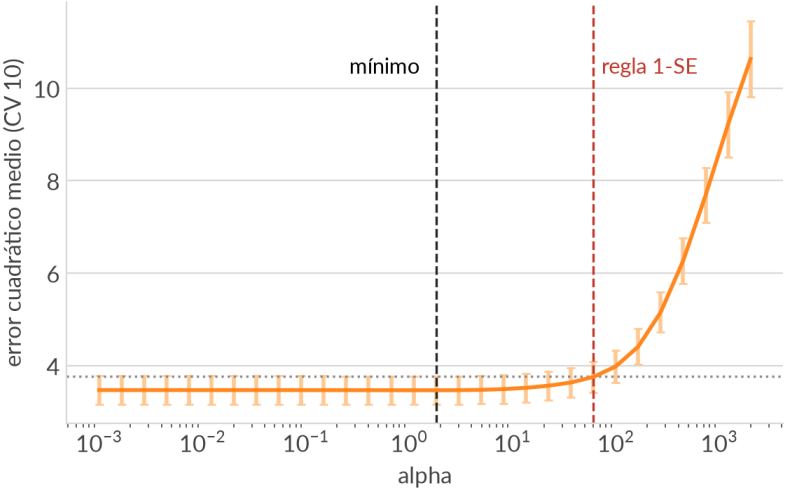


El Pipeline completo va dentro de cross_val_score: el escalado se reaprende en cada pliegue. Mismo resultado para OLS, Ridge y Lasso (≈ 1.82): aquí los ruidos son pocos y la regularización casi no cambia el error.

LEAD

Elegir λ: la curva de validación

El mínimo, y la regla de un error estándar




```
from sklearn.linear_model import RidgeCV
ridge = make_pipeline(StandardScaler(),
   RidgeCV(alphas=np.logspace(-3, 3, 50))).fit(X, y)
ridge[-1].alpha_
## 0.655
```

RidgeCV

Usa una versión eficiente de dejar uno fuera: prueba 50 valores casi al costo de un ajuste.

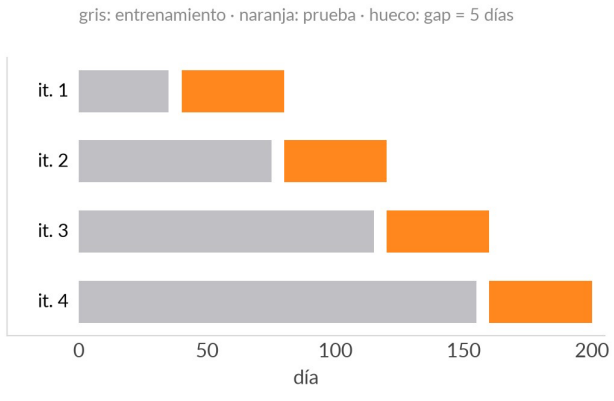
Regla 1-SE

El modelo más simple a una barra de error del mínimo.

Cuando los datos tienen reloj: TimeSeriesSplit

Entrenar en el pasado, probar en el futuro

```
from sklearn.model_selection import TimeSeriesSplit
# tipo de cambio simulado: caminata aleatoria de 200 dias
serie = 520 + np.cumsum(rng.normal(0, 1.5, 200))
tss = TimeSeriesSplit(n_splits=4, gap=5)
for i, (tr, te) in enumerate(tss.split(serie), 1):
    print(i, tr[-1], te[0], te[-1])
## 1 34 40 79
## 2 74 80 119
## 3 114 120 159
## 4 154 160 199
```



Es la trampa 3 de la pizarra, resuelta: nunca se usa el futuro para predecir el pasado, y gap deja un colchón entre ambos. Vuelve con fuerza en las semanas 6 y 7.

LEAD

Caso Costa Rica: pobreza y la ENAHO

El proxy-means test es un Lasso con propósito social

El contexto real

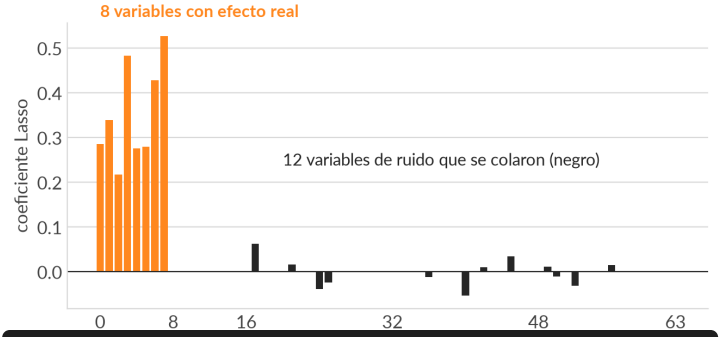
Según la ENAHO 2025 del INEC, el 15.2 % de los hogares está en pobreza (286 365 hogares) y el ingreso promedio es de ₡1 209 825 mensuales por hogar.

La pregunta

¿Con pocas variables fáciles de observar se puede predecir el ingreso para focalizar programas?

Un asterisco

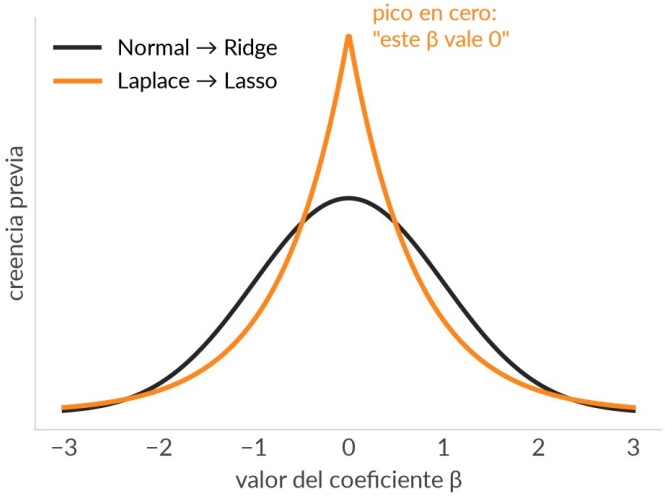
El INEC reconoció inconsistencias entre la ENAHO 2025 y la Encuesta Continua de Empleo.




```
# 64 variables simuladas; solo 8 con efecto real
X_enaho = rng.normal(size=(n, 64))
log_ingreso = (1.5 + X_enaho[:, :8] @ rng.uniform(0.3, 0.8, 8)
               + rng.normal(0, 1.0, n))
## seleccionadas: 20 de 64; las 8 reales, todas
```

La regularización es un prior disfrazado

El puente con la semana 4



La equivalencia

- Prior Normal(0, τ^2) sobre cada β: la moda del posterior es Ridge, con $\lambda = \sigma^2/\tau^2$.
- Prior Laplace: la moda del posterior es Lasso.
- Prior más concentrado = correa más corta.

La diferencia que importa

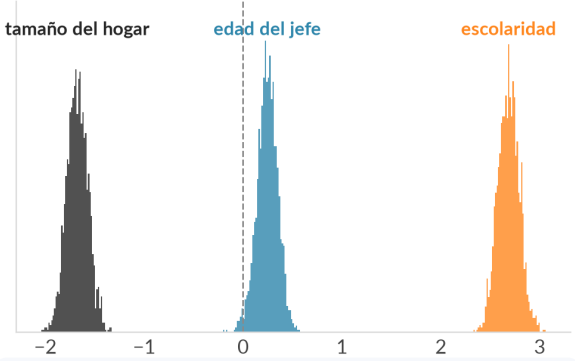
Ridge entrega un solo punto. El enfoque bayesiano entrega la distribución completa de cada coeficiente: su incertidumbre.

Regresión bayesiana con PyMC

El mismo patrón de la semana 4, ahora con coeficientes

```
import pymc as pm, arviz as az
X3 = df[["escolaridad", "tamano_hogar", "edad_jefe"]].values
X_std = StandardScaler().fit_transform(X3)

with pm.Model():
    b0 = pm.Normal("intercepto", mu=0, sigma=10)
    betas = pm.Normal("betas", mu=0, sigma=1, shape=3)
    sigma = pm.HalfNormal("sigma", sigma=5)
    mu = b0 + pm.math.dot(X_std, betas)
    pm.Normal("y_obs", mu=mu, sigma=sigma, observed=y)
    idata = pm.sample(random_seed=2026)
az.summary(idata, var_names=["betas"], kind="stats")
##           mean    sd eti89_lb eti89_ub
## betas[0]   2.7  0.11      2.5      2.9
## betas[1]  -1.7  0.11     -1.8     -1.5
## betas[2]  0.25   0.1    0.077     0.41
```



Cómo se lee

Prior Normal: sabor Ridge. La edad tiene un efecto pequeño cuyo intervalo de 89 % no llega a cero. Para sabor Lasso, basta pm.Laplace.

Bambi: la fórmula hace el trabajo

Regresión bayesiana en dos líneas

```
import bambi as bmb
m = bmb.Model("ingreso ~ escolaridad + tamano_hogar", data=df)
print(m)          # muestra los priors que eligio Bambi
## Intercept    ~ Normal(mu: 7.8242, sigma: 35.8691)
## escolaridad  ~ Normal(mu: 0.0, sigma: 2.5478)
## tamano_hogar ~ Normal(mu: 0.0, sigma: 4.7881)
## sigma        ~ HalfStudentT(nu: 4.0, sigma: 3.7627)

idata = m.fit(draws=2000, chains=4, random_seed=2026)
az.summary(idata, kind="stats")
## escolaridad   0.74  0.028  0.69  0.78
## tamano_hogar -0.87  0.055 -0.96 -0.78
```

Priors automáticos

Bambi elige priors débilmente informativos según la escala de los datos. Siempre hay que leerlos.

Misma respuesta

Coincide con statsmodels (0.735 y −0.873), ahora con distribución completa.

La misma sintaxis de fórmula de statsmodels. Con family="bernoulli" se vuelve una regresión logística bayesiana.

LEAD

¿Cuál modelo gana? az.compare

Comparación bayesiana de modelos con LOO

```
m1 = bmb.Model("ingreso ~ escolaridad", df)
m2 = bmb.Model("ingreso ~ escolaridad + tamano_hogar", df)
kw = {"log_likelihood": True}          # requisito para comparar
i1 = m1.fit(chains=4, random_seed=2026, idata_kwargs=kw)
i2 = m2.fit(chains=4, random_seed=2026, idata_kwargs=kw)
comp = az.compare({"simple": i1, "completo": i2})
comp[["rank", "elpd", "elpd_diff", "dse", "weight"]]
##           rank    elpd  elpd_diff   dse  weight
## completo     0  -610.0        0.0   0.0     1.0
## simple       1  -700.0      -90.0  11.0     0.0
```

Cómo se lee

elpd estima qué tan bien predice cada modelo datos nuevos. El completo gana por 90 puntos, unas 8 veces el error de la diferencia (dse).

Tiene sentido

Simulamos el ingreso con el tamaño del hogar.

LOO es validación cruzada dejando uno fuera, calculada sin reajustar el modelo 300 veces. En ArviZ 1.x reemplaza a WAIC, que ya no está disponible.

LEAD

De Ridge a los modelos de lenguaje

Por qué esta semana reaparece en toda la carrera

L2

Ridge: penalizar el cuadrado de los coeficientes (Hoerl y Kennard, 1970)

decay

Weight decay: la misma penalización sobre los pesos de una red

AdamW

Adam con decay desacoplado (Loshchilov y Hutter, 2019)

La historia en una frase

El weight decay de las redes neuronales es la penalización L2 de Ridge aplicada a millones de pesos. Con optimizadores como Adam ambos dejan de ser equivalentes, y AdamW los separa: es el optimizador habitual para entrenar modelos de lenguaje.

Lo veremos en la semana 11 con PyTorch. Quien hoy entiende por qué Ridge encoge coeficientes ya entiende una parte de cómo se regulariza un modelo grande.

LEAD

Actividad grupal en salas

Los últimos 40 minutos de clase, con los grupos del proyecto

Cómo funciona

Cada grupo va a una sala virtual con un notebook de Colab compartido. Una parte a mano y tres en Python. No se entrega ni se califica; lo que no terminen queda como tarea moral.

1. A mano

Recta de cuatro tiendas, su R^2 y el encogimiento de Ridge con tres valores de λ.

2. Python

Consumo eléctrico de 400 hogares: OLS con statsmodels y lectura de residuos.

3. Python

Ridge, Lasso y Elastic Net con Pipeline y validación cruzada. ¿Quién gana?

4. Python

La fuga de datos en vivo: seleccionar variables antes o dentro de la validación.

Recordatorio: el avance del proyecto se entrega en la semana 8 con un primer modelo aplicado. Una regresión bien validada ya cumple ese requisito.

LEAD

Síntesis de la sesión

Cada idea de hoy y dónde vuelve a aparecer

A mano	En la computadora	Vuelve en
La tablita de los cinco hogares	LinearRegression y statsmodels	Semana 6: ARIMA como regresión con rezagos
R^2 y los supuestos LINE	Residuos, Q-Q y Breusch-Pagan	Semana 6: diagnóstico de series
Ridge con $\lambda = 0, 20, 100$	Rutas de coeficientes y RidgeCV	Semana 11: weight decay y AdamW
El círculo y el rombo	LassoCV y la ENAHO simulada	Proyecto: selección de variables
K-fold y las tres trampas	Pipeline, KFold y TimeSeriesSplit	Semanas 6 y 7: validación temporal

Tres preguntas detrás de todo: ¿cuál es la mejor recta?, ¿cuánto debo frenarla? y ¿qué creo de sus coeficientes?

LEAD

Para la próxima semana

Clase 6 · jueves 15 de octubre · Series temporales clásicas

Pendientes

- Resolver la tarea moral de los cuatro bloques.
- Terminar las partes de la actividad que quedaron abiertas.
- Leer Hyndman y Athanasopoulos, Forecasting: Principles and Practice (3.ª ed.), capítulos 1 a 3, en otexts.com/fpp3.

Tema 6: series temporales

- Componentes: tendencia, estacionalidad y ruido.
- Modelos ARIMA y SARIMA.
- Diagnóstico y validación de modelos de series.
- statsmodels en Python y fpp3 en R.

Un ARIMA es, en el fondo, una regresión de la serie contra su propio pasado, validada siempre hacia adelante como en TimeSeriesSplit.

Dudas: jordy.alfaro@ulead.ac.cr

LEAD

LEAD UNIVERSITY

Lo que se llevan de esta sesión

La mejor recta minimiza errores al cuadrado

Se calcula con una tablita y se juzga con R^2 y con los residuos.

Regularizar es ponerle correa al modelo

Ridge encoge, Lasso apaga, Elastic Net mezcla. Siempre estandarizando dentro de un Pipeline.

Validar es examinar con datos no vistos

K-fold elige λ; TimeSeriesSplit cuando hay reloj. Y un prior es una correa con incertidumbre.

Nos vemos el próximo jueves con series temporales clásicas.