LEAD UNIVERSITY

Series temporales clásicas

Semana 6: separar la receta del tiempo, con R y fpp3

BCD5105 · Modelado matemático

Profesor: Jordy Alfaro Brenes

Lead University · III cuatrimestre 2026 · Modalidad virtual

Jueves 15 de octubre de 2026 · 4:00 a 7:00 p. m.

Ruta de la sesión

Primero las ideas, después el flujo completo en R

Al terminar la sesión usted podrá

- Reconocer tendencia, estacionalidad, ciclo y ruido en una serie.
- Explicar qué es una serie estacionaria y cómo la diferenciación la consigue.
- Leer una ACF y traducir ARIMA y SARIMA a palabras.
- Descomponer, modelar, diagnosticar y pronosticar una serie con fpp3.
- Validar un pronóstico sin hacer trampa y compararlo con un modelo ingenuo.

Bloques y tiempos estimados

1	Qué es una serie y sus ingredientes	20 min
2	Estacionariedad y diferencias	15 min
3	ACF y ARIMA, en palabras	20 min
	Receso	10 min
4	R: tsibble, exploración y STL	25 min
5	R: ARIMA, residuos y pronóstico	30 min
6	Validar contra el ingenuo	20 min
7	Actividad en salas	40 min

LEAD

LEAD UNIVERSITY

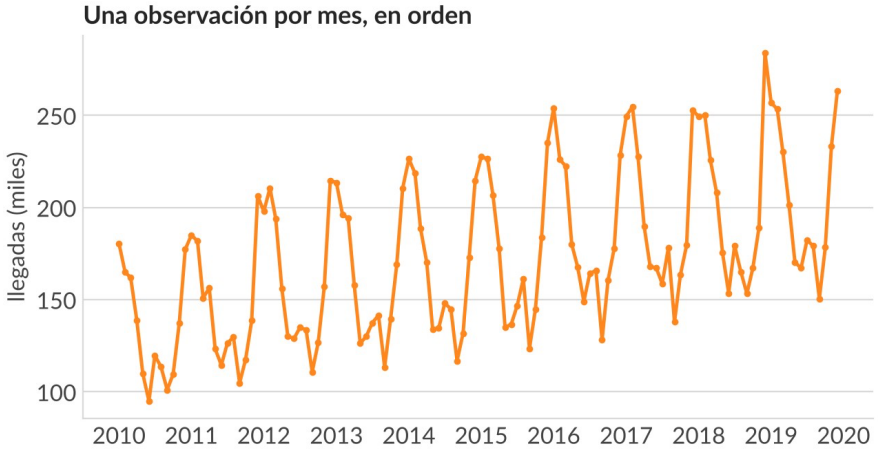
Parte 1

Las ideas

Qué es una serie de tiempo, qué ingredientes tiene, por qué hay que aplanarla y cómo leer su memoria. Sin fórmulas pesadas.

¿Qué es una serie de tiempo?

Aquí, a diferencia del resto del curso, el orden importa



La idea

Una observación por período (mes, trimestre, año), siempre en orden.

Lo que cambia

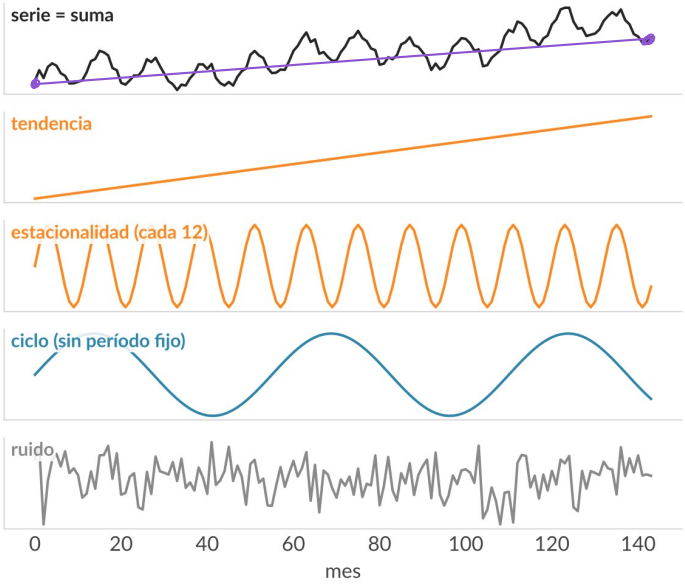
- El dato de hoy se parece al de ayer: hay memoria.
- No se pueden barajar los datos.
- Se rompe la independencia de la regresión.

Pronosticar es usar esa memoria. La pregunta de hoy: ¿cuántos turistas llegarán el mes que viene, y con cuánta confianza?

LEAD

La receta: cuatro ingredientes

Toda serie mezcla tendencia, estacionalidad, ciclo y ruido



Estacionalidad no es ciclo

La estacionalidad tiene período fijo y conocido: 12 meses, 7 días, 4 trimestres. El ciclo no: una recesión puede durar 2 años o 7.

Modelar es separar la receta

Quitar lo predecible (tendencia y estacionalidad) y quedarse con el ruido. Si en el ruido todavía hay patrón, el modelo dejó algo sin capturar.

LEAD

$\ln(a \cdot b) = \ln(a) + \ln(b)$

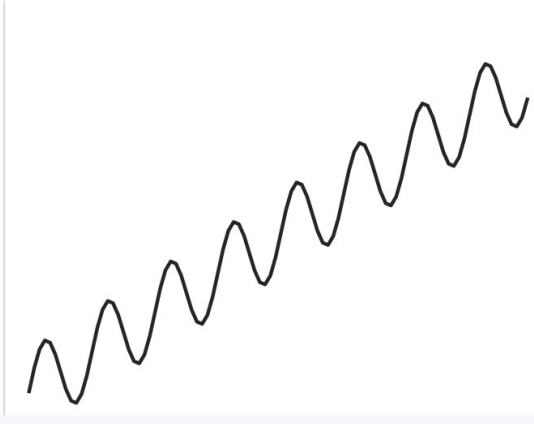
¿La oscilación es pareja o crece?

Aditiva contra multiplicativa, a ojo

$Ln(Serie) = Ln(T \cdot E \cdot R)$

$Ln(Serie) = Ln(T) + Ln(E) + Ln(R)$

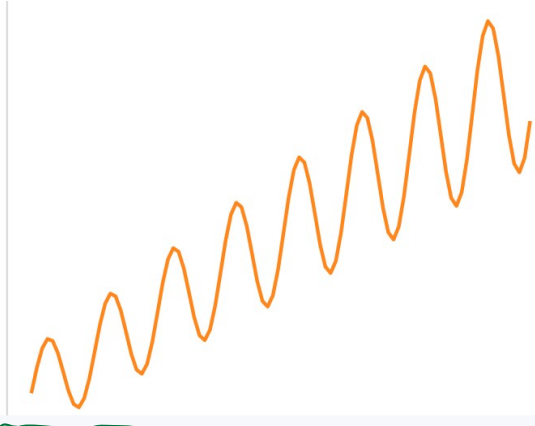
Aditiva: oscilación pareja



Aditiva

serie = tendencia + estacionalidad + ruido

Multiplicativa: oscilación que crece



Multiplicativa

serie = tendencia × estacionalidad × ruido. Turismo, ventas y economía suelen ser así; un logaritmo la vuelve aditiva.

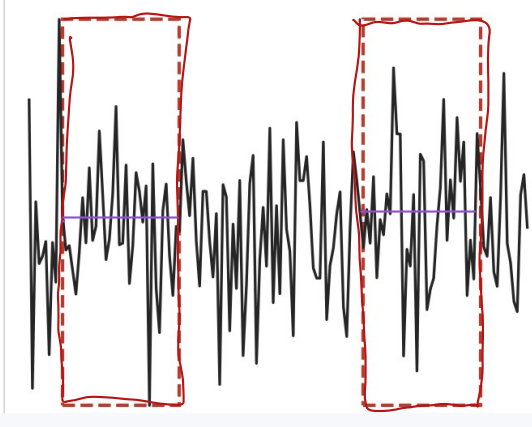
LEAD

Estacionalidad ≠

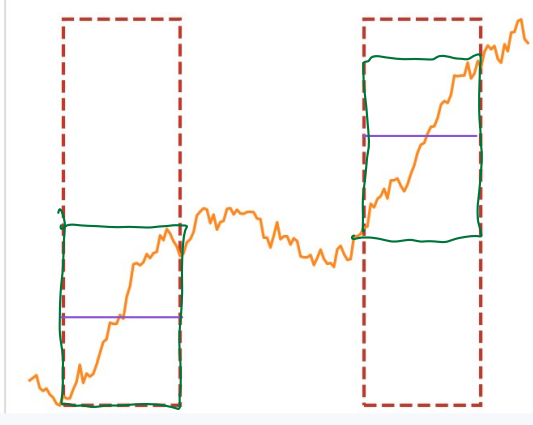
Estacionariedad: la prueba de la ventana

¿Se ve igual sin importar cuándo la miro?

Estacionaria: toda ventana se ve igual



No estacionaria: cada ventana es distinta



Estacionaria

Media y variabilidad no dependen del momento: cualquier ventana se parece a otra.

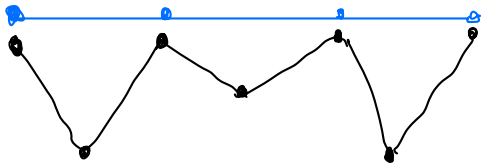
Por qué importa

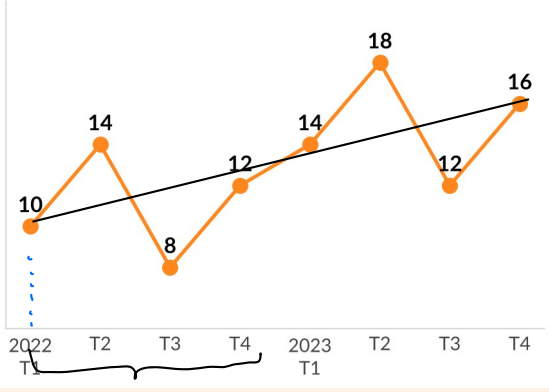
ARIMA solo sabe modelar series estacionarias. La tendencia y la estacionalidad hay que quitarlas primero.

LEAD

Micro ejemplo: diferenciar

Restarle a la serie su memoria · ventas trimestrales





Trimestre	y	$y_t - y_{t-1}$	$y_t - y_{t-4}$
2022 T1	10	—	—
2022 T2	14	14−10 = 4	—
2022 T3	8	8−14 = −6	—
2022 T4	12	12−8 = 4	—
2023 T1	14	14−12 = 2	→ 14−10=4
2023 T2	18	18−14 = 4	18−14 = 4
2023 T3	12	12−18 = −6	12−8 = 4
2023 T4	16	16−12 = 4	16−12 = 4

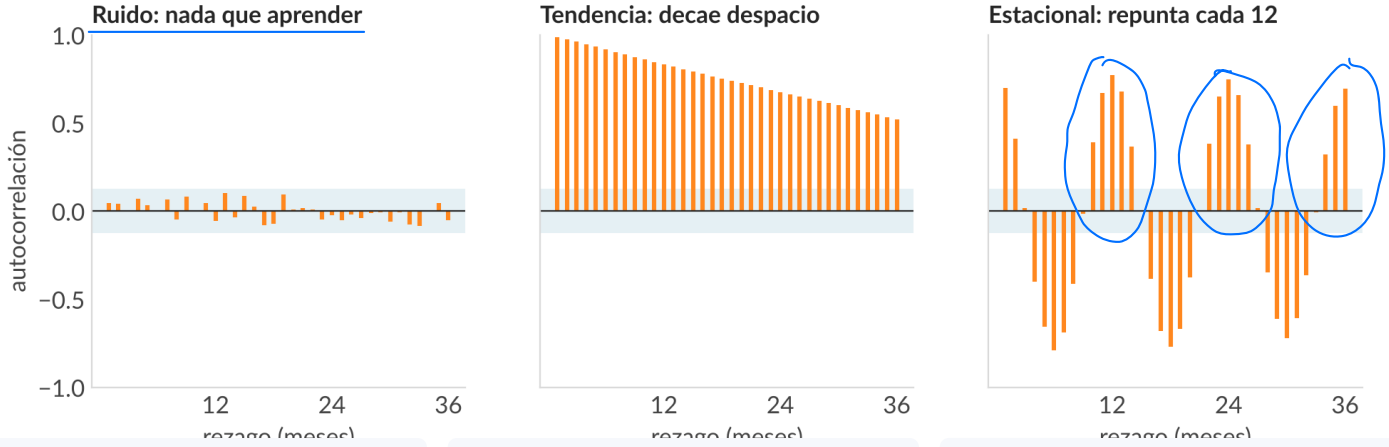
Primera diferencia: $y_t - y_{t-1}$

Diferencia estacional: $y_t - y_{t-4}$

LEAD

ACF: la serie comparada consigo misma

Qué mide y qué forma tiene, sin la fórmula



La idea

Correlación entre la serie y una copia suya corrida k pasos (el rezago).

La franja azul

Lo que el azar puede producir. Las barras que la superan son memoria real.

PACF

Igual, pero descontando los rezagos intermedios: la relación directa.

LEAD

ARIMA y SARIMA, en palabras

Tres letras, tres ideas

AR

autorregresivo: hoy depende de mis valores pasados

I

integrado: cuántas veces diferencié para aplanar

MA

media móvil: hoy corrijo con mis errores pasados

$$\text{SARIMA}(p, d, q)(P, D, Q)_m$$

Minúsculas y mayúsculas

Las minúsculas modelan el corto plazo (mes a mes); las mayúsculas, el ciclo anual (el mismo mes del año pasado). Es la misma idea aplicada dos veces.

El modelo de aerolínea

ARIMA$(0,1,1)(0,1,1)_{12}$: una diferencia ordinaria, una estacional y un poco de memoria de errores en cada parte. El clásico para series mensuales.

LEAD

LEAD UNIVERSITY

Ejemplos

Resolvemos juntos en la pizarra

Las ideas

Ejemplo 1

Ventas trimestrales: 30, 42, 24, 36, 33, 45, 27, 39.

a) Calcule la primera diferencia.

b) Calcule la diferencia estacional (m = 4).

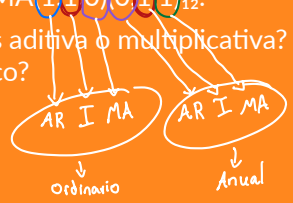
c) ¿Qué queda? Describa la serie con sus ingredientes.

Ejemplo 2

a) Una ACF decae muy despacio y repunta en 12 y 24. ¿Cuántas diferencias ordinarias y estacionales sugiere? $d = 1$ $D = 1$

b) Traduzca a palabras ARIMA $(1,1,0)(0,1,1)_{12}$.

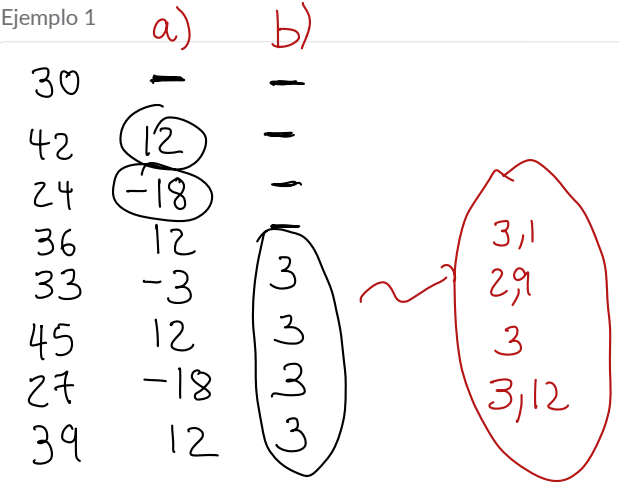
c) ¿La llegada de turistas es aditiva o multiplicativa? ¿Cómo lo vería en un gráfico?



Espacio de trabajo

Las ideas

Ejemplo 1



Ejemplo 2



LEAD

LEAD UNIVERSITY

Ejercicios

Tarea moral · resuélvalos durante la semana

Las ideas

Ejercicio 1

Serie trimestral: 5, 9, 7, 3, 7, 11, 9, 5.

a) Calcule ambas diferencias.

b) ¿Cuál de las dos deja una constante? ¿Qué significa?

Ejercicio 2

Clasifique como aditiva o multiplicativa y justifique:

a) Temperatura diaria de San José.

b) Ventas mensuales de una tienda que crece rápido.

c) Casos semanales de dengue en años de brote.

Ejercicio 3

El modelo ingenuo estacional pronostica que cada mes repetirá el valor del mismo mes del año anterior.

Con las llegadas de 2019, ¿qué pronostica para enero de 2020? ¿Por qué es difícil de superar?

LEAD UNIVERSITY

Receso: Volvemos 5:50pm.

Parte 2

Series temporales en R

El flujo completo con fpp3: estructurar, explorar, descomponer, modelar, diagnosticar, pronosticar y validar.

El stack de la semana

Volvemos a R: el ecosistema tidyverts, vigente a octubre de 2026

fpp3 1.0

Carga todo de un golpe y acompaña al libro gratuito de Hyndman y Athanasopoulos (otexts.com/fpp3).

tsibble 1.2

La tabla que sabe que su índice es el tiempo.

fable 0.5

Los modelos: ARIMA(), ETS(), SNAIVE(). STL() viene de feasts.

ggtime 1.1

Los gráficos de series (gg_season, gg_tsresiduals) ahora viven aquí. fpp3 lo carga solo.

```
# Colab: Entorno de ejecucion > Cambiar tipo de entorno > R
install.packages("fpp3")   # una vez por sesion, tarda unos minutos
library(fpp3)
```

En Python

statsmodels tiene STL y SARIMAX con la misma lógica.

Regla de la semana: siempre library(fpp3) al inicio. Todo el flujo habla el mismo idioma: el tsibble.

LEAD

¿Para qué sirven las series temporales hoy?

Pronosticar es decidir antes de que pase

TURISMO

Llegadas e itinerarios

El ICT y las aerolíneas pronostican llegadas mensuales para planear capacidad. Estacionalidad anual muy marcada: el caso de hoy.

ENERGÍA

Demanda eléctrica

Se pronostica hora a hora para despachar generación. Estacionalidad diaria, semanal y anual a la vez.

SALUD PÚBLICA

Brotes y epidemias

Los casos de dengue por semana epidemiológica siguen la temporada de lluvias.

COMERCIO Y FINANZAS

Demanda e inventario

Ventas, flujos de caja e inventarios. La competencia M5 (2020) usó ventas de Walmart.

ARIMA y sus parientes siguen siendo la línea base que cualquier modelo moderno debe superar.

LEAD

El protagonista: el objeto tsibble

Una tabla que sabe que el tiempo es su eje

```
library(fpp3)

ventas <- tsibble(
  Trim  = yearquarter("2023 Q1") + 0:3,
  Total = c(120, 90, 105, 160),
  index = Trim)
ventas
## # A tsibble: 4 x 2 [1Q]
##      Trim Total
## 1 2023 Q1   120
## 2 2023 Q2    90
## 3 2023 Q3   105
## 4 2023 Q4   160
```

Qué lo hace especial

- [1Q]: una observación por trimestre.
- Sabe que después de 2023 Q4 viene 2024 Q1.
- Detecta huecos en el calendario.

Índices de calendario

yearmonth(), yearquarter() y yearweek() crean el índice correcto.

Graficar, descomponer, modelar y validar: todo el ecosistema recibe un tsibble.

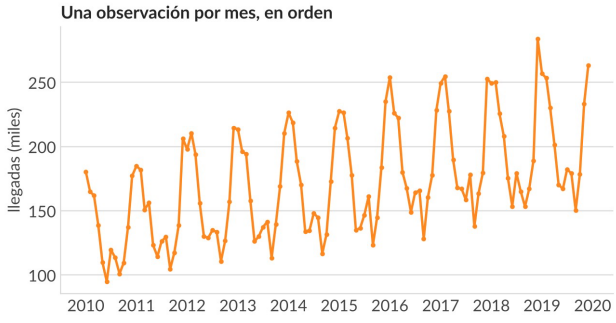
LEAD

La serie de hoy: turismo simulado

120 meses al estilo de las llegadas del ICT

```
set.seed(2026)
n <- 120; t <- 1:n
tendencia  <- 130000 + 650 * t
patron <- c(1.35, 1.32, 1.22, 1.05, 0.85, 0.80,
            0.92, 0.88, 0.74, 0.82, 1.02, 1.33)
estacional <- patron[((t - 1) %% 12) + 1]
ruido      <- rnorm(n, 0, 0.045)
llegadas   <- round(tendencia * estacional * (1 + ruido))

turismo <- tsibble(
  Mes = make_yearmonth(2010, 1) + 0:(n - 1),
  Llegadas = llegadas, index = Mes)
turismo |> autoplot(Llegadas)
```

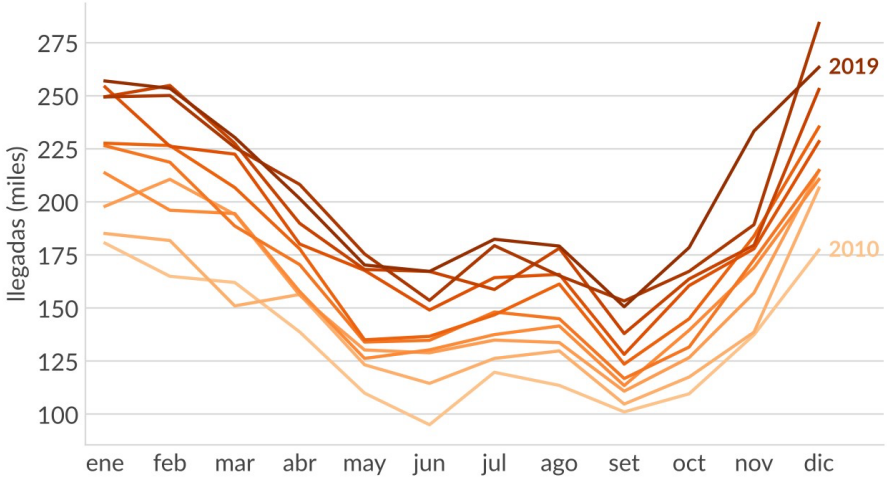


Por qué simulada

Conocemos la verdad: +650 llegadas por mes y un patrón fijo, multiplicativo. Además evitamos el quiebre de la pandemia que tiene la serie real del ICT.

Mirar antes de modelar: gg_season

Un año por línea, superpuestos sobre los 12 meses




```
turismo |> gg_season(Llegadas)
```

La forma de cada línea

Alto de diciembre a marzo, bajo en setiembre: la estacionalidad.

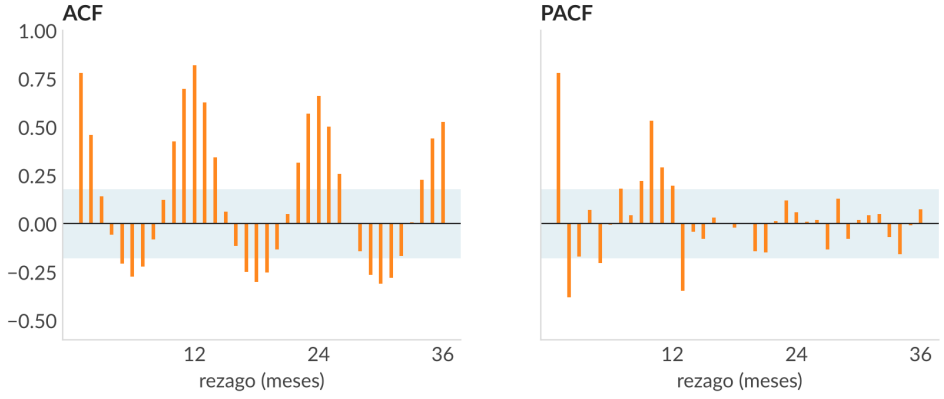
La altura de las líneas

Los años recientes (oscuros) van más arriba: la tendencia.

LEAD

ACF y PACF de la serie

La firma que anticipa cuántas diferencias hacen falta




```
turismo |> gg_tsdisplay(Llegadas, plot_type = "partial")
turismo |> ACF(Llegadas)  |> autoplot()
turismo |> PACF(Llegadas) |> autoplot()
```

Lo que se lee

La ACF repunta en 12, 24 y 36 (0.82 en el rezago 12): estacionalidad anual muy marcada.

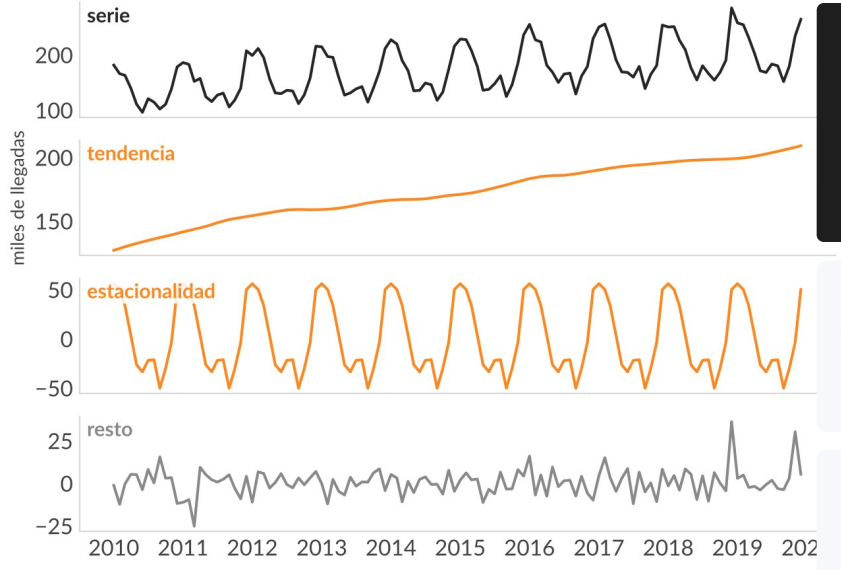
Lo que sugiere

Hace falta al menos una diferencia estacional. La prueba KPSS lo confirma más adelante.

LEAD

Descomposición STL: separar la receta

La descomposición estándar, en una línea




```
dcmp <- turismo |>
  model(STL(Llegadas ~ trend() +
        season(window = "periodic"),
        robust = TRUE))
components(dcmp) |> autoplot()
```

Lo que separa

Tendencia suave que sube, estacionalidad que se repite cada 12 meses y un resto pequeño.

robust = TRUE

Evita que un mes atípico deforme la tendencia.

LEAD

Diferenciar y decidir cuántas veces

La resta del micro ejemplo, ahora en R

```
mini <- tsibble(
  Trim = yearquarter("2022 Q1") + 0:7,
  y = c(10, 14, 8, 12, 14, 18, 12, 16),
  index = Trim)
mini |> mutate(d1 = difference(y),
               d4 = difference(y, 4))
##      Trim     y    d1    d4
## 1 2022 Q1    10    NA    NA
## 2 2022 Q2    14     4    NA
## 3 2022 Q3     8    -6    NA
## 4 2022 Q4    12     4    NA
## 5 2023 Q1    14     2     4
## 6 2023 Q2    18     4     4
## 7 2023 Q3    12    -6     4
## 8 2023 Q4    16     4     4
```

```
turismo |> features(Llegadas, unitroot_kpss)
## kpss_stat 1.06   kpss_pvalue 0.01
turismo |> features(Llegadas, unitroot_nsdiffs)
## nsdiffs 1
turismo |> features(Llegadas, guerrero)
## lambda_guerrero 0.27
```

Cómo se lee

KPSS: p = 0.01, la serie no es estacionaria. Hace falta una diferencia estacional. Guerrero sugiere una transformación intermedia (λ = 0.27, entre raíz y logaritmo) por la oscilación que crece.

LEAD

Dejar que la máquina elija: ARIMA()

El algoritmo de Hyndman y Khandakar, comparado con el clásico

```
fit <- turismo |>
  model(
    auto      = ARIMA(Llegadas),
    aerolinea = ARIMA(Llegadas ~ 0 + pdq(0,1,1) + PDQ(0,1,1)))
fit
##   auto                                aerolinea
##   <ARIMA(0,0,0)(0,1,1)[12] w/ drift>  <ARIMA(0,1,1)(0,1,1)[12]>
```

Qué eligió

Una diferencia estacional, sin diferencia ordinaria, con una deriva (drift) que captura la tendencia de +650 por mes. No eligió el modelo de aerolínea.

La trampa del AICc

El AICc solo compara modelos con las mismas diferencias. Estos dos tienen distinto d: no se comparan por AICc.

Entonces, ¿cuál?

El que pronostique mejor datos que no vio. Lo decidimos con validación, en unas láminas.

LEAD

Qué estimó cada modelo: report()

Coeficientes con su error estándar

```
fit |> select(auto) |> report()
## ARIMA(0,0,0)(0,1,1)[12] w/ drift
##          sma1   constant
##       -0.7761  7847.2558
## s.e.   0.1163   329.0049
```

```
fit |> select(aerolinea) |> report()
## ARIMA(0,1,1)(0,1,1)[12]
##           ma1     sma1
##       -0.9528  -0.7573
## s.e.   0.0731   0.1145
```

sma1

Peso del error del mismo mes del año pasado. Ambos modelos lo estiman cerca de −0.77.

constant = 7847

Crecimiento de un año al siguiente, cerca de 12 × 650 = 7800: el modelo recuperó la tendencia simulada.

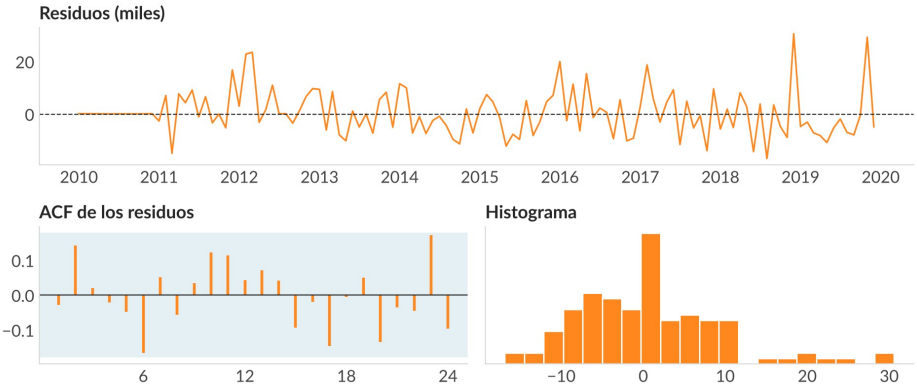
ma1 ≈ −0.95

Un MA cerca de −1 delata una diferencia de más: por eso el algoritmo no diferenció dos veces.

LEAD

El modelo confiesa en sus residuos

¿Quedó solo ruido blanco?



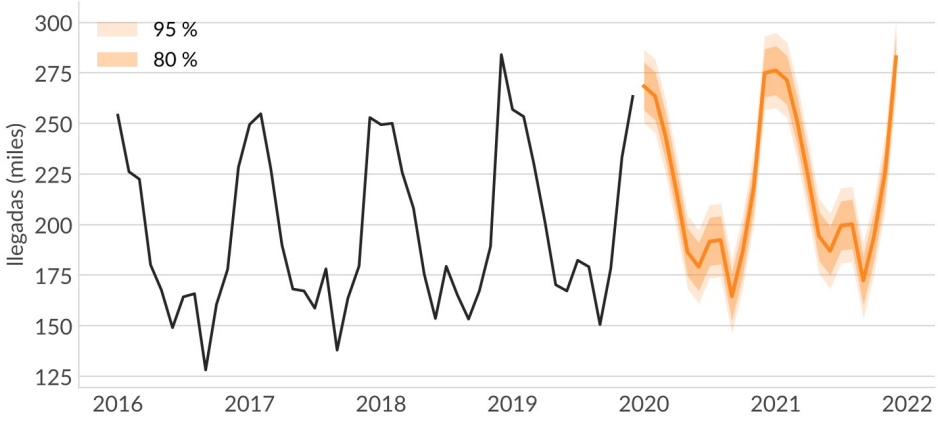

```
fit |> select(auto) |>
  gg_tsresiduals()
augment(fit) |>
  filter(.model == "auto") |>
  features(.innov, ljung_box,
           lag = 24, dof = 1)
## lb_stat 26.1  lb_pvalue 0.294
```

Cómo se lee

La ACF de los residuos queda casi toda en la franja y Ljung-Box da p = 0.29: no hay evidencia de estructura sobrante. dof es el número de coeficientes ARMA (aquí, sma1).

Pronosticar: forecast() e intervalos

No un número, sino una distribución de futuros




```
fc <- fit |> select(auto) |> forecast(h = "2 years")
fc |> autoplot(turismo, level = c(80, 95))
```

```
## Mes       Llegadas
## 2020 Jan  N(268377, 8.6e+07)
## 2020 Feb  N(263582, 8.6e+07)
## 2020 Mar  N(243637, 8.6e+07)
```

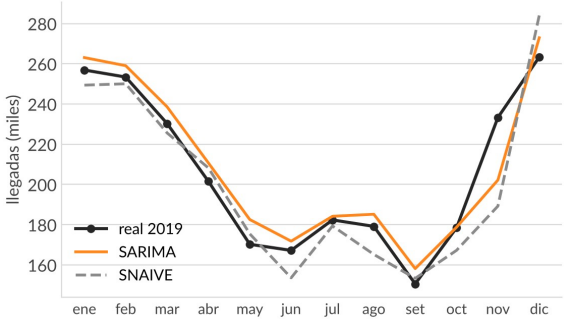
Cómo se lee

Cada mes trae una normal: media y varianza. Las franjas son los intervalos de 80 % y 95 %. El pronóstico conserva la estacionalidad y la tendencia que el modelo aprendió.

¿Le gana al ingenuo? SARIMA contra SNAIVE

Entrenar hasta 2018 y pronosticar 2019

```
entreno <- turismo |> filter(Mes < make_yearmonth(2019, 1))
entreno |>
  model(snaive    = SNAIVE(Llegadas),
        auto      = ARIMA(Llegadas),
        aerolinea = ARIMA(Llegadas ~ 0 + pdq(0,1,1) + PDQ(0,1,1))) |>
  forecast(h = 12) |> accuracy(turismo) |>
  select(.model, RMSE, MAPE, MASE)
##   .model      RMSE  MAPE  MASE
## 1 aerolinea  11461  4.09 0.818
## 2 auto       11373  4.11 0.818
## 3 snaive     15949  5.42 1.09
```



SNAIVE

Repetir el mismo mes del año pasado. Gratis y difícil de superar.

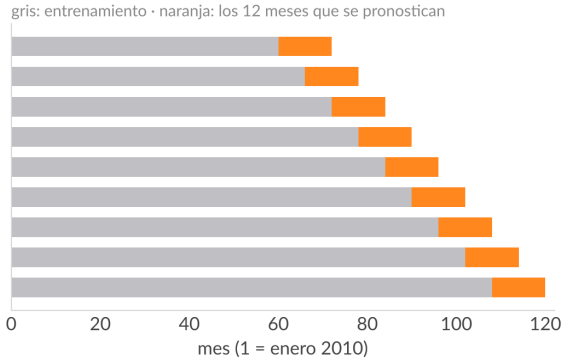
MASE

Error relativo al ingenuo: menos de 1 le gana. Ambos SARIMA lo logran (0.82).

Validar sin hacer trampa: ventana expansiva

El TimeSeriesSplit de la semana pasada, ahora en R

```
cv <- turismo |>
  filter(Mes < make_yearmonth(2019, 1)) |>
  stretch_tsibble(.init = 60, .step = 6)   # 9 ventanas
cv |>
  model(snaive = SNAIVE(Llegadas), auto = ARIMA(Llegadas),
        aerolinea = ARIMA(Llegadas ~ 0 + pdq(0,1,1) + PDQ(0,1,1))) |>
  forecast(h = 12) |> accuracy(turismo) |>
  select(.model, RMSE, MASE) |> arrange(MASE)
##   .model     RMSE   MASE
## 1 auto       9905  0.752
## 2 aerolinea 10207  0.764
## 3 snaive    13950  1.04
```



Nueve entrenamientos que solo ven su pasado. Con más evidencia, los dos SARIMA quedan casi empatados y ambos le ganan al ingenuo: la diferencia de AICc no decidía nada.

LEAD

Para el proyecto: datos reales de Costa Rica

Series con estacionalidad de verdad

TURISMO

Llegadas del ICT

Series mensuales descargables. En 2025 llegaron 2 689 278 turistas por vía aérea; diciembre creció 13.6 % frente a 2024.

SALUD

Dengue del Ministerio de Salud

Casos por semana epidemiológica (m ≈ 52), ligados a la temporada de lluvias. Vienen en PDF: hay que transcribirlos.

ECONOMÍA

Indicadores del BCCR

IMAE mensual, tipo de cambio y otras series en el portal de indicadores económicos.

Advertencia de modelador: la serie real del ICT tiene un quiebre enorme en 2020 y 2021 por la pandemia. Conviene usar datos anteriores a 2020 o posteriores a 2022, o tratar ese período como una intervención. Por eso hoy aprendemos la mecánica con una serie simulada limpia.

¿Siguen vigentes los clásicos? Las competencias M

La evidencia sobre qué funciona

M4 • 2018

100 000 series: ganó un híbrido de suavizamiento exponencial y red recurrente

M5 • 2020

Ventas de Walmart: ganaron métodos de aprendizaje automático (LightGBM)

M6 • 2022-23

Finanzas: solo el 23 % de los equipos superó el pronóstico de referencia

La lección

- Con muchos datos regulares y jerárquicos, el aprendizaje automático gana.
- Con pocos datos o ruido casi puro, los clásicos siguen siendo competitivos.
- Los mejores resultados suelen ser combinaciones de modelos.

ARIMA y ETS no están obsoletos: son la línea base que todo método moderno debe superar.

LEAD

La frontera: modelos de fundación para series

Pronosticar sin entrenar, como un LLM

Qué son

Modelos preentrenados con millones de series que pronostican una serie nueva sin reentrenar (zero-shot).

- Chronos y Chronos-2 (Amazon)
- TimesFM (Google)
- Moirai (Salesforce)

Cómo se evalúan

GIFT-Eval: 23 conjuntos de datos, unas 144 000 series y 177 millones de puntos. Son competitivos en muchos casos, pero los clásicos siguen siendo difíciles de batir en varios dominios.

Todos, del SARIMA al modelo de fundación, comparten la idea de hoy: separar tendencia, estacionalidad y resto. Cambia cómo se estima cada parte. La próxima semana: Prophet, NeuralProphet y Chronos, medidos con el mismo MASE contra el mismo SNAIVE.

LEAD

Síntesis: el flujo completo de fpp3

Ocho pasos, un solo idioma

Paso	Qué hace	Función clave
1. Estructurar	Tabla que entiende el calendario	tsibble(), yearmonth()
2. Explorar	Ver tendencia y estacionalidad	autoplot(), gg_season(), ACF()
3. Descomponer	Separar la receta	STL() + components()
4. Estacionarizar	Decidir cuántas diferencias	unitroot_kpss, unitroot_nsdiffs
5. Modelar	Elegir (p,d,q)(P,D,Q)	ARIMA(), report()
6. Diagnosticar	¿Residuos de ruido blanco?	gg_tsresiduals(), ljung_box
7. Pronosticar	Distribución de futuros	forecast(), autoplot()
8. Validar	Comparar fuera de muestra	stretch_tsibble(), accuracy()

Cambia la serie (turismo, dengue, electricidad); el flujo es siempre este.

Conexión con el proyecto y el calendario

Lo que viene en las próximas semanas

Carriles donde encaja

- Demanda eléctrica: SARIMA frente a la regresión de la semana 5.
- Turismo: SARIMA frente a un modelo de fundación.
- Dengue: SARIMA estacional junto al SEIR de la semana 2.

Un primer modelo sólido

Una serie descompuesta, un SARIMA validado contra SNAIVE en MASE y un diagnóstico de residuos ya cumplen el primer modelo del avance.

Semana	Qué pasa
8 (29 de octubre)	Repaso con un ejemplo parecido a la prueba parcial; se asigna la prueba y se empieza en clase. Entrega del avance del proyecto.
9 (5 de noviembre)	Entrega de la prueba parcial grupal, antes de la sesión.
13 (3 de diciembre)	Las tres presentaciones grupales de tema complementario.

Actividad grupal en salas

Los últimos 40 minutos de clase, con los grupos del proyecto

Cómo funciona

Cada grupo va a una sala virtual con un notebook de Colab con entorno de R. Una parte a mano y tres en R. No se entrega ni se califica; lo que no terminen queda como tarea moral.

1. A mano

Diferencias de una serie trimestral y lectura de tres ACF.

2. R

Demanda eléctrica mensual simulada: tsibble, gg_season y STL.

3. R

ARIMA automático, report() y diagnóstico con Ljung-Box.

4. R

Validación contra SNAIVE en un año de prueba. ¿Gana el SARIMA?

Instalen fpp3 en cuanto abran el notebook: tarda unos minutos y pueden trabajar la parte a mano mientras tanto.

LEAD

Para la próxima semana

Clase 7 · jueves 22 de octubre · Series temporales modernas

Pendientes

- Resolver la tarea moral de la parte de ideas.
- Terminar las partes de la actividad que quedaron abiertas.
- Leer en fpp3 (otexts.com/fpp3) los capítulos de descomposición y de ARIMA.
- Avanzar el primer modelo del proyecto: el avance se entrega en la semana 8.

Tema 7: series modernas

- Prophet: tendencia más estacionalidad de Fourier.
- NeuralProphet y modelos basados en aprendizaje automático.
- Modelos de fundación: Chronos.
- El mismo árbitro de hoy: MASE contra SNAIVE.

Si quedó claro que un pronóstico se valida en el futuro y se compara contra un ingenuo, la mitad de las series modernas ya está ganada.

Dudas: jordy.alfaro@ulead.ac.cr

LEAD

LEAD UNIVERSITY

Lo que se llevan de esta sesión

Una serie es una receta

Tendencia, estacionalidad, ciclo y ruido. STL los separa; lo que sobra debe ser pequeño y sin patrón.

Diferenciar aplana

La "I" de ARIMA es una resta. KPSS decide cuántas; la ACF y los residuos dicen si alcanzó.

Validar es mirar al futuro

Ventana expansiva y MASE contra el ingenuo. El AICc no compara modelos con distintas diferencias.

Nos vemos el próximo jueves con series temporales modernas.