

Modelado matemático

Semana 1: fundamentos del modelado matemático

BCD5105 · Modelado matemático

Profesor: Jordy Alfaro Brenes

Lead University · III cuatrimestre 2026 · Modalidad virtual

Jueves de 4:00 a 7:00 p. m.

Bienvenidos al curso

El puente entre la matemática rigurosa y las decisiones del mundo real

De qué se trata este curso

Es un curso teórico-práctico en el que aprenderán a formular, implementar y validar modelos matemáticos para resolver problemas reales. Van a conocer la maquinaria matemática que hay detrás de casi todo lo que hoy llamamos ciencia de datos: ecuaciones diferenciales, cadenas de Markov, simulación de Monte Carlo, regresión, series temporales, optimización, teoría de grafos, teoría de la decisión y aprendizaje por refuerzo.

Modalidad

Virtual, jueves de 4:00 a 7:00 p. m. Se recomienda cámara encendida y participación activa en el chat y en las dinámicas de cada sesión.

Lenguajes y herramientas

Python y R sobre Google Colab y Posit Cloud, con GitHub para el control de versiones y la entrega del proyecto integrador.

Materiales

Presentaciones, notebooks del profesor y datasets reales de Costa Rica (BCCR, INEC, ICE, AyA, ICT) compartidos semanalmente en Moodle.

Al final del curso no van a poder mirar un noticiero, una tarifa eléctrica, un pronóstico del tiempo o un sistema de recomendación sin reconocer detrás un modelo matemático que decidió algo importante por ustedes.

Presentémonos

Quién les acompaña este cuatrimestre y quiénes son ustedes

EL PROFESOR

Jordy Alfaro Brenes

- Consultor de ciencia de datos e inteligencia artificial en BDO Costa Rica.
- Profesor universitario de matemática, ciencia de datos e IA.
- Formación en enseñanza de la matemática (TEC) y en métodos matemáticos con énfasis en ciencia de datos (UCR).
- Trabaja a diario con Python, R y Power BI en proyectos reales de analítica y modelado.
- Correo: jordy.alfaro@ulead.ac.cr. Atención a estudiantes en sesiones virtuales a convenir.

LOS ESTUDIANTES: DOS MINUTOS CADA UNO

Ronda de presentaciones

- Nombre y a qué se dedican actualmente.
- Experiencia previa con Python, R o alguna herramienta de datos (cualquier nivel es bienvenido).
- Un problema de su trabajo o de su vida que les gustaría modelar.
- Qué esperan llevarse del curso.
- Un modelo matemático que crean haber usado hoy sin darse cuenta.

Con esta ronda empezamos a armar los grupos de trabajo de 3 o 4 personas que se mantendrán todo el cuatrimestre.

Agenda de hoy

Lo que vamos a cubrir en esta primera sesión

1. Qué es un modelo matemático

Definición, el mapa que no es el territorio y los modelos que decidieron por ustedes hoy

3. Propiedades de los modelos

Validación, calibración, identificabilidad, sensibilidad y parsimonia

5. Modelado en Costa Rica y la región

El equipo de la UCR que llegó a Nature, el BCCR, el ICE, el IMN y más

7. El sílabo en resumen

Cronograma, evaluación, proyecto, presentaciones grupales y políticas del curso

2. Historia y propósito

De Newton a los modelos de fundación: tres siglos en diez minutos

4. Éxitos y fracasos célebres

Casos donde los modelos salvaron millones y casos donde los hundieron

6. Demo en Colab

Crecimiento poblacional de Costa Rica con dos modelos: lineal y logístico

8. Formación de grupos

Conformar los equipos y asignar los temas de la presentación grupal

¿Qué es un modelo matemático?

Una definición rigurosa, pero accesible

Un modelo matemático es una representación formal, expresada en lenguaje matemático, de un fenómeno o sistema del mundo real, construida con un propósito específico de comprensión, predicción o decisión.

Fomal

Lo que no se puede escribir en notación matemática (ecuaciones, grafos, distribuciones, algoritmos) no es un modelo matemático.

Intencional

Todo modelo se construye para algo. No existe un modelo verdadero, solo modelos útiles para preguntas concretas.

Simplificado

El modelo no es el sistema. Es una caricatura intencional, un mapa, una idealización del fenómeno.

El modelo no busca copiar la realidad. Busca resaltar lo que importa para responder una pregunta concreta y tomar una decisión.

El mapa no es el territorio

Tres metáforas para entender la relación entre modelo y realidad

El mapa del metro de Londres

El diagrama que Harry Beck dibujó en 1933 es geográficamente incorrecto: estira distancias, endereza curvas e inventa ángulos rectos. Y sin embargo es uno de los mejores mapas jamás creados, porque responde con perfección a la pregunta correcta: ¿cómo llego de A a B en metro? Un buen modelo no copia la realidad, la simplifica con criterio.

La caricatura

Un buen caricaturista exagera ciertos rasgos para hacer visible la esencia. Como dijo el Dr. Fabio Sánchez (UCR) sobre su modelo de COVID-19: se trata de hacer una caricatura de la realidad.

Korzybski, 1931

"A map is not the territory". Todo modelo es un mapa: útil si nos lleva al destino, peligroso si lo confundimos con la realidad misma.

La pregunta correcta no es "¿es verdadero el modelo?", sino "¿es lo suficientemente útil para la decisión que tengo que tomar?"

¿Cuántos modelos decidieron por ustedes hoy?

El modelado matemático ya está en todas partes

MAÑANA

El filtro de su correo

Un clasificador bayesiano (o un transformer moderno) decidió qué correos vieron en la bandeja principal y cuáles fueron al spam, con un modelo probabilístico entrenado con millones de mensajes.

TRANSPORTE

Waze y el ICE

Waze calculó su ruta resolviendo el problema del camino mínimo en un grafo (Dijkstra). El ICE pronosticó la demanda eléctrica para decidir cuánta agua liberar en Reventazón.

MEDIODÍA

Recomendaciones y precios

Spotify, Netflix y Amazon les recomendaron contenido con modelos de factorización matricial. Uber Eats calculó el precio dinámico con un modelo de oferta y demanda en tiempo real.

TARDE

El BCCR y su banco

El BCCR ajustó la tasa de política monetaria con un modelo macroeconómico. Su banco le aprobó (o negó) una tarjeta de crédito con un modelo de credit scoring.

Probablemente más de 30 modelos matemáticos tomaron decisiones por ustedes entre que despertaron y se conectaron a esta clase. La pregunta no es si confiamos en los modelos, sino si los entendemos.

Historia del modelado matemático I

De Newton a Kermack: cuando la matemática conquistó la realidad

1687 — Newton

Las leyes del movimiento y la gravitación universal son el primer gran sistema de ecuaciones diferenciales que predice el comportamiento del mundo físico con precisión asombrosa.

1705 — Halley

Usando la mecánica de Newton, Edmond Halley predice el regreso del cometa en 1758. El cometa apareció. Triunfo paradigmático del modelado predictivo.

1838 — Verhulst

Modelo logístico de crecimiento poblacional. La primera respuesta matemática a Malthus que reconoce la saturación de recursos. Lo veremos hoy en la demo.

1925-1926 — Lotka y Volterra

Ecuaciones depredador-presa. Volterra las dedujo al intentar explicar por qué los tiburones aumentaron en el Adriático cuando bajó la pesca durante la I Guerra Mundial.

1927 — Kermack y McKendrick: el modelo SIR

Dividen a la población en susceptibles, infectados y recuperados. Es el ancestro directo de todos los modelos de COVID-19 que vimos en 2020. Su gran aporte: el número básico de reproducción R_0 , el indicador que dictó las cuarentenas del mundo entero.

Historia del modelado matemático II

De Fisher a TabPFN: la era de los datos

1925-1948 — Era estadística

Fisher (verosimilitud, ANOVA), Neyman y Pearson (pruebas de hipótesis), Kolmogorov (probabilidad moderna), Wiener (cibernética). Las herramientas para razonar con datos.

1970 — Box y Jenkins

Publican Time Series Analysis. Nacen los modelos ARIMA que dominarán el pronóstico por cinco décadas. Los estudiaremos a fondo en la semana 6.

1986-2012 — Era del machine learning

Backpropagation (Rumelhart y Hinton), SVM (Vapnik), random forests (Breiman), deep learning (AlexNet, 2012). La estadística se encuentra con la computación masiva.

2017 — Transformers

Vaswani y colaboradores publican Attention Is All You Need. Es la arquitectura matemática detrás de ChatGPT, Claude, Gemini y de prácticamente toda la IA generativa actual.

2020-2026 — Modelos de fundación

AlphaFold resuelve el plegamiento de proteínas (2020). ChatGPT cambia la conversación pública (2022). Aparecen modelos de fundación para tareas científicas: Chronos y TimesFM para series temporales, TabPFN para datos tabulares. Por primera vez un modelo preentrenado supera a XGBoost sin ajuste alguno.

George Box, 1976

La frase más famosa de la historia del modelado

All models are wrong, but some are useful.

— George E. P. Box (1919-2013)

El contexto que pocos conocen

Box no era nihilista. En su libro de 1987 con Draper escribió la versión completa: "Remember that all models are wrong; the practical question is how wrong do they have to be to not be useful". Toda aproximación es imperfecta; la pregunta científica útil no es si el modelo es verdadero, sino si es lo suficientemente bueno para la decisión que se va a tomar.

"Since all models are wrong the scientist cannot obtain a 'correct' one by excessive elaboration."

— Box (1976)

"Statisticians, like artists, have the bad habit of falling in love with their models."

— Box (1976)

Tipos de modelos matemáticos

Cuatro formas útiles de clasificarlos

Por origen

Mecanísticos (basados en leyes físicas o biológicas), **fenomenológicos** (basados en observaciones), **estadísticos** (basados en datos) e **híbridos** (combinan los anteriores).

Por naturaleza

Determinísticos: la misma entrada produce siempre la misma salida. **Estocásticos**: incorporan azar y producen distribuciones de probabilidad sobre los resultados.

Por tiempo

Estáticos: una foto del sistema. **Dinámicos**: describen la evolución temporal, en tiempo continuo (EDO) o discreto (cadenas de Markov, series temporales).

Por propósito

Descriptivos (resumir), **explicativos** (entender causas), **predictivos** (anticipar), **prescriptivos** (recomendar acciones) y **generativos** (crear nuevos datos).

Un mismo problema admite varios tipos de modelo. La elección no es objetiva: depende de los datos disponibles, de la pregunta y de las consecuencias de equivocarse.

Validación y calibración

Cómo saber si el modelo sirve antes de creerle

Validación

Comprobar que el modelo cumple su propósito en datos que no se usaron para construirlo. Técnicas que veremos:

- Hold-out: separar entrenamiento y prueba
- Validación cruzada k-fold
- Validación cruzada para series temporales
- Validación externa con poblaciones distintas

Calibración

Un modelo está calibrado si, cuando dice 70 % de probabilidad, efectivamente acierta el 70 % de las veces. Métodos clave:

- Platt scaling (sigmoide logística)
- Regresión isotónica (no paramétrica)
- Temperature scaling (estándar en redes neuronales)
- Diagramas de confiabilidad y ECE

Un modelo puede ser muy preciso y muy mal calibrado al mismo tiempo. Es típico en redes neuronales modernas: aciertan mucho, pero cuando dicen 99 % de seguridad en realidad están al 85 %. En medicina o finanzas las consecuencias son enormes.

Tres propiedades que todo modelo debe tener

Identificabilidad, sensibilidad y parsimonia

Identificabilidad

¿Pueden recuperarse los parámetros del modelo a partir de los datos disponibles? Si dos combinaciones distintas de parámetros producen exactamente el mismo ajuste, el modelo no es identificable. Es un problema invisible que arruina silenciosamente muchos análisis.

Sensibilidad

¿Cómo cambia el resultado si perturbamos los inputs o los parámetros? El análisis local (derivadas parciales) y el global (índices de Sobol, screening de Morris) nos dicen qué parámetros importan de verdad. Si una política pública depende de un parámetro con altísima sensibilidad, vale la pena invertir en medirlo mejor.

Parsimonia (la navaja de Occam)

A igualdad de poder explicativo, prefíerese el modelo más simple. Se formaliza con criterios como AIC y BIC, y con técnicas de regularización como Ridge, Lasso y Elastic Net (semana 5). Box lo decía así: la sobreelaboración y la sobreparametrización son la marca de la mediocridad.

Éxitos y fracasos célebres

Modelos que cambiaron el mundo, para bien y para mal

Éxitos

- **SIR durante COVID-19:** la modelación apoyó la vacunación que, según The Lancet, evitó 14.4 millones de muertes en el primer año.
- **Black-Scholes (1973):** ecuación para precios de opciones. Nobel de Economía 1997. Base de un mercado de cientos de billones de dólares.
- **Pronóstico meteorológico numérico:** hoy a 10 días es tan bueno como a 3 días en 1980.
- **AlphaFold 2 (2020):** predijo más de 200 millones de estructuras de proteínas.
- **GPS:** sin correcciones relativistas acumularía 10 km de error por día.

Fracasos

- **LTCM (1998):** dos Nobel en el equipo y modelos que asumían normalidad; perdieron 4.6 mil millones de dólares en meses y la Fed organizó el rescate.
- **Crisis subprime (2008):** las cópulas gaussianas subestimaron la correlación de impagos; daño global estimado en 15 billones de dólares según el FMI.
- **Google Flu Trends:** funcionó años y luego falló en más del 50 %.
- **Zillow Offers (2021):** los modelos de precios fallaron tras la pandemia; pérdidas superiores a 500 millones.

La diferencia entre éxitos y fracasos no es la sofisticación matemática, es la humildad: entender los supuestos, validar fuera de la muestra, monitorear el drift y nunca creerle al modelo más allá de lo que los datos justifican.

Pipeline moderno del modelado

Del problema a la decisión, no del problema al notebook

1. Definir el problema

convertir una pregunta de negocio en una cuantitativa

2. Recolectar y curar datos

fuentes, ETL, gobernanza, calidad

3. Explorar (EDA)

distribuciones, faltantes, outliers, drift

4. Formular el modelo

mecanístico, estadístico, ML o híbrido; supuestos explícitos

5. Implementar y entrenar

optimización, control de versiones

6. Validar

validación cruzada, calibración, equidad

7. Desplegar

contenedores, API, batch o streaming

8. Monitorear

drift de datos y de concepto, métricas de negocio

9. Comunicar

dashboards, intervalos, escenarios para stakeholders

10. Iterar

la v1 entra rápido; las siguientes mejoran con feedback real

El modelado no termina cuando se publica un número. Termina cuando una decisión se toma, se ejecuta y produce un resultado medible en el mundo real.

Frameworks contemporáneos

CRISP-DM, OSEMN, TDSP y MLOps

CRISP-DM (1999)

Cross-Industry Standard Process for Data Mining. Seis fases iterativas: comprensión del negocio, comprensión de los datos, preparación, modelado, evaluación y despliegue. Sigue siendo el framework más usado en proyectos rigurosos.

OSEMN

Obtain, Scrub, Explore, Model, iNterpret. Más operativo, estilo Unix. Ideal para análisis exploratorios y proyectos de corta duración.

TDSP (Microsoft, 2016)

Team Data Science Process. Agrega gestión de proyectos, plantillas de Git y roles definidos (arquitecto de solución, científico de datos, líder de proyecto). Más alineado con equipos ágiles.

MLOps

DevOps aplicado a machine learning. Versionado de datos y modelos, pipelines automatizados, monitoreo en producción, feature stores. Lo que diferencia un notebook de un sistema real.

El código de producción es típicamente 10 a 100 veces más extenso que el código del modelo (Sculley et al., 2015, "Hidden Technical Debt"). Construir el modelo es la parte fácil.

Modelado matemático en Costa Rica I

El CIMPA-UCR y el modelo de COVID-19 que llegó a Nature

El equipo costarricense que sorprendió al mundo

Durante la pandemia, el Centro de Investigación en Matemática Pura y Aplicada (CIMPA) de la UCR, junto con la Escuela de Matemática, desarrolló un modelo de redes multicapa con cinco millones de nodos, uno por habitante del país. Distingue cuatro tipos de relaciones (familia, trabajo, amigos, esporádicas), cada una con tasas de transmisión propias. Fue publicado en Scientific Reports, del grupo Nature, en febrero de 2022.

Dr. Fabio Sánchez

Coordinador. PhD en matemática biológica (Cornell). Lidera la modelación de enfermedades transmisibles en el CIMPA.

Dr. Juan Gabriel Calvo

Matemática aplicada y EDP. Desarrolla modelos SIR con estructura de edad y métodos numéricos para epidemiología.

Dr. Luis Barboza

Estadística bayesiana y Approximate Bayesian Computation. Calibra los modelos a datos reales del Ministerio de Salud.

Las proyecciones del modelo alimentaron decisiones de política pública del Ministerio de Salud. El equipo también publicó modelos para zika (2016-2017) y dengue con técnicas de ML y variables climáticas.

Modelado matemático en Costa Rica II

Más allá de la academia: el modelado en las instituciones nacionales

POLÍTICA MONETARIA

Banco Central de Costa Rica

Opera el MMPE (Macroeconómico de Pequeña Escala) y el MMPT (Proyección Trimestral). Alimentan el Informe de Política Monetaria y la decisión sobre la Tasa de Política Monetaria.

ENERGÍA

ICE

Modelos hidrológicos y de demanda eléctrica para planificar la generación. Costa Rica depende en más del 70 % de la hidroeléctrica: un error del 5 % en el pronóstico representa millones de dólares en el MER.

METEOROLOGÍA

IMN

Modelos numéricos de pronóstico (WRF) y análisis de fenómenos como El Niño y La Niña. Críticos para zonas vulnerables como Limón y el Pacífico Norte.

TURISMO

ICT

Modelos de demanda turística pospandemia, segmentación por país de origen y capacidad de carga de áreas protegidas. Uno de los carriles sugeridos del proyecto.

También: AyA con detección de fugas, INEC con modelos demográficos, CENAT con imágenes satelitales y todos los bancos (BAC, BCR, BN) con modelos de scoring crediticio.

Modelado matemático en Latinoamérica

Centros de excelencia y casos regionales

IMPA (Brasil)

Instituto de Matemática Pura e Aplicada, en Río de Janeiro. Uno de los centros matemáticos más prestigiosos del mundo. Artur Avila ganó la Medalla Fields en 2014 como investigador del IMPA.

CIMAT (México)

Centro de Investigación en Matemáticas, en Guanajuato. Aplicaciones en estadística, optimización, finanzas y matemática industrial. Trabajos relevantes con el Banco de México.

CMM (Chile)

Centro de Modelamiento Matemático de la Universidad de Chile. Pionero en aplicaciones a minería, energía y modelos epidemiológicos. Codelco usa modelos del CMM para optimización minera.

EMBRAPA y la agricultura de precisión

Brasil lidera la región en modelos agroclimáticos para soja, maíz y caña. Empresas como Solinftec (Brasil) y Auravant (Argentina) combinan teledetección con ML para optimizar cosechas.

El modelado matemático no es algo lejano ni exclusivo de Stanford o el MIT. Se hace activamente, con excelencia y publicaciones de impacto, en toda la región y en Costa Rica.

Tendencias punteras 2025-2026

Lo que está cambiando el modelado en este preciso momento

Modelos de fundación para series temporales

Chronos-2 (Amazon), TimesFM (Google) y Moirai (Salesforce) están reemplazando a ARIMA y Prophet en muchas pipelines industriales. Predicen sin entrenamiento previo (zero-shot). Los veremos en la semana 7.

TabPFN para datos tabulares

Publicado en Nature en enero de 2025. La versión 2.5 gana en todos los datasets pequeños contra XGBoost y es miles de veces más rápida. Cambia el juego para la mayoría de aplicaciones empresariales.

Physics-Informed Neural Networks

Redes neuronales que aprenden respetando ecuaciones diferenciales conocidas. En 2025, SeisPINN localiza epicentros de terremotos en 5 segundos con 0.5 km de error.

Programación diferenciable y renacimiento bayesiano

JAX y PyTorch permiten optimizar simuladores físicos completos. PyMC y NumPyro corren ahora en GPU, haciendo viable la inferencia bayesiana en datasets grandes.

Y además: ética y gobernanza de modelos. El EU AI Act entró en vigor en 2024 y la Estrategia Nacional de IA del MICITT define el marco costarricense. Todo modelo en producción necesita model card y datasheet.

Google Colab: nuestro laboratorio del curso

Plataforma principal de esta semana y de las siguientes

¿Por qué Colab?

Notebook en la nube basado en Jupyter, sin instalación y con casi todas las librerías que vamos a usar preinstaladas (NumPy, SciPy, scikit-learn, PyMC, NetworkX, PyTorch, JAX). Funciona en cualquier dispositivo con navegador y cuenta de Google. Incluye el asistente Gemini y el Data Science Agent, que genera notebooks a partir de instrucciones en lenguaje natural.

3.12

Python preinstalado

16 GB

VRAM en GPU T4 gratuita

Gemini

Asistente de IA integrado

Atajos esenciales

Shift + Enter: ejecutar y avanzar · Ctrl + Enter: ejecutar sin avanzar

Ctrl + M, B: nueva celda abajo · Ctrl + M, M: convertir a Markdown

Más adelante en el curso

Para series temporales con fpp3 usaremos Posit Cloud (R) en la semana 6. Para optimización moderna con PyTorch y JAX activaremos la GPU T4 en la semana 11.

Demo en vivo: crecimiento poblacional de Costa Rica

Dos modelos, una pregunta: ¿cuál es más útil?

```
import numpy as np, pandas as pd
from scipy.optimize import curve_fit
from sklearn.linear_model import LinearRegression

# Población de Costa Rica en millones (Banco Mundial, INEC)
data = pd.DataFrame({
    "anio": [1960, 1970, 1980, 1990, 2000, 2010, 2020, 2023],
    "poblacion_M": [1.33, 1.82, 2.35, 3.08, 3.93, 4.66, 5.12, 5.21]})

# Modelo 1: regresión lineal (ingenuo)
lin = LinearRegression().fit(data[["anio"]], data["poblacion_M"])

# Modelo 2: crecimiento logístico (Verhulst, 1838)
def logistic(t, K, r, t0):
    return K / (1 + np.exp(-r * (t - t0)))

popt, _ = curve_fit(logistic, data["anio"], data["poblacion_M"],
                    p0=[6.0, 0.04, 1990], maxfev=10000)
K, r, t0 = popt
print(f"Capacidad de carga estimada K = {K:.2f} millones")
```

Preguntas para la clase

- ¿Cuál modelo predice mejor el 2050?
- ¿Cuál es más útil para el ICE al planificar la demanda eléctrica?
- ¿Qué supuestos hace cada uno?
- ¿Pueden extrapolar al 2100 con seguridad?

Qué observar

- El modelo lineal crece sin límite: ignora la saturación.
- El logístico estima una capacidad de carga K y se aplan.
- Con ocho datos, ambos ajustan bien. La diferencia aparece al extrapolar.

El sílabo en resumen

Cronograma, evaluación, proyecto integrador, presentaciones grupales, políticas y bibliografía.
El documento completo está en Moodle.

Mapa del curso: 15 semanas

Doce temas, dos pruebas grupales, tres sesiones de presentaciones y un proyecto integrador

Sem.	Fecha	Tema de la sesión	Hitos evaluativos
1	10 set.	Fundamentos del modelado matemático; entorno Colab y GitHub	Formación de grupos y asignación de temas
2	17 set.	Modelos con ecuaciones diferenciales (SIR, SEIR, scipy.integrate)	
3	24 set.	Cadenas de Markov, PageRank y redes con NetworkX	Selección del tema del proyecto
4	1 oct.	Simulación de Monte Carlo, MCMC e inferencia bayesiana con PyMC	
5	8 oct.	Regresión clásica, regularizada y bayesiana	
6	15 oct.	Series temporales clásicas: ETS, ARIMA y SARIMA (statsmodels, fpp3)	
7	22 oct.	Series temporales modernas: Prophet, NeuralProphet, Chronos	Presentaciones grupales 1 · Se asigna la prueba parcial
8	29 oct.	Repaso integrador de los temas 1 a 7	Entrega de la prueba parcial (20 %) · Avance del proyecto (15 %)
9	5 nov.	Optimización clásica: optimalidad, gradiente, cvxpy	
10	12 nov.	Optimización con restricciones: Lagrange, KKT, sensibilidad	
11	19 nov.	Optimización moderna: autodiff, SGD, Adam y AdamW (PyTorch, JAX)	Presentaciones grupales 2
12	26 nov.	Métodos heurísticos y derivative-free; inicio de teoría de grafos	
13	3 dic.	Teoría de grafos: algoritmos, network science, embeddings	Presentaciones grupales 3 · Se asigna la prueba final
14	10 dic.	Teoría de la decisión y aprendizaje secuencial: bandits, MDP, Bellman	Entrega de la prueba final (20 %)
15	17 dic.	Cierre del curso y síntesis	Entrega final (25 %) y presentación del proyecto (10 %)

Sistema de evaluación

Cómo se compone la nota final (artículo 15 del Reglamento Académico)

20 %

Prueba parcial (grupal, extraclase,
semanas 7 a 8)

20 %

Prueba final (grupal, extraclase,
semanas 13 a 14)

50 %

Proyecto integrador: avance 15 % +
entrega 25 % + presentación 10 %

10 %

Presentación grupal de tema
complementario (semanas 7, 11 o
13)

Todo se evalúa en grupo

Los grupos de 3 o 4 personas se forman hoy y se mantienen todo el cuatrimestre. Son la unidad de trabajo para los cuatro rubros, incluidas las pruebas. Todos los miembros reciben la misma nota, salvo casos demostrados de falta de participación.

Las pruebas no son en clase

La prueba parcial y la final se asignan al final de una sesión y se entregan antes de la siguiente: siete días naturales de trabajo extraclase, una única entrega por grupo, sin IA generativa ni colaboración entre grupos.

No se aceptan entregas tardías de ningún componente evaluativo. Ante una emergencia justificada, comuníquense con el profesor antes de la fecha de entrega, no después.

Pruebas parcial y final

Grupales, extraclase y con procedimiento a mano

Prueba parcial (20 %)

- Se asigna al final de la semana 7 (22 de octubre) y se entrega antes de la semana 8 (29 de octubre).
- Cubre los temas 1 a 6: fundamentos, EDO, Markov, Monte Carlo y MCMC, regresión y series temporales.

Prueba final (20 %)

- Se asigna al final de la semana 13 (3 de diciembre) y se entrega antes de la semana 14 (10 de diciembre).
- Cubre los temas 7 a 12: optimización clásica, moderna y heurística, grafos, decisión y aprendizaje secuencial.

Formato y reglas comunes

- 60 % ejercicios matemáticos resueltos a mano, con procedimiento completo, digitalizados o escaneados; 40 % preguntas conceptuales y análisis de fragmentos de código y resultados.
- Una única entrega por grupo y la misma calificación para todos sus integrantes.
- No se permite inteligencia artificial generativa ni colaboración entre grupos. Sin reposición, salvo fuerza mayor debidamente justificada según el Reglamento Académico.

Proyecto integrador (50 %)

Un problema real del contexto costarricense resuelto con al menos dos métodos del curso

15 %

Avance • semana 8

- Documento de 6 a 8 páginas más notebook reproducible.
- Planteamiento, justificación para Costa Rica, objetivos, dataset con tabla de variables.
- Formulación matemática inicial, supuestos y métricas de éxito.
- Primer modelo aplicado y EDA con al menos tres visualizaciones. Cinco referencias APA 7.

25 %

Entrega final • semana 15

- Artículo corto de 12 a 16 páginas y repositorio público en GitHub (README, estructura estándar, licencia).
- Marco teórico riguroso y al menos dos modelos distintos comparados con validación cruzada.
- Análisis de sensibilidad, limitaciones, ética y gobernanza de datos. Diez referencias APA 7.

10 %

Presentación • semana 15

- 12 minutos más 5 de preguntas, con participación equitativa de todos.
- Problema (2), formulación y datos (2), metodología (3), resultados (3), conclusiones (2).
- Diapositivas profesionales y dominio del tema; puede haber defensa oral breve.

La metodología es la del modelado matemático clásico

Identificación del problema, elección y formalización del modelo, implementación, validación y comparación de resultados. Datos reales (o simulados de forma realista), un tema distinto por grupo y, en la semana 3, cada grupo confirma su tema. Cualquier fraude o plagio anula el trabajo.

Carriles temáticos sugeridos para el proyecto

Cada grupo elige un tema diferente; no se repiten entre grupos

01

Predicción de demanda eléctrica residencial con datos del ICE o la CNFL

02

Modelo SEIR calibrado a datos de dengue del Ministerio de Salud

03

Optimización de rutas de transporte público en el GAM con teoría de grafos

04

Credit scoring con datos sintéticos basados en la SUGEF

05

Predicción de pobreza por hogar con datos del INEC

06

Red de coautoría científica costarricense (Scopus o SciELO)

07

Optimización de cartera de inversión con datos del BCCR y la BNV

08

Detección de anomalías en el consumo de agua del AyA

09

Llegadas de turistas a Costa Rica (ICT) con modelos de fundación

10

Propagación de información en redes sociales costarricenses

11

Optimización de inventario en una cadena de retail simulada

12

Tipo de cambio colón-dólar con datos históricos del BCCR

También se aceptan propuestas propias con datos reales y al menos dos métodos del curso, previa aprobación del profesor.

Presentación grupal de tema complementario (10 %)

Un tópico moderno que no se cubre en detalle en las sesiones magistrales

Reglas

- Se realiza en vivo en las semanas 7, 11 o 13, con dos presentaciones por sesión. Sin entregables escritos posteriores.
- 15 a 20 minutos de presentación más 5 de preguntas.
- Todos los miembros participan equitativamente; la ausencia injustificada de uno afecta la nota grupal.
- Los temas se asignan hoy y no se repiten entre grupos.

Contenido esperado

- Definición y motivación del tema.
- Fundamento matemático mínimo necesario.
- Aplicaciones prácticas y casos de uso.
- Demostración con código en Python o R.
- Ventajas, desventajas y limitaciones. Mínimo cuatro referencias.

Cómo se califica

Con la rúbrica del sílabo: dominio conceptual y matemático del tema, calidad de la demostración con código, claridad de las diapositivas, manejo del tiempo, participación equitativa y capacidad de responder preguntas. La rúbrica completa está en la sección IX del sílabo.

Temas disponibles para la presentación grupal

Se asignan hoy, por grupo. Cada tema se conecta con una semana del curso

- | | | | | | |
|----|--|-----------|----|---|-----------|
| 01 | Modelos epidemiológicos compartimentales (SIR, SEIR) y su calibración con datos reales | Semana 2 | 02 | Inferencia bayesiana aplicada con PyMC: del prior al posterior | Semana 4 |
| 03 | Diferenciación automática y comparación de optimizadores (SGD, Adam, AdamW) | Semana 11 | 04 | Modelos de fundación para series temporales: Chronos, TimesFM y Moirai | Semana 7 |
| 05 | Redes neuronales sobre grafos (GNN): de message passing a aplicaciones | Semana 13 | 06 | Multi-armed bandits aplicados a A/B testing y sistemas de recomendación | Semana 14 |
| 07 | Optimización bayesiana e hiperparámetros con procesos gaussianos | Semana 12 | 08 | CMA-ES y métodos derivative-free modernos para optimización de caja negra | Semana 12 |
| 09 | Modelos de lenguaje grandes y cadenas de Markov; nociones de RLHF y DPO | Semana 3 | 10 | Redes neuronales informadas por física (PINN): cuándo y por qué | Semana 2 |

Políticas del curso

Lo que necesitan saber para no tener sorpresas

Asistencia

La asistencia es obligatoria. El curso se pierde con tres ausencias injustificadas consecutivas o cuatro alternas durante el cuatrimestre.

Entregas tardías

No se aceptan entregas tardías de ningún componente evaluativo. Ante emergencias médicas o desastres naturales, comuníquense lo antes posible para evaluar opciones.

Comunicación

El medio oficial es el correo institucional; respuesta en un máximo de 48 horas hábiles. Las consultas urgentes o técnicas se atienden en sesiones virtuales previa coordinación.

Integridad académica e inteligencia artificial

- La IA generativa puede apoyar la búsqueda y el contraste de ideas, nunca sustituir el proceso de aprendizaje. Rige el Protocolo sobre el uso de la IA de Lead University (Campus Virtual, sección Soy ULEAD).
- Deben poder explicar oralmente cualquier solución entregada, incluido el código generado con asistencia de IA.
- Copiar, no citar o colaborar entre grupos en las pruebas anula el trabajo y se reporta según el Reglamento Estudiantil.

Trabajo en grupos

- Grupos de 3 o 4 integrantes formados en la primera semana; se mantienen todo el cuatrimestre.
- Son la unidad de trabajo para todos los rubros, incluidas las pruebas.
- Los conflictos se resuelven primero dentro del grupo; si persisten, el profesor media.
- Misma nota para todos, salvo falta de participación demostrada.

Bibliografía y recursos

Un texto base y una biblioteca gratuita y legal para todo el curso

LIBRO DEL CURSO

Texto base oficial

Giordano, Fox y Horton. A First Course in Mathematical Modeling, 5.^a ed., Cengage, 2014.

HERRAMIENTAS

Plataformas

Google Colab (Python), Posit Cloud (R con fpp3), GitHub (proyecto) y Moodle (notebooks y materiales semanales).

Textos complementarios gratuitos en línea

- **Brunton y Kutz**, Data-Driven Science and Engineering, 2.^a ed. (databookuw.com): puente entre modelado clásico y ML moderno.
- **Murphy**, Probabilistic Machine Learning: An Introduction (probml.github.io/pml-book): regresión, optimización, MCMC.
- **Hyndman y Athanasopoulos**, Forecasting: Principles and Practice, 3.^a ed. (otexts.com/fpp3): series temporales en R.
- **Barabási**, Network Science (networksciencebook.com): texto base de ciencia de redes.
- **Kochenderfer, Wheeler y Wray**, Algorithms for Decision Making (algorithmsbook.com): decisión, MDP, bandits y RL.
- **Boyd y Vandenberghe**, Convex Optimization (stanford.edu/~boyd/cvxbook): el canon de optimización convexa.
- **Documentación** de PyMC, cvxpy, NetworkX, Chronos y el artículo de Distill sobre GNN.

Para la próxima semana

Tareas concretas y preparación

Configuración técnica obligatoria

- Cuenta de Google para acceder a Colab.
- Cuenta de GitHub con el correo institucional y aceptar la invitación al GitHub Classroom del curso.
- Abrir el notebook de bienvenida en Colab y guardar una copia en su GitHub personal.
- Confirmar el grupo definitivo (3 o 4 personas) y el tema asignado para la presentación grupal.

Preparación para la semana 2: ecuaciones diferenciales

- Repasar derivadas y ecuaciones diferenciales ordinarias del curso de cálculo.
- Leer el capítulo introductorio de Giordano, Fox y Horton y el de Brunton y Kutz (databookuw.com).
- Opcional: la serie de 3Blue1Brown sobre ecuaciones diferenciales en YouTube.
- Ir pensando en un carril del proyecto: se confirma en la semana 3.

El próximo jueves empezamos a modelar con ecuaciones diferenciales: dinámicas poblacionales, modelos SIR de epidemiología y calibración a datos reales del Ministerio de Salud de Costa Rica.

Dudas: jordy.alfaro@ulead.ac.cr

Lo que se llevan de esta primera sesión

Un modelo no copia la realidad, la simplifica con criterio

El mapa no es el territorio. Un buen modelo responde con utilidad a una pregunta concreta. Box tenía razón: todos los modelos son incorrectos, pero algunos son útiles.

El modelado ya decide por todos nosotros

Del filtro del correo a la tasa de política monetaria, de Waze al ICE. El profesional de datos no es quien usa modelos, sino quien los entiende, los critica y sabe cuándo confiar en ellos.

Esto se hace en Costa Rica y se hace bien

El CIMPA-UCR llegó a Nature, el BCCR opera modelos macroeconómicos y el ICE planifica la generación eléctrica con modelos que ustedes podrán construir al final de este curso.

Bienvenidos al curso. Nos vemos el próximo jueves con ecuaciones diferenciales.