

Modelos con ecuaciones diferenciales

Semana 2: de la regla de cambio a la simulación numérica

BCD5105 • Modelado matemático

Profesor: Jordy Alfaro Brenes

Lead University • III cuatrimestre 2026 • Modalidad virtual

Jueves 17 de setiembre de 2026 • 4:00 a 7:00 p. m.

Ruta de la sesión

Dos mitades: primero a mano, después en Python

Al terminar la sesión usted podrá

- Leer una ecuación diferencial como una regla de cambio y decir qué modela.
- Explicar por qué Malthus crece sin límite y Verhulst se frena, y cuándo sirve cada uno.
- Encontrar los equilibrios de un modelo y decidir si son estables mirando un diagrama de fase.
- Leer el sistema SIR, interpretar R_0 y saber si una epidemia crece o se apaga.
- Resolver cualquiera de estos modelos con `scipy.integrate` y calibrarlo a datos reales.

Bloques y tiempos estimados

1	Qué es una EDO y cómo leerla	15 min
2	Malthus y Verhulst: dos modelos de población	25 min
3	Equilibrios y estabilidad	15 min
4	Sistemas de EDO: el modelo SIR y R_0	20 min
5	Caso real: la tesis del vapeo	15 min
	<i>Receso</i>	10 min
6	<code>scipy.integrate</code> , demos y calibración	50 min
7	Actividad en salas y cierre	30 min

Parte 1

Modelos con EDO, a mano

Trabajo conceptual en la pizarra: cómo se lee una ecuación diferencial, qué modela y qué nos dice sin resolverla. Ejemplos en clase y ejercicios de tarea moral.

Una ecuación diferencial es una regla de cambio

No dice cuánto vale y ; dice cómo cambia y

$$dy/dt = f(t, y)$$

t es la variable independiente (casi siempre el tiempo). $y(t)$ es la variable dependiente: lo que queremos entender. dy/dt es la rapidez con la que cambia.

y'

Ejemplo: la población de Costa Rica

Si $y(t)$ es la población del país en el año t , entonces dy/dt es la tasa de crecimiento de la población en ese año: cuántas personas se suman (o restan) por unidad de tiempo. La ecuación diferencial es la hipótesis sobre de qué depende ese crecimiento.

Qué es resolver una EDO

Encontrar la función $y(t)$ que cumple la regla en todo momento, partiendo de un valor conocido $y(0) = y_0$ (la condición inicial). Cambiar la condición inicial cambia la solución, aunque la regla sea la misma.

Modelar con EDO es traducir una frase del tipo "el cambio de algo depende de..." a una ecuación. La mayor parte del trabajo es la traducción, no la integral.

Cómo clasificar una EDO

Tres etiquetas que anticipan cómo se comporta y cómo se resuelve

Orden

La derivada más alta que aparece.

$y'' + y = 0$ es de orden 2

Un modelo de orden n necesita n condiciones iniciales.

Lineal

y y sus derivadas aparecen a la primera potencia y sin multiplicarse entre sí.

$y' + 3y = t$ es lineal

Las lineales casi siempre tienen solución cerrada.

Autónoma

t no aparece explícitamente: la regla es la misma en todo momento.

$y' = y(1 - y)$ es autónoma

Permite dibujar un diagrama de fase.

Ecuación	Orden	¿Lineal?	¿Autónoma?	Qué modela
$y'' + y = 0$	2	Sí	Sí	Un resorte o un péndulo pequeño: oscila
$y' + 3y = t$	1	Sí	No	Algo que decae pero recibe un empuje que crece con el tiempo
$y' = y(1 - y)$	1	No	Sí	Crecimiento logístico: la base de Verhulst

Ejemplos

Qué es una EDO

Resolvemos juntos en la pizarra

Ejemplo 1

Clasifique por orden, linealidad y autonomía:

a) $dT/dt = -k(T - 20)$

b) $y'' + 2y' + y = \sin(t)$

c) $dN/dt = rN(1 - N/K)$

d) $y' = t \cdot y$

Orden 2
Lineal
No autónoma

Ejemplo 2

Traduzca cada frase a una ecuación diferencial (no la resuelva):

a) "Un depósito crece al 5 % anual continuo."

b) "Una taza de café se enfría a una rapidez proporcional a la diferencia con la temperatura del cuarto."

c) "Un rumor se propaga a una rapidez proporcional a quienes lo saben y a quienes no."

Espacio de trabajo

Qué es una EDO

Ejemplo 1

$$1a) \frac{dT}{dt} = -K(T-20)$$

$$\Rightarrow T' = -K(T-20)$$

→ Orden 1

→ Lineal

→ Es autónoma

Ejemplo 2

Ejercicios

Qué es una EDO

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Clasifique:

- a) $y' = 3y - 2$
- b) $y'' = -9.8$
- c) $dP/dt = 0.02P - 0.0001P^2$
- d) $y' + y/t = 1$

Ejercicio 2

Escriba la EDO que modela:

- a) La cantidad de un medicamento en sangre, que se elimina a un 10 % por hora.
- b) La adopción de Sinpe Móvil, proporcional a los usuarios actuales y a los que aún no lo usan.

Ejercicio 3

La ecuación $y' = 2$ tiene infinitas soluciones $y = 2t + C$.

- a) ¿Qué información falta para elegir una sola?
- b) ¿Por qué un modelo de orden 2 necesita dos datos iniciales? Piense en un objeto que cae.

tasa de crecimiento

Malthus (1798): crecer en proporción a lo que ya hay

La técnica de separación de variables, en tres pasos

$$\frac{dN}{dt} = r \cdot N$$

$$N(0) = N_0$$

$$N(t) = N_0 \cdot e^{rt}$$

Cómo se llega a la solución

- Separar: todo lo que tenga N a un lado, todo lo que tenga t al otro: $dN/N = r \cdot dt$.
- Integrar ambos lados: $\ln|N| = r \cdot t + C$.
- Despejar N y usar $N(0) = N_0$ para fijar la constante.

Lo que importa conceptualmente

- r es la tasa de crecimiento per cápita: cuánto crece cada individuo por unidad de tiempo.
- La solución es exponencial: el tiempo de duplicación es $\ln 2 / r$ y no depende de N_0 .
- No hay freno. El modelo asume recursos infinitos.

Malthus es lineal y autónomo. Su gran virtud es que se resuelve a mano; **su gran defecto es que nada en el mundo crece exponencialmente para siempre.**

Malthus con datos de Costa Rica

Dos censos bastan para estimar r ; el tercero pone a prueba el modelo

120 000

Habitantes en 1864 (censo)

800 000

Habitantes en 1950 (censo)

$r \approx 0.022$

De 800 000 = 120 000 · $e^{(86r)}$: un
2.2 % anual

4.14 M

Predicción para 2025: 120 000 ·
 $e^{(0.022 \cdot 161)}$

El paso a paso

- Tomamos 1864 como $t = 0$, así $N_0 = 120\,000$.
- En 1950, $t = 86$: despejamos r del cociente $800\,000 / 120\,000 = e^{(86r)}$.
- Para 2025, $t = 161$: evaluamos la solución.

Realidad en 2025: 5.19 millones

El modelo se queda corto en un millón de personas. Con solo dos datos, r mezcla épocas muy distintas: alta mortalidad en el siglo XIX, transición demográfica en el XX, migración en el XXI. La tasa no fue constante.

El error no invalida el modelo: lo ubica. Malthus funciona bien en ventanas cortas y poblaciones lejos de su límite. Para ventanas largas necesitamos un freno.

Verhulst (1838): crecer hasta que el ambiente no da más

El modelo logístico y la capacidad de carga

$$dN/dt = r \cdot N \cdot (1 - N/K)$$

$$N(t) = K / (1 + ((K - N_0)/N_0) \cdot e^{(-rt)})$$

K: capacidad de carga

El tamaño máximo que el ambiente puede sostener. Es el nuevo parámetro y el que le da al modelo su forma de S.

El factor $(1 - N/K)$

Vale casi 1 cuando N es pequeño (Malthus puro) y se acerca a 0 cuando N se acerca a K: el crecimiento se frena solo.


¿Cuándo crece más rápido?

Cuando $N = K/2$. Antes de ese punto la curva acelera; después, desacelera. Es el punto de inflexión de la S.

La solución cerrada existe (fracciones parciales), pero lo que usaremos es la lectura: mismo r que Malthus al inicio, saturación en K al final. En Colab la ajustaremos a los censos del INEC.

Los dos modelos frente a los censos

Lo que a mano solo podíamos intuir



Qué muestra

Los puntos son los nueve censos del INEC; la estrella, la estimación de 2025. Malthus pasa por dos puntos y se dispara; Verhulst usa los nueve y se dobla hacia K.

Para pensar

La K ajustada ronda los 7 millones, pero el CCP-INEC proyecta 5.7 millones en 2050 y luego un descenso. ¿Qué le falta a Verhulst para capturar eso?

Ejemplos

Malthus y Verhulst

Resolvemos juntos en la pizarra

Ejemplo 1

Con $r = 0.022$ anual:

- a) ¿Cada cuántos años se duplica la población según Malthus?
- b) ¿Qué predice para 2050 partiendo de 5.19 millones en 2025?
- c) ¿Le cree al resultado? ¿Por qué?

Ejemplo 2


Suponga $K = 6.5$ millones para Costa Rica.

- a) ¿Qué signo tiene dN/dt hoy, con $N = 5.19$ millones? ¿Y si N fuera 7 millones?
- b) ¿En qué valor de N creció más rápido el país? ¿Ya pasó ese momento?
- c) Dibuje a mano la S de Verhulst y ubique 1864, 1950 y 2025.


Espacio de trabajo

Malthus y Verhulst

Ejemplo 1



Ejemplo 2



Ejercicios

Malthus y Verhulst

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Use los censos de 1950 (800 000) y 2022 (5 044 197) para estimar r con Malthus.

- a) Compare con el $r \approx 0.022$ de la clase.
- b) Explique por qué difieren si el modelo es el mismo.

Ejercicio 2

Una bacteria en un frasco duplica su población cada hora y el frasco está lleno a la medianoche.

- a) ¿A qué hora estaba a la mitad? ¿Y a un cuarto?
- b) ¿Qué modelo describe esto, Malthus o Verhulst? ¿Y después de la medianoche?

Ejercicio 3

Describe en una frase, sin fórmulas, un fenómeno de su trabajo o entorno que:

- a) siga a Malthus en el corto plazo;
- b) siga a Verhulst;
- c) no siga a ninguno de los dos. ¿Qué le falta al modelo?

Equilibrios y estabilidad

Sin resolver la ecuación, ya sabemos hacia dónde va


Equilibrio

Un valor N^* donde $dN/dt = 0$: si la población llega ahí, se queda.
En Malthus el único equilibrio es $N^* = 0$. En Verhulst hay dos:
 $N^* = 0$ y $N^* = K$.

Estabilidad

Un equilibrio es estable si, al perturbarlo un poco, la solución regresa; inestable si se aleja. El signo de $f(N)$ a cada lado del equilibrio lo decide: positivo empuja hacia la derecha, negativo hacia la izquierda.

Diagrama de fase de Verhulst: $f(N) = rN(1 - N/K)$ sobre la recta N



Inestable: cualquier población positiva se aleja de 0. Estable: todas las flechas apuntan a K , sin importar de dónde se parta.

Ejemplos

Equilibrios y estabilidad

Ejemplo 1

Para $y' = y(1 - y)$:

- Encuentre los equilibrios.
- Dibuje el diagrama de fase con las flechas.
- ¿Qué pasa a largo plazo si $y(0) = 0.1$? ¿Si $y(0) = 0.5$?
¿Si $y(0) = 1.5$?

$$y' = y(1 - y)$$

Equilibrios:

$$y' = 0$$

$$y(1 - y) = 0$$

$$y = 0 \vee y = 1$$

Ejemplo 2

Ley de enfriamiento de Newton, $dT/dt = -k(T - 20)$, con $k > 0$:

- ¿Cuál es el equilibrio y qué significa físicamente?
- ¿Es estable? Argumente con el signo de dT/dt para $T = 90$ y para $T = 5$.
- Bosqueje $T(t)$ para un café a 90°C y para un refresco a 5°C .

Resolvemos juntos en la pizarra

$$T' = -K(T - 20)$$

$$T' = 0$$


$$-K(T - 20)$$

$T = 20$


Espacio de trabajo

Equilibrios y estabilidad

Ejemplo 1



Ejemplo 2



Ejercicios

Equilibrios y estabilidad

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Para $y' = y(y - 1)(3 - y)$:

- a) Encuentre los tres equilibrios.
- b) Dibuje el diagrama de fase.
- c) Clasifique cada equilibrio como estable o inestable.

Ejercicio 2

Pesquería con cosecha constante:

$$dN/dt = rN(1 - N/K) - h.$$

- a) Dibuje $f(N)$ para h pequeño y para h grande.
- b) ¿Qué le pasa a los equilibrios cuando h crece?
- c) ¿Qué significa para la pesquería que desaparezcan?

Ejercicio 3

Sin calcular nada: la cuenta de un préstamo con interés continuo r y pago mensual constante p sigue $dD/dt = rD - p$.

- a) ¿Dónde está el equilibrio?
- b) ¿Es estable? ¿Qué le pasa a quien debe más que ese valor?

Sistemas de EDO: el modelo SIR

Cuando varias cantidades cambian y se afectan entre sí



Kermack y McKendrick, 1927. Población cerrada: $S + I + R = N$ constante.

$$\begin{cases} dS/dt = -\beta SI/N \\ dI/dt = \beta SI/N - \gamma I \\ dR/dt = \gamma I \end{cases}$$

β : tasa de contacto efectivo

Contactos por día que transmiten la enfermedad. El término $S \cdot I / N$ cuenta los encuentros entre susceptibles e infectados.

γ : tasa de recuperación

Si la enfermedad dura 7 días en promedio, $\gamma = 1/7$ por día. Es el inverso de la duración del período infeccioso.

Cómo leer el sistema

Lo que sale de un compartimento entra al siguiente: los términos se repiten con signo opuesto. Por eso la suma de las tres derivadas es cero.

El SIR no tiene solución cerrada. Aun así, sin resolverlo, podemos responder la pregunta más importante: ¿la epidemia crece o se apaga?

R_0 : el número que dictó las cuarentenas

Cuántos casos nuevos genera un infectado en una población totalmente susceptible

$$R_0 = \beta / \gamma$$

Al inicio $S \approx N$, así que $dI/dt \approx (\beta - \gamma) \cdot I$. Los infectados crecen si $\beta > \gamma$, es decir, si $R_0 > 1$; se extinguen si $R_0 < 1$. Es un umbral, no una velocidad.

$R_0 > 1$

La epidemia crece. Cada infectado deja más de un sucesor y el brote se sostiene hasta agotar susceptibles.

$R_0 < 1$

La epidemia se extingue. Puede haber casos, pero cada generación es menor que la anterior.

Inmunidad de rebaño


Basta proteger a una fracción $1 - 1/R_0$ para que el brote no crezca. Con $R_0 = 3$, el 67 %; con sarampión ($R_0 \approx 15$), el 93 %.

Enfermedad	Gripe estacional	SARS-CoV-2 (cepa original)	Sarampión	Dengue (depende del vector y el clima)
R_0 aproximado	1.3	2.5 a 3	12 a 18	1 a 4 según la temporada

Tres epidemias, tres R_0

Mismo modelo, misma duración de la enfermedad; solo cambia β

El mismo SIR con tres valores de R_0 ($\gamma = 1/7$, un infectado inicial)



Cómo leerlo

Con $R_0 < 1$ el brote nunca despegue. Cuanto mayor es R_0 , más temprano y más alto es el pico, y mayor la fracción final de contagiados.

Lo que no dice el pico

Aun con $R_0 = 3$ no se contagia el 100 %: el brote se apaga cuando ya no quedan suficientes susceptibles, no cuando todos se infectaron. Es la inmunidad de rebaño actuando sola.

Ejemplos

Sistemas y SIR

Resolvemos juntos en la pizarra

Ejemplo 1

Gripe con $\beta = 0.3$ por día y duración media de 7 días.

- a) Calcule γ y R_0 .
- b) ¿Crece o se apaga el brote?
- c) ¿Qué fracción habría que vacunar para frenarlo?
- d) Si un tratamiento acorta la enfermedad a 4 días, ¿cambia la respuesta?

Ejemplo 2


Lea el sistema SIR término por término:

- a) ¿Por qué el término de contagio es $\beta \cdot S \cdot I/N$ y no $\beta \cdot S$?
- b) ¿Qué pasa con dI/dt cuando S es muy pequeño, aunque I sea grande?
- c) ¿En qué momento ocurre el pico de infectados? Escríbalo como una condición sobre S .


Espacio de trabajo

Sistemas y SIR

Ejemplo 1



Ejemplo 2



Ejercicios

Sistemas y SIR

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Agregue un compartimento E (expuestos: infectados pero aún no contagiosos) entre S e I, con tasa σ de paso a I.

- a) Dibuje el diagrama SEIR.
- b) Escriba las cuatro ecuaciones.
- c) ¿Qué significa $1/\sigma$?

Ejercicio 2

Modelo SIS: los recuperados vuelven a ser susceptibles (resfrío común).

- a) Dibuje el diagrama y escriba el sistema.
- b) ¿Existe un equilibrio con $I > 0$?
¿Qué condición sobre R_0 necesita?

Ejercicio 3

El dengue se transmite por el mosquito *Aedes aegypti*, no de persona a persona.

- a) ¿Por qué el SIR simple no basta?
- b) Proponga los compartimentos de un modelo con humanos y mosquitos.
- c) ¿Qué parámetro nuevo dependería del clima?


Caso real

El vapeo como una epidemia social

El mismo razonamiento del SIR, con cinco compartimentos, aplicado a Costa Rica. Alfaro Brenes y Sevilla Moreira (2026), trabajo final de la Maestría en Métodos Matemáticos y Aplicaciones, UCR, dirigido por el Dr. Fabio Sánchez.

Modelar el vapeo en Costa Rica: del SIR al SVR

Cinco compartimentos, porque iniciar, dejar y recaer no son lo mismo



Entradas: $q\mu N$ a S y $(1-q)\mu N$ a P. Salidas: mortalidad natural μ en todos los compartimentos.

Por qué cinco

- P: no todos son igual de susceptibles; la evidencia de pares (OR ≈ 5) pide un grupo más receptivo.
- Qt y Qp: quien deja de vapear un tiempo recae con patrones distintos de quien deja para siempre.
- ρ : la recaída depende del contacto con vapeadores activos, igual que el contagio.

La misma gramática del SIR: cada flecha es un término que sale de un compartimento con signo negativo y entra al siguiente con signo positivo. Los términos de contagio y de recaída tienen la forma "algo $\cdot V/N$ ": son encuentros, no tasas fijas. Con eso ya podemos escribir el sistema.

El sistema y su R_0

Cinco ecuaciones, un número que resume la capacidad de invasión

$$\begin{cases} dS/dt = q\mu N - \varphi\beta S V/N - \mu S \\ dP/dt = (1-q)\mu N - \varphi_p\beta_p P V/N - \mu P \\ dV/dt = \varphi\beta S V/N + \varphi_p\beta_p P V/N + \rho Q_t V/N - (\mu + \gamma_t + \gamma_p)V \\ dQ_t/dt = \gamma_t V - \rho Q_t V/N - \mu Q_t \\ dQ_p/dt = \gamma_p V - \mu Q_p \end{cases}$$

$$R_0 = [\varphi\beta q + \varphi_p\beta_p(1 - q)] / (\mu + \gamma_t + \gamma_p)$$

Cómo leerlo

Numerador: capacidad de transmisión, ponderada por la proporción de cada grupo. Denominador: todas las formas de salir del compartimento V. Es la generalización directa de β/γ .

Antes de calcular nada

Se verifica que el sistema esté bien planteado: existencia y unicidad (Picard-Lindelöf), positividad y conservación de N.

Cómo se obtiene R_0

Método de la próxima generación: se linealiza en el equilibrio libre de vapeo y se toma el cociente entre generación y salida de casos.

Un detalle que importa

ρ no aparece en R_0 : en el equilibrio libre de vapeo no hay nadie en Q_t que pueda recaer. Eso tendrá consecuencias.

Lo que dijeron los datos

Calibrar con la literatura internacional y contrastar con Costa Rica

$$R_0 = 0.69$$

Con parámetros de estudios internacionales (PATH, SAVM): el vapeo se extinguiría


$$4 \% \rightarrow 13 \%$$

Prevalencia juvenil en Costa Rica entre 2021 y 2025 (crecimiento del 225 %)

$$R_0 \approx 2.3$$

Lo que hace falta para reproducir ese crecimiento: régimen supercrítico

Dos calibraciones del mismo modelo frente a los datos de Costa Rica



La calibración inversa

En vez de tomar los parámetros de la literatura y ver qué predicen, se pregunta qué transmisión efectiva reproduce el paso de 4 % a 13 % en cuatro años. La respuesta exige una transmisión unas tres veces mayor que la internacional, y un pico cercano al 19 % hacia 2029.

Un modelo "correcto" según la literatura puede contradecir el dato local. La discrepancia es el resultado, no un error.

La lección: $R_0 < 1$ no siempre basta

Bifurcación hacia atrás y por qué la recaída cambia el juego

Bifurcación transcítica (el caso del SIR)

La rama endémica nace en $R_0 = 1$ y crece hacia la derecha. Bajar R_0 por debajo de 1 elimina el comportamiento. Es lo que vimos hoy en la pizarra.

Bifurcación hacia atrás (cuando la recaída manda)

Si $\rho \cdot \gamma t$ supera a $(\phi\beta)^2 q + (\phi_p\beta_p)^2(1 - q)$, la rama endémica se extiende hacia $R_0 < 1$. Coexisten el equilibrio libre de vapeo y un equilibrio endémico estable: el destino depende de dónde se parte.

Un ejemplo del trabajo

Con $\rho = 2.5$ se obtiene $R_0 = 0.85$ y, aun así, dos equilibrios endémicos: uno inestable al 0.2 % y otro estable al 4.9 % de prevalencia.

Para la política pública

Reducir R_0 no alcanza si la población ya está en la cuenca del equilibrio endémico. Hay que sumar prevención de recaídas, que R_0 ni siquiera ve.

Para este curso

Todo esto se hizo con las herramientas de hoy: EDO, equilibrios, estabilidad y R_0 , más numpy, scipy y matplotlib. El código está en Zenodo y GitHub.

Parte 2

De la pizarra al código

Simulación numérica con `scipy.integrate`, calibración a datos reales costarricenses y el ecosistema diferenciable moderno.

Por qué las EDO importan en ciencia de datos hoy

2026 no es 1980: el rol de las ecuaciones diferenciales cambió

IA GENERATIVA

Stable Diffusion, Sora, FLUX

Los modelos que generan imágenes y video están definidos por ecuaciones diferenciales estocásticas. El artículo de Stable Diffusion 3 cita explícitamente la teoría de flow matching de Lipman et al. (ICLR 2023).

SALUD

Series clínicas con muestreo irregular

Latent ODE y Neural ODE son el enfoque de referencia para signos vitales en UCI y farmacocinética. Cuando los datos no llegan a intervalos uniformes, la EDO es la estructura correcta.

EPIDEMIOLOGÍA

Decisiones de política en pandemia

Los modelos compartimentales (SIR, SEIR, SEICR) guiaron las decisiones de confinamiento. En Costa Rica, Tomás de-Camino-Beck (Lead University) publicó un SEICR adaptado al país en mayo de 2020.

NEGOCIOS

Difusión de productos y adopción

El modelo de Bass (1969) es la misma matemática que el logístico. Predice adopción: Sinpe Móvil, Netflix, vehículos eléctricos. PyMC-Marketing trae una implementación bayesiana lista.

Las ecuaciones diferenciales no son tema antiguo: son la maquinaria matemática detrás de la IA generativa de 2026.

El gancho: cómo genera imágenes Stable Diffusion

Una EDO neuronal transforma ruido en una imagen coherente

La idea matemática

Imaginen una imagen como un punto en un espacio de altísima dimensión. La generación tiene dos direcciones:

- **Forward (entrenamiento):** añadir ruido gradualmente a la imagen hasta que sea solo estática. Esto define una ecuación diferencial estocástica.
- **Reverse (generación):** partir de ruido puro y, paso a paso, quitar ruido hasta recuperar una imagen. Esto resuelve una EDO cuyo campo vectorial fue aprendido por una red.

Flow matching: el avance de 2023 que cambió el campo

Lipman, Chen, Ben-Hamu, Nickel y Le (Meta AI, ICLR 2023) propusieron entrenar directamente una red que aprenda el campo vectorial de una EDO: $dx/dt = v_{\theta}(x, t)$. Stable Diffusion 3, Sora y FLUX usan variantes de esta técnica.

El $dy/dt = f(t, y)$ de la primera lámina de hoy es, literalmente, la ecuación que resuelve un generador de imágenes. Solo que f es una red neuronal.

scipy.integrate: la herramienta del curso

Cómo resolver una EDO sin escribir la fórmula a mano

```
from scipy.integrate import solve_ivp
import numpy as np
import matplotlib.pyplot as plt

# Una EDO de primer orden:  $dy/dt = -2y$ , con  $y(0) = 1$ 
def campo(t, y):
    return -2 * y

sol = solve_ivp(campo, t_span=(0, 5), y0=[1.0],
                t_eval=np.linspace(0, 5, 100))

# Comparar contra la solución analítica  $y(t) = \exp(-2t)$ 
fig, ax = plt.subplots(figsize=(9, 4))
ax.plot(sol.t, sol.y[0], label="numérica", lw=2)
ax.plot(sol.t, np.exp(-2 * sol.t), "--", label="analítica")
ax.set_xlabel("t"); ax.set_ylabel("y(t)"); ax.legend()
ax.set_title("Decaimiento exponencial:  $dy/dt = -2y$ ")
plt.show()
```

solve_ivp

API moderna: la que usamos

odeint

API legada: no usar en código nuevo

La receta

Una función `campo(t, y)` que devuelve la derivada, un intervalo `t_span`, la condición inicial `y0` y, opcionalmente, en qué puntos queremos la solución.

Cuándo usar cada método numérico

La tabla que deben tener a mano siempre

Método	Tipo	Cuándo usarlo
RK45	Runge-Kutta explícito de orden 5(4)	Por defecto, para problemas típicos no rígidos
RK23	Bogacki-Shampine de orden 3(2)	Cuando se acepta una tolerancia baja
DOP853	Dormand-Prince de orden 8	Alta precisión ($\text{rtol} < 1\text{e-}8$)
Radau	Runge-Kutta implícito de orden 5	Problemas rígidos con precisión
BDF	Backward Differentiation Formula	Sistemas rígidos grandes (estilo ode15s)
LSODA	Adams/BDF con conmutación automática	"No sé si es rígido": dejen que decida

Regla práctica: empiecen siempre con RK45. Si ven muchos pasos rechazados o advertencias sobre el tamaño del paso, prueben LSODA. Si LSODA conmuta a BDF, su problema es rígido: pasen explícitamente a Radau.

Demo en vivo: el modelo de Lotka-Volterra

Depredador y presa: el sistema de Volterra y los tiburones del Adriático

```
def lotka_volterra(t, z, alpha, beta, delta, gamma):  
    x, y = z  
    return [alpha*x - beta*x*y, delta*x*y - gamma*y]  
  
params = (1.1, 0.4, 0.1, 0.4)  
sol = solve_ivp(lotka_volterra, t_span=(0, 50), y0=[10, 5],  
                args=params, method="RK45",  
                rtol=1e-8, atol=1e-10,  
                t_eval=np.linspace(0, 50, 1000))  
  
# Dos paneles: serie temporal y plano de fase  
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 4))  
ax1.plot(sol.t, sol.y[0], label="presa")  
ax1.plot(sol.t, sol.y[1], label="depredador")  
ax1.set_xlabel("tiempo"); ax1.legend()  
ax2.plot(sol.y[0], sol.y[1])  
ax2.set_xlabel("presa"); ax2.set_ylabel("depredador")  
ax2.set_title("Plano de fase: orbitas cerradas")  
plt.show()
```

args

Los parámetros del modelo se pasan aparte y llegan a la función campo después de (t, z).

t_eval

Define dónde queremos la solución. No es la malla interna del solver, que es adaptativa.

rtol y atol

Tolerancias relativa y absoluta. Típico: $1e-6$ y $1e-9$. Se bajan cuando se necesita precisión.

Caso real: la población de Costa Rica

Ajustar Verhulst a los censos del INEC con `curve_fit`

```
from scipy.optimize import curve_fit

# Solucion analitica del modelo logistico (Verhulst)
def logistico(t, K, r, N0):
    return K / (1 + ((K - N0) / N0) * np.exp(-r * t))

# Censos INEC 1864 a 2022
anios = np.array([1864, 1892, 1927, 1950, 1973,
                  1984, 2000, 2011, 2022])
poblacion = np.array([120000, 243000, 472000, 800000, 1872000,
                      2417000, 3810000, 4301000, 5044197])

t = anios - anios[0]
params, _ = curve_fit(logistico, t, poblacion,
                      p0=[6e6, 0.03, 120000])

K, r, N0 = params
print(f"Capacidad de carga K = {K/1e6:.2f} millones")
print(f"Tasa de crecimiento r = {r:.4f} por anio")
```

5.04 M

Habitantes según el censo 2022

5.19 M

Estimación 2025 del INEC

Conexión con la pizarra

El $r \approx 0.022$ lo estimamos a mano con dos censos. Aquí la computadora usa los nueve y además estima K . Comparen ambos r .

El modelo SIR en código

El sistema que vimos a mano, resuelto numéricamente

```
def sir(t, y, beta, gamma):
    S, I, R = y
    N = S + I + R
    dS = -beta * S * I / N
    dI = beta * S * I / N - gamma * I
    dR = gamma * I
    return [dS, dI, dR]

# Parametros tipicos para gripe estacional: R0 = beta/gamma = 2.1
beta, gamma = 0.3, 1/7
N = 1000; I0 = 1; S0 = N - I0

sol = solve_ivp(sir, (0, 160), [S0, I0, 0],
                args=(beta, gamma), rtol=1e-8,
                t_eval=np.linspace(0, 160, 500))

pico = sol.y[1].argmax()
print(f"Pico: {sol.y[1][pico]:.0f} infectados el dia {sol.t[pico]:.0f}")
print(f"Total contagiados: {N - sol.y[0, -1]:.0f}")
```

Estructura general

El campo recibe (t, y, *args) y devuelve la lista de derivadas. Puede crecer a 10 o 20 compartimentos sin cambiar la estructura: así está escrito el modelo del vapeo.

Es el Ejemplo 1 de la pizarra

$\beta = 0.3$ y $\gamma = 1/7$ dan $R_0 = 2.1$. Verifiquen en la gráfica la fracción final de contagiados y el día del pico; compárenlo con lo que razonamos a mano.

Detectar eventos durante la simulación

"Avísame cuando pase algo importante"

```
# Detectar el pico de infectados: cuando dI/dt = 0
def pico_infectados(t, y, beta, gamma):
    S, I, R = y
    N = S + I + R
    return beta * S * I / N - gamma * I    # dI/dt

pico_infectados.terminal = False    # continuar despues del evento
pico_infectados.direction = -1     # solo de positivo a negativo

sol = solve_ivp(sir, (0, 200), [S0, I0, 0],
                args=(beta, gamma),
                t_eval=np.linspace(0, 200, 500),
                events=pico_infectados)

t_pico = sol.t_events[0][0]
I_pico = sol.y_events[0][0][1]
print(f"Pico de la epidemia en el dia {t_pico:.1f}")
print(f"Infectados en el pico: {I_pico:.0f}")
```

Qué hace

`solve_ivp` vigila una función y registra el instante exacto en que cruza cero, con la precisión del solver y no de la malla `t_eval`. Es algo que `odeint` no tiene.

Para qué sirve en producción

Activar una alarma cuando un tanque se vacía, detener una simulación de mercado cuando un precio cruza un umbral, identificar el día del pico para planificación hospitalaria.

Caso costarricense: el SEICR de Lead University

Tomás de-Camino-Beck (Automata Innovations y Lead University, 2020)

El modelo SEICR aplicado a COVID-19 en Costa Rica

En mayo de 2020 publicó en medRxiv un modelo SEIR modificado con un compartimento C de confinados, específico para Costa Rica, calibrado a la curva de casos del Ministerio de Salud de marzo y abril de 2020.

La innovación

Las intervenciones no farmacéuticas (confinamiento, distanciamiento) se modelan como un flujo dinámico entre S y C: al confinar, se reduce la población susceptible disponible para el contagio.

El sistema

$S \rightarrow E \rightarrow I \rightarrow R$ con un flujo paralelo $S \leftrightarrow C$. Es el Ejercicio 1 de la pizarra (SEIR) más un compartimento de política pública.

El autor es profesor de su universidad. Referencia: de-Camino-Beck, T. (2020), medRxiv, doi:10.1101/2020.05.19.20106492.

Dengue en Costa Rica: un carril del proyecto

Datos reales del Ministerio de Salud

30 649

Casos en 2023

31 259

Casos en 2024

7

Fallecidos en 2024: el segundo año con más muertes por dengue en 31 años

Por qué el dengue es ideal para modelar

- Patrón estacional fuerte, ligado al ciclo del vector *Aedes aegypti* (el Ejercicio 3 de la pizarra).
- Cuatro serotipos en circulación; DENV-3 dominó en 2024.
- Datos semanales públicos en el Boletín Epidemiológico del Ministerio de Salud.
- Modelos SEIR vectoriales bien establecidos en la literatura.

Alternativa para no batallar con PDF: OpenDengue (opendengue.org), dataset publicado en Scientific Data (2024) con 56 millones de casos en 102 países, Costa Rica incluida desde 1924.

Calibración a datos reales

Ajustar β y γ con mínimos cuadrados robustos

```
from scipy.optimize import least_squares

# 1. Datos sinteticos con parametros conocidos (R0 real = 2.1)
beta_real, gamma_real = 0.30, 1/7
t_data = np.linspace(0, 100, 50)
sol_real = solve_ivp(sir, (0, 100), [N-I0, I0, 0],
                    args=(beta_real, gamma_real), t_eval=t_data)
rng = np.random.default_rng(42)
I_data = sol_real.y[1] + rng.normal(0, 8, len(t_data))

# 2. Residuos y ajuste
def residuos(theta):
    beta, gamma = theta
    sol = solve_ivp(sir, (0, 100), [N-I0, I0, 0],
                    args=(beta, gamma), t_eval=t_data)
    return sol.y[1] - I_data

res = least_squares(residuos, [0.5, 0.05], bounds=([0, 0], [5, 5]),
                    loss="soft_l1") # robustez ante outliers
beta_hat, gamma_hat = res.x
print(f"R0 estimado: {beta_hat/gamma_hat:.2f}")
```

La idea

Cada intento de (β, γ) resuelve el SIR y compara con los datos. El optimizador mueve los parámetros hasta que los residuos son mínimos.

loss='soft_l1' o 'huber'

Pérdidas robustas para datos epidemiológicos con semanas de subreporte u outliers. Es lo que separa un modelo de juguete de uno utilizable.

Calibración bayesiana: el estándar de 2026

No un valor estimado, una distribución completa

```
import pymc as pm, arviz as az
from pymc.ode import DifferentialEquation

def sir_ode(y, t, p):
    S, I, R = y[0], y[1], y[2]
    return [-p[0]*S*I/N, p[0]*S*I/N - p[1]*I, p[1]*I]

sir_eq = DifferentialEquation(func=sir_ode, times=t_data[:,5],
                             n_states=3, n_theta=2)

with pm.Model() as modelo:
    beta = pm.LogNormal("beta", mu=np.log(0.3), sigma=0.5)
    gamma = pm.LogNormal("gamma", mu=np.log(0.1), sigma=0.5)
    sigma = pm.HalfNormal("sigma", sigma=15)
    sol = sir_eq(y0=[N-I0, I0, 0], theta=[beta, gamma])
    pm.Normal("obs", mu=sol[:, 1], sigma=sigma, observed=I_data[:,5])
    idata = pm.sample(1000, tune=1000, chains=2, target_accept=0.95)

R0 = (idata.posterior["beta"] / idata.posterior["gamma"]).values
print(np.percentile(R0, [2.5, 50, 97.5]))
```

Qué cambia

Mínimos cuadrados da un valor puntual. La inferencia bayesiana responde: "con 95 % de probabilidad, R_0 está entre 1.9 y 2.4". Es lo que usa la epidemiología profesional.

Lo veremos a fondo

Semana 4: Monte Carlo y MCMC con PyMC. Tema 2 de la presentación grupal: inferencia bayesiana del prior al posterior.

Más allá de SciPy: el ecosistema diferenciable

Cuando el solver es una capa de una red neuronal

SciPy resuelve EDO. Lo que cambió la industria fue poder propagar gradientes a través del solver: los parámetros de un modelo de EDO se aprenden por descenso de gradiente, igual que los pesos de una red.

Diffraction (JAX)

Patrick Kidger. Solver unificado para EDO, EDE y CDE en JAX, nativo en GPU y diferenciable. Referencia cuando se necesita JIT, GPU y gradientes.

torchdiffeq (PyTorch)

Ricky Chen. Implementación de referencia de las Neural ODE (NeurIPS 2018, mejor artículo). Provee odeint y odeint_adjoint con gradientes de memoria constante.

DifferentialEquations.jl (Julia)

Chris Rackauckas. El ecosistema más maduro y rápido del mundo para EDO. Lo mencionamos para que sepan que existe; no es el stack del curso.

NumPyro + Diffraction

Para SIR o SEIR bayesianos en GPU, la combinación más rápida de 2026. Alternativa a PyMC cuando el modelo es muy grande.

Neural ODE en producción real

Dónde se usan hoy las EDO neuronales

SALUD

Series clínicas irregulares

Latent ODE (Rubanova et al., NeurIPS 2019) son el enfoque académico estándar para signos vitales en UCI, curvas farmacocinéticas y datos de PhysioNet.

BIOLOGÍA DE SISTEMAS

Modelos cinéticos a gran escala

Jaxkineticmodel (2025) entrena modelos SBML con miles de parámetros usando DiffraX. Sustituye horas de Matlab o Fortran por minutos en GPU.

FINANZAS

Datos de mercado de alta frecuencia

Neural CDE (ecuaciones diferenciales controladas) para datos financieros con frecuencia irregular. Adopción en mesas de trading desde 2024.

PRONÓSTICO

Demanda en retail con faltantes

Casos documentados de consultoras (Ekimetrics) para pronóstico de demanda. No reemplazan a los transformers, pero ganan cuando la dinámica continua es la estructura correcta.

Mensaje honesto: en producción a gran escala, transformers y RNN siguen ganando en muchos benchmarks. Las Neural ODE ganan cuando la física o la biología subyacente es continua.

PINN: redes neuronales informadas por física

Una nota honesta sobre dónde están en 2026

La promesa

Una red neuronal que aprende la solución de una ecuación diferencial (incluso en derivadas parciales) sin mallas tradicionales. NVIDIA mantiene PhysicsNeMo como framework comercial. Es el tema 10 de la presentación grupal.

Dónde sí funcionan

Problemas inversos (estimar coeficientes desde datos), geometrías complejas sin malla y escasez extrema de datos donde la física se conoce parcialmente.

Dónde no funcionan (todavía)

Problemas multiescala, dinámicas de alta frecuencia y problemas directos estándar, donde CFD y FEM siguen ganando en precisión y velocidad.

Conclusión equilibrada: área activa de investigación con resultados mixtos y limitaciones documentadas en revisiones recientes. No las descartemos, pero tampoco son solución mágica. En este curso solo las mencionamos.

Datasets para el proyecto integrador

Fuentes reales costarricenses y regionales para modelos con EDO

Dataset	Fuente	Ideal para
Población de Costa Rica 1864-2025	INEC, estimaciones CCP-INEC	Malthus, Verhulst, ajuste con curve_fit
Dengue semanal en Costa Rica	Ministerio de Salud (PDF del boletín)	SEIR vectorial, calibración bayesiana
Dengue regional (limpio)	OpenDengue, opendengue.org	SEIR comparativo entre países
Demanda eléctrica de Costa Rica	ICE, CNFL	EDO con forzante estacional
Llegadas de turistas	ICT, datos mensuales	Difusión de Bass, logísticos generalizados
Usuarios de Sinpe Móvil	BCCR, indicadores económicos	Difusión de Bass para adopción tecnológica

Recordatorio: cada grupo elige un tema distinto y no se repiten. Hoy la idea es que vean qué fuentes existen; la elección formal del tema se hace en la clase 3, el próximo jueves.

Validación correcta para EDO en series temporales

Lo que no se aprende en un curso estándar de machine learning

Por qué k-fold no funciona aquí

La validación cruzada estándar baraja los datos al azar. En series temporales eso rompe la dependencia temporal: el modelo "ve el futuro" durante el entrenamiento.

Hold-out hacia adelante

Entrenar con datos hasta el momento t , predecir $t + h$, repetir incrementalmente.

Backtesting epidemiológico

Ajustar hasta la semana k , predecir $k + 1$ a $k + 4$, desplazar una semana y repetir.

WIS (weighted interval score)

Métrica estándar en los Forecast Hubs del CDC y otros organismos para pronósticos con intervalos.

Análisis de sensibilidad con SALib

Herramienta canónica en Python para saber qué parámetros importan más en la salida: Morris (screening barato) y Sobol (descomposición global de varianza). Es lo que hicimos en la tesis con R_0 y lo que distingue un modelo que ajusta de uno que se entiende.

Limitaciones de los modelos compartimentales

Lo que un modelador serio debe poder enumerar

1. Mezcla homogénea

Todos pueden contagiar a todos por igual. Las redes de contacto reales son muy heterogéneas: por eso el CIMPA-UCR usó cinco millones de nodos.

2. Población cerrada

No hay nacimientos, muertes ni migración a menos que se añadan explícitamente, como el μ del modelo del vapeo.

3. Parámetros constantes

β no cambia con intervenciones, estaciones o comportamiento. En la realidad sí cambia; SEICR lo resolvió con un compartimento.

4. Determinismo

En poblaciones pequeñas el azar importa. Se usan ecuaciones diferenciales estocásticas o modelos basados en agentes.

5. Identificabilidad

Distintos pares (β , γ) producen curvas similares con datos truncados. En la tesis, φ y β solo se identifican por su producto.

6. Sin estructura de edad

Iniciación y cesación difieren entre adolescentes y adultos. Es la primera extensión pendiente del modelo del vapeo.

Un modelador profesional no se enamora del modelo. Enumera sus limitaciones primero y propone mejoras después.

Actividad grupal en salas

Los últimos 40 minutos de clase, con los grupos del proyecto

Cómo funciona

Cada grupo va a una sala virtual con un notebook compartido. Cuatro miniexploraciones: una a mano y tres en Colab. Repártanse el trabajo y vuelvan a la plenaria para una puesta en común breve. No se entrega ni se califica; lo que no terminen queda como tarea moral.

1. A mano

Ley de enfriamiento de Newton: clasifique la EDO, halle el equilibrio y dibuje el diagrama de fase.

2. Colab

Implemente Verhulst con `solve_ivp` y compárelo con la solución analítica de la pizarra.

3. Colab

Simule un SIR con tres valores de R_0 (0.8, 1.5 y 3) y compare las curvas de infectados.

4. Colab

Ajuste el modelo logístico a los censos del INEC con `curve_fit` y estime K . Compare r con el 0.022 de la clase.

Pregunta para la plenaria: ¿qué aprendieron en Colab que no podían ver en la pizarra, y qué vieron en la pizarra que Colab no les explica?

Síntesis de la sesión

Cada idea de hoy y dónde vuelve a aparecer

A mano	En la computadora	Vuelve en
Una EDO es una regla de cambio $dy/dt = f(t, y)$	La función <code>campo(t, y)</code> que recibe <code>solve_ivp</code>	Toda la segunda mitad del curso
Malthus crece sin freno; Verhulst se satura en K	<code>curve_fit</code> sobre los censos del INEC	Semana 6, series temporales
Equilibrios y diagrama de fase	Eventos en <code>solve_ivp</code> ; estabilidad numérica	Semanas 9 y 10, optimización
El sistema SIR y el umbral R_0	Simulación, calibración y pico del brote	Semana 4, MCMC con PyMC
Cinco compartimentos: el modelo del vapeo	Mismo código, más ecuaciones; sensibilidad con SALib	Proyecto integrador

La diferencia entre saber cálculo y saber modelado matemático es manejar las dos cosas: la lectura conceptual que hicimos a mano y la herramienta computacional que resuelve lo que la pizarra no puede.

Para la próxima semana

Clase 3 · jueves 24 de setiembre · cadenas de Markov

Pendientes

- Resolver la tarea moral de los cuatro bloques de ejercicios.
- Terminar las miniexploraciones de Colab que quedaron abiertas.
- Leer el capítulo 1 de Giordano, Fox y Horton y hojear el SEICR de de-Camino-Beck (medRxiv, 2020).
- Decidir en grupo el tema preliminar del proyecto: la elección formal es en la clase 3.

Tema 3: cadenas y procesos de Markov

- Definición, matriz de transición y distribuciones estacionarias.
- PageRank como cadena de Markov, con NetworkX.
- Conexión conceptual con los modelos de lenguaje.
- Otro modelo dinámico, ahora en tiempo discreto y con azar.

Del cambio continuo y determinista de hoy pasamos al cambio por saltos y probabilístico. El SIR volverá en la semana 4 para calibrarlo con MCMC.

Dudas: jordy.alfaro@ulead.ac.cr

Lo que se llevan de esta sesión

Una EDO se lee antes de resolverse

Regla de cambio, parámetros con significado, equilibrios y estabilidad. Casi todo lo importante se ve sin integrar.

Todos los modelos son incorrectos

Malthus falló por un millón de personas y la literatura internacional falló con el vapeo en Costa Rica. Esas discrepancias son resultados.

R_0 es un umbral, y a veces no basta

Del SIR de 1927 a una tesis costarricense de 2026: el mismo número, con matices que cambian una política pública.

Nos vemos el próximo jueves con cadenas de Markov.