

Cadenas y procesos de Markov

Semana 3: del clima al PageRank, pasando por los LLM

BCD5105 • Modelado matemático

Profesor: Jordy Alfaro Brenes

Lead University • III cuatrimestre 2026 • Modalidad virtual

Jueves 24 de setiembre de 2026 • 4:00 a 7:00 p. m.

Ruta de la sesión

Dos mitades: primero a mano, después en R

Al terminar la sesión usted podrá

- Reconocer cuándo un fenómeno cumple la propiedad de Markov y cuándo no.
- Construir el diagrama y la matriz de transición de una cadena.
- Proyectar la distribución a varios pasos y leer qué significa P^n .
- Calcular e interpretar la distribución estacionaria, y saber cuándo existe.
- Explicar con el monje en la cueva qué agrega un modelo de Markov oculto.
- Hacer todo lo anterior en R, más PageRank y un modelo de texto.

Bloques y tiempos estimados

1	Propiedad de Markov y matriz de transición	15 min
2	La cadena en el tiempo: $\pi_0 P, \pi_0 P^2, \dots$	20 min
3	Distribución estacionaria y cuándo existe	20 min
4	Modelos ocultos: el monje en la cueva	20 min
	<i>Receso</i>	10 min
5	R: clima, convergencia y simulación	25 min
6	PageRank, SIR en redes, texto y HMM	30 min
7	Actividad en salas y tema del proyecto	40 min

Parte 1

Cadenas de Markov, a mano

Trabajo conceptual en la pizarra: qué es un estado, cómo se lee una matriz de transición, hacia dónde va la cadena a largo plazo y qué pasa cuando el estado no se ve.

La propiedad de Markov

El futuro depende solo del presente, no de cómo llegamos aquí

$$P(X_{t+1} \mid X_t, X_{t-1}, \dots, X_0) = P(X_{t+1} \mid X_t)$$

Estado

La descripción del sistema en un instante: el clima de hoy, la página que usted está viendo, la palabra que acaba de escribir. En este curso, siempre un conjunto finito $S = \{s_1, \dots, s_n\}$.

Tiempo discreto

La cadena avanza a saltos: día a día, clic a clic, mes a mes. Cada salto es una transición entre estados, posiblemente al mismo estado.

Memoria corta

Toda la historia relevante está resumida en el estado actual. Es una simplificación fuerte, y ahí está su poder: con eso basta para modelar clima, clientes, la web y el texto.

Preguntarse "¿cumple la propiedad de Markov?" es preguntarse si el estado elegido contiene toda la información necesaria. Si no, a veces basta con redefinir el estado.

La matriz de transición

Cada fila es "desde dónde", cada columna es "hacia dónde"


$$P_{ij} = P(X_{t+1} = j \mid X_t = i)$$

Dos propiedades que siempre se revisan

- $P_{ij} \geq 0$: son probabilidades.
- Cada fila suma 1: desde cualquier estado, algo tiene que pasar.

	A	B
A	0.7	0.3
B	0.6	0.4


$$P(X_{t+1} = j \mid X_t = i)$$
$$P_{ij} = P(j \mid i)$$



El diagrama y la matriz son la misma información: cada flecha es una entrada de P . Las flechas que regresan al mismo nodo son la diagonal.

Ejemplo: el clima de mañana

Estados S = soleado, N = nublado, L = lluvioso



La matriz

	S	N	L
S	0.7	0.2	0.1
N	0.3	0.5	0.2
L	0.2	0.4	0.4

Una lectura

$P(S \rightarrow L) = 0.1$: si hoy está soleado, hay 10 % de probabilidad de lluvia mañana. Las columnas no tienen por qué sumar 1.

Pregunta

¿Qué fila tiene la mayor diagonal? ¿Qué dice sobre la persistencia de ese clima?

Ejemplos

Propiedad de Markov y matriz de transición

Resolvemos juntos en la pizarra

Ejemplo 1

Un estudiante cada día estudia (E) o no estudia (N). Si estudió hoy, mañana estudia con probabilidad 0.6; si no estudió, con probabilidad 0.3.

- a) Dibuje el diagrama.
- b) Escriba la matriz P y verifique las filas.
- c) ¿Qué supuesto sobre el estudiante hace el modelo?

Ejemplo 2


¿Cumple la propiedad de Markov? Justifique:

- a) El saldo de su cuenta al final del mes.
- b) Las ventas de un producto que dependen de los dos meses anteriores.
- c) El resultado de la lotería de esta semana.
- d) Para (b), ¿cómo redefiniría el estado para que sí la cumpla?

Espacio de trabajo

Propiedad de Markov y matriz de transición

Ejemplo 1



b)

$$P = \begin{matrix} & \begin{matrix} E & N \end{matrix} \\ \begin{matrix} E \\ N \end{matrix} & \begin{pmatrix} 0.6 & 0.4 \\ 0.3 & 0.7 \end{pmatrix} \end{matrix}$$

c) No importa que pasó ayer
Homogeneidad
No hay estados intermedios

Ejemplo 2

Ejercicios

Tarea moral · resuélvalos durante la semana

Propiedad de Markov y matriz de transición

Ejercicio 1

Una plataforma de streaming clasifica cada mes a sus suscriptores en Activo, Pausado o Cancelado.

Un activo sigue activo con 0.85 y pausa con 0.10; un pausado reactiva con 0.40 y cancela con 0.20; quien cancela no vuelve.

Construya el diagrama y la matriz.

Ejercicio 2

Complete las entradas que faltan y explique su razonamiento:

Fila 1: (0.5, 0.3, ?)

Fila 2: (?, 0.6, 0.1)

Fila 3: (0.2, ?, 0.2)

¿Es posible que una columna sume más de 1?

Ejercicio 3

Proponga una cadena de Markov con tres estados para algo de su trabajo o entorno.

a) Defina los estados.

b) Invente una matriz razonable.

c) ¿Qué información importante estaría ignorando por la propiedad de Markov?

La cadena en el tiempo

¿Cómo estará el clima dentro de dos días si hoy está soleado?

$$\pi_{t+1} = \pi_t \cdot P$$

$$P(X_n = j \mid X_0 = i) = (P^n)_{ij}$$

El cálculo de la pizarra

$\pi_0 = (1, 0, 0)$ hoy soleado con certeza

$\pi_1 = \pi_0 P = (0.70, 0.20, 0.10)$ la primera fila de P

$\pi_2 = \pi_1 P = (0.57, 0.28, 0.15)$ ←

$\pi_2(S) = 0.7 \cdot 0.7 + 0.2 \cdot 0.3 + 0.1 \cdot 0.2 = 0.57$

$$\pi_3 = \pi_2 \cdot P$$
$$\vdots$$


Chapman-Kolmogorov, en palabras

Para ir de i a j en n pasos hay que sumar sobre todos los caminos intermedios, y eso es exactamente multiplicar la matriz por sí misma n veces. No hace falta memorizar la fórmula: la potencia de la matriz hace el trabajo.

La distribución es un vector fila que "viaja" por la matriz. Cada multiplicación es un día más. La suma siempre debe dar 1: es la verificación rápida de cualquier cálculo a mano.

¿Y si seguimos multiplicando?

$\pi(S)$ a lo largo del tiempo, desde los tres climas posibles de hoy



Qué muestra

Las tres curvas empiezan en lugares distintos (certeza de sol, de nubes o de lluvia) y terminan en el mismo valor.

La pregunta de la pizarra

¿Hay convergencia? Sí, y rápida: en unos seis días el clima de hoy ya casi no informa sobre el de la próxima semana.

Ejemplos

La cadena en el tiempo

Ejemplo 1

Con la cadena del estudiante (E: 0.6 y 0.4; N: 0.3 y 0.7):

- a) Si hoy estudió, ¿qué probabilidad hay de que estudie pasado mañana?
- b) Escriba π_1 y π_2 .
- c) ¿Coincide con la fila E de P^2 ?

Resolvemos juntos en la pizarra

Ejemplo 2

Con la cadena del clima, hoy está lluvioso: $\pi_0 = (0, 0, 1)$.

- a) Calcule π_1 y π_2 .
- b) ¿Qué es más probable dentro de dos días?
- c) Compare con el caso "hoy soleado". ¿Qué tan distinto es?

Espacio de trabajo

La cadena en el tiempo

Ejemplo 1

$$P = \begin{matrix} & \begin{matrix} E & N \end{matrix} \\ \begin{matrix} E \\ N \end{matrix} & \begin{pmatrix} 0.6 & 0.4 \\ 0.3 & 0.7 \end{pmatrix} \end{matrix}$$

$$a) \pi_0 = \begin{matrix} E & N \\ (1, 0) \end{matrix}$$

$$\pi_1 = (0.6, 0.4)$$

$$\pi_2 = \pi_1 \cdot P = (0.6, 0.4) \cdot \begin{pmatrix} 0.6 & 0.4 \\ 0.3 & 0.7 \end{pmatrix}$$

$$= \begin{matrix} E & N \\ (0.48, 0.52) \end{matrix}$$

R/ Hay 48% de prob.

Ejemplo 2

$$0.6 \cdot 0.6 + 0.4 \cdot 0.3 = 0.48$$

$$0.6 \cdot 0.4 + 0.4 \cdot 0.7 = 0.52.$$

Ejercicios

La cadena en el tiempo

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Clima, hoy nublado: $\pi_0 = (0, 1, 0)$.

- a) Calcule π_2 .
- b) Verifique que suma 1.
- c) Interprete el valor de $\pi_2(L)$ en una frase.

Ejercicio 2

Sin calcular: si hoy la probabilidad está repartida $\pi_0 = (0.5, 0.5, 0)$, ¿por qué π_1 es el promedio de las filas S y N de P?

Verifíquelo numéricamente.

Ejercicio 3

Prediga, antes de ver la parte en R:

- a) ¿Cómo se verán las filas de P^{10} ?
- b) ¿Qué significaría que todas las filas fueran iguales?
- c) ¿Hay alguna cadena para la que eso nunca ocurra? Invente una.

Distribución estacionaria

El "clima promedio" hacia el que converge la cadena

$$\begin{pmatrix} 0.7 & 0.2 & 0.1 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.4 & 0.4 \end{pmatrix} \begin{cases} 0.7\pi(S) + 0.3\pi(N) + 0.2\pi(L) = \pi(S) \\ 0.2\pi(S) + 0.5\pi(N) + 0.4\pi(L) = \pi(N) \\ 0.1\pi(S) + 0.2\pi(N) + 0.4\pi(L) = \pi(L) \\ \pi(S) + \pi(N) + \pi(L) = 1 \end{cases}$$

$\Rightarrow \pi(S) = 46,8\%$

$$\pi \cdot P = \pi \quad y \quad \sum \pi_i = 1$$

Qué significa

Si hoy la probabilidad está repartida según π , mañana sigue repartida igual. No es que el clima se quede quieto: cambia todos los días, pero la proporción de días de cada tipo a largo plazo ya no cambia.

El sistema de la pizarra

$$\pi(N) = 34\%$$

$$0.7\pi(S) + 0.3\pi(N) + 0.2\pi(L) = \pi(S)$$

$$0.2\pi(S) + 0.5\pi(N) + 0.4\pi(L) = \pi(N)$$

$$0.1\pi(S) + 0.2\pi(N) + 0.4\pi(L) = \pi(L)$$

$$\pi(S) + \pi(N) + \pi(L) = 1$$


$$\pi(L) = 19,1\%$$

$$\pi = (22/47, 16/47, 9/47) \approx (46.8\%, 34.0\%, 19.1\%)$$

Una de las tres primeras ecuaciones sobra (es combinación de las otras). Por eso se reemplaza por la condición de que π sume 1.


Cuándo existe y es única

La cadena debe ser irreducible y aperiódica



Irreducible: se puede llegar de todos a todos

Aquí C atrapa a la cadena: una vez ahí, no sale. A largo plazo todo termina en C y $\pi = (0, 0, 1)$. El clima, en cambio, conecta los tres estados.



Aperiódica: sin ritmo fijo

Aquí la cadena alterna A, B, A, B para siempre: $\pi = (\frac{1}{2}, \frac{1}{2})$ existe, pero π_t nunca converge porque oscila. Basta una autotransición (diagonal positiva) para romper el ritmo.

Ejemplos

Distribución estacionaria

Resolvemos juntos en la pizarra

Ejemplo 1

Para la cadena A-B (A: 0.7 y 0.3; B: 0.6 y 0.4):

- a) Plantee $\pi P = \pi$ con $\pi_A + \pi_B = 1$.
- b) Resuelva.
- c) ¿Qué fracción del tiempo pasa la cadena en A?

Ejemplo 2


Decida si cada cadena es irreducible y aperiódica:

- a) El clima.
- b) La plataforma de streaming con estado Cancelado.
- c) Un semáforo: verde $\rightarrow$ amarillo $\rightarrow$ rojo $\rightarrow$ verde.
- d) Para las que fallen, ¿qué le pasa a π_t a largo plazo?


Espacio de trabajo

Distribución estacionaria

Ejemplo 1



Ejemplo 2



Ejercicios

Distribución estacionaria

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Calcule la distribución estacionaria del estudiante (E: 0.6 y 0.4; N: 0.3 y 0.7).

Interprete: en un cuatrimestre de 105 días, ¿cuántos días estudia?

$$\begin{matrix} E \\ N \end{matrix} \begin{pmatrix} 0.6 & 0.4 \\ 0.3 & 0.7 \end{pmatrix} \begin{cases} 0.6\pi(E) + 0.3\pi(N) = \pi(E) \\ 0.4\pi(E) + 0.7\pi(N) = \pi(N) \\ \pi(E) + \pi(N) = 1 \end{cases}$$

$$\pi(E) = \frac{3}{7} \quad \pi(N) = \frac{4}{7}$$

$$\approx 42,85\% \quad \approx 57,14\%$$

Ejercicio 2

Con π del clima:

a) ¿Cuántos días soleados espera en un año?

b) Si el IMN dice que en su cantón llueve 190 días al año, ¿la matriz es razonable para ese lugar? ¿Qué cambiaría?

Ejercicio 3

En la plataforma de streaming:

a) ¿Cuál es π ?

b) ¿Por qué eso no significa que el negocio esté perdido en el corto plazo?

c) ¿Qué transición agregaría para que la cadena sea irreducible?

$$105 \cdot 42,85\% = 44,99$$

$$= 45.$$

Modelos de Markov ocultos: el monje en la cueva

Cuando no vemos el estado, solo sus señales

La historia

Un monje vive en una cueva sin ventanas. Cada día alguien le pasa un objeto: un paraguas, unos lentes de sol o un sombrero. Con solo esa secuencia, quiere adivinar el clima de afuera.

Estados ocultos

El clima: S, N, L. Sigue la cadena de siempre, con su matriz P.

Observaciones

El objeto: paraguas, lentes, sombrero. Depende solo del clima de ese día.

Matriz de emisión B = P(objeto | clima)

	Paraguas	Lentes	Sombrero
Soleado	0.05	0.80	0.15
Nublado	0.30	0.20	0.50
Lluvioso	0.85	0.05	0.10

Dos matrices

P mueve el estado oculto de un día al otro; **B** dice qué señal emite cada estado. La cadena sigue ahí, detrás del telón.

Mismo esquema en finanzas (régimen de mercado detrás de los retornos), en voz (fonemas detrás del sonido) y en genómica (genes detrás de la secuencia de ADN).

El monje hace cuentas

Día 1: entra un paraguas. ¿Qué clima es más probable?

Bayes en una tabla

Sin información previa, el monje supone $\pi_0 = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ y multiplica por la columna "paraguas" de B:

$$S: \frac{1}{3} \times 0.05 = 0.017$$

$$N: \frac{1}{3} \times 0.30 = 0.100$$

$$L: \frac{1}{3} \times 0.85 = 0.283$$

$$\text{Suma} = 0.400 \text{ (la evidencia)}$$

4 %

Soleado

25 %

Nublado

71 %

Lluvioso

Posterior = cada producto dividido entre la suma. El paraguas no prueba la lluvia; la vuelve muy probable.

Día 2: predecir y corregir

Primero se proyecta la creencia del día 1 con P (predecir). Luego se multiplica por la columna del nuevo objeto y se normaliza (corregir). Repetido día a día, eso es el algoritmo forward.

Viterbi hace lo mismo guardando el mejor camino en cada paso: programación dinámica, la misma idea de Dijkstra que veremos en grafos.

Ejemplos

Modelos ocultos

Ejemplo 1

El monje, sin información previa, recibe unos lentes.

- a) Calcule los tres productos y su suma.
- b) Obtenga la posterior.
- c) ¿Por qué el resultado es más "seguro" que con el paraguas?

Resolvemos juntos en la pizarra

Ejemplo 2

Día 1 fue paraguas (posterior 0.04, 0.25, 0.71). El día 2 llega un sombrero.

- a) Prediga el clima del día 2 multiplicando por P.
- b) Corrija con la columna "sombrero" de B.
- c) ¿Cambió el clima más probable?

Espacio de trabajo

Modelos ocultos

Ejemplo 1

S N L

$$a) \pi_0 = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right)$$

$$S = \frac{1}{3} \cdot 0.80 = 0.2667$$

$$N = \frac{1}{3} \cdot 0.20 = 0.0667$$

$$L = \frac{1}{3} \cdot 0.05 = 0.0167$$

$$\text{Suma} = 0.35$$

$$b) P(S | \text{lentes}) = \frac{0.2667}{0.35} = 0.762$$

$$P(N | \text{lentes}) = \frac{0.0667}{0.35} = 0.19$$

$$P(L | \text{lentes}) = \frac{0.0167}{0.35} = 0.04$$

Ejemplo 2

Ejercicios

Modelos ocultos

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Sin información previa, el monje recibe un sombrero.

- a) Calcule la posterior.
- b) ¿Qué objeto le da menos información al monje? Argumente con la tabla B.

Ejercicio 2

Identifique el estado oculto y la observación en:

- a) Detección de fraude con tarjetas.
- b) Estado de ánimo a partir de mensajes de texto.
- c) Reconocimiento de voz.
- d) Un paciente con una enfermedad crónica.

Ejercicio 3

¿Por qué el monje no debería decidir el clima solo con el objeto del día, ignorando P?

Invente una secuencia de cinco objetos donde P cambie la conclusión de algún día.

Parte 2

Cadenas de Markov en R

Verificar en la computadora lo que hicimos a mano y llevarlo a escalas que la pizarra no alcanza:
PageRank, redes, texto y regímenes ocultos.

¿Por qué R esta semana?

Diversidad de herramientas, no de hábitos

Dos lenguajes del oficio

Python domina la inteligencia artificial y la producción. R domina la estadística, las series temporales y el análisis exploratorio profundo. Un científico de datos competitivo lee y escribe ambos.

R brilla en este tema

El paquete `markovchain` define un objeto para cadenas de tiempo discreto con métodos para la distribución estacionaria, la clasificación de estados, la simulación y el ajuste a datos, cada uno en una línea.

Volveremos a R

En la semana 6 usaremos el ecosistema `fpp3` de Hyndman, el estándar para pronóstico. Hoy nos calentamos. El resto del curso es Python, y las mismas ideas se implementan con NumPy y NetworkX.

R en Google Colab

Abrir `colab.to/r`, o en un notebook existente: Entorno de ejecución → Cambiar tipo de entorno → R. Sin instalación local. Limitación: `drive.mount()` solo funciona en entornos de Python; para leer del Drive use el paquete `googledrive`.

El stack de R para esta clase

Cinco paquetes, cinco superpoderes

markovchain

Cadenas de tiempo discreto: estacionaria, simulación, clasificación y ajuste.

igraph

Análisis de grafos, incluido `page_rank()` exacto. Vuelve en el tema 10.

depmixS4

Modelos de Markov ocultos con respuestas tipo GLM.

expm

Potencias de matrices con el operador `%^%`.

diagram

Dibuja la matriz de transición como diagrama de flujo.

```
# Celda 1 del notebook: instalacion (una vez por sesion)
install.packages(c("markovchain", "igraph", "depmixS4", "expm", "diagram"))
library(markovchain); library(igraph); library(expm)
```

¿Para qué importan las cadenas de Markov hoy?

Cuatro aplicaciones que mueven la industria

BÚSQUEDA

PageRank de Google

Brin y Page, 1998. Ordenar la web por importancia y no por densidad de palabras clave. Es la distribución estacionaria de un grafo gigante.

RECOMENDACIÓN

PinSage de Pinterest

Red neuronal sobre grafos que usa caminatas aleatorias para decidir qué vecinos importan. Se entrenó sobre un grafo de 3 mil millones de nodos y 18 mil millones de aristas (Ying et al., 2018).

INTELIGENCIA ARTIFICIAL

Modelos de lenguaje

Zekri et al. (2024) muestran que un LLM autorregresivo con vocabulario T y ventana K equivale formalmente a una cadena de Markov sobre un espacio de estados enorme.

FINANZAS Y BIOLOGÍA

Regímenes y genes

Los HMM detectan regímenes de mercado a partir de retornos y, combinados con aprendizaje profundo, predicen genes en el ADN (AUGUSTUS, Tiberius).

La misma idea en todas: estados discretos, probabilidades de transición y la pregunta de qué pasa a largo plazo. De tres estados a miles de millones.

El clima en R

Verificando la pizarra con código

```
library(markovchain)

estados <- c("Soleado", "Nublado", "Lluvioso")
P <- matrix(c(0.7, 0.2, 0.1,
              0.3, 0.5, 0.2,
              0.2, 0.4, 0.4),
            nrow = 3, byrow = TRUE,
            dimnames = list(estados, estados))

mc_clima <- new("markovchain", states = estados,
               transitionMatrix = P, name = "Clima_CR")

# Distribucion estacionaria (resuelve  $\pi P = \pi$ )
steadyStates(mc_clima)
##      Soleado  Nublado  Lluvioso
## [1,] 0.4680851 0.3404255 0.1914894

is.irreducible(mc_clima) ## TRUE
period(mc_clima)        ## 1 (aperiodica)
```

22/47

0.4680851... es exactamente $\pi(S)$ de la pizarra

Un objeto, no una matriz


mc_clima guarda la matriz, los nombres de los estados y los métodos que la analizan.

Las condiciones, verificadas

is.irreducible() y period() confirman lo que razonamos con el diagrama.

Convergencia: P , P^2 , P^5 y P^{10}

Las filas se vuelven idénticas a π



```
library(expm)
round(P %^^ 10, 3)
# todas las filas ~ (0.468, 0.340, 0.191)
```

La fila S de P^2 es el (0.57, 0.28, 0.15) de la pizarra. En P^{10} ya no importa desde dónde se parte: eso es la distribución estacionaria vista como matriz.

Simulación: un año de clima

La frecuencia empírica debe acercarse a π


```
set.seed(2026)
dias <- markovchainSequence(n = 365,
  markovchain = mc_clima, t0 = "Soleado")

head(dias, 7)
## "Soleado" "Soleado" "Soleado" ...

round(table(dias) / length(dias), 3)
```

Lo que enseña

Con 365 días la frecuencia de nublados se desvía casi seis puntos de π ; con 10 000 días coincide a la milésima. Un año de datos todavía es una muestra ruidosa.



Es la ley de los grandes números para cadenas: la proporción de tiempo en cada estado converge a π . La semana 4 construye MCMC sobre esta idea.

PageRank: una idea de tesis doctoral

Stanford, 1996-1998

El problema en 1996

La web crecía exponencialmente y los buscadores ordenaban por frecuencia de palabras clave, algo fácil de manipular. La pregunta de Brin y Page: ¿se puede ordenar la web por importancia?

La idea recursiva

"Una página es importante si páginas importantes la enlazan."
Suen a circular, pero es exactamente buscar la distribución estacionaria de un navegante aleatorio.

El factor de amortiguación

$d = 0.85$: con esa probabilidad el navegante sigue un enlace; con 0.15 salta a una página al azar. Ese salto hace la cadena irreducible y aperiódica.

Año	Hito	Cifra clave
1998	Artículo en la WWW Conference y fundación de Google	24 millones de páginas; PageRank converge en unas 52 iteraciones
2001	Patente de PageRank otorgada a Stanford	Licencia exclusiva a Google a cambio de acciones

PageRank en R con igraph

Mini-web de seis páginas


```
library(igraph)

aristas <- c("A","B", "A","C", "B","C", "C","A",
            "D","A", "E","B", "E","D",
            "F","E", "F","B")
g <- graph_from_edgelist(
  matrix(aristas, ncol = 2, byrow = TRUE),
  directed = TRUE)

pr <- page_rank(g, damping = 0.85)$vector
round(sort(pr, decreasing = TRUE), 4)
##      A      C      B      D      E      F
## 0.3529 0.3456 0.2007 0.0401 0.0356 0.0250

# Personalizado: el salto siempre vuelve a A
reset <- ifelse(V(g)$name == "A", 1, 0)
round(page_rank(g, personalized = reset)$vector, 3)
##      A      B      C      D      E      F
## 0.452 0.192 0.356 0.000 0.000 0.000
```

Mini-web de seis páginas: tamaño del nodo = PageRank



Por qué C casi empata con A

C recibe enlaces de A y de B, y A le pasa la mitad de su importancia. F nadie la enlaza: solo vive del salto aleatorio.

Propagación en redes: SIR como proceso de Markov


El SIR de la semana 2, ahora persona por persona

La idea

Cada nodo está en S, I o R. En cada paso, un infectado contagia a cada vecino susceptible con probabilidad β y se recupera con probabilidad γ .

Por qué es Markov

El estado de la red en $t + 1$ depende solo del estado en t . El espacio de estados es 3^{100} para 100 personas: imposible de escribir como matriz, fácil de simular.



```
set.seed(42)
g_sw <- sample_smallworld(1, 100, 4, 0.05) # red de 100 nodos, 4 vecinos por lado
h <- sir_sim(g_sw, beta = 0.15, gamma = 0.05, T = 80) # funcion completa en el notebook
```

N-gramas: cadenas de Markov en el texto

El primer puente hacia los modelos de lenguaje

La idea

Un modelo bigrama supone que la siguiente palabra depende solo de la actual. Es una cadena de Markov donde cada estado es una palabra y la matriz tiene tamaño $|V| \times |V|$, con V el vocabulario.

Modelo	Estado	Orden	Limitación principal
Bigrama	Última palabra	1	Olvida todo lo anterior
Trigrama	Últimas 2 palabras	2	$ V ^2$ estados: explosión combinatoria
5-grama	Últimas 4 palabras	4	Intratable sin suavizado
Transformer (LLM)	Últimos K tokens	K	Memoria compacta por atención

Un n -grama es una cadena de Markov de orden $n - 1$. Un LLM es una de orden K , con K la ventana de contexto. La diferencia no es matemática, es de representación.

Generando texto con un bigrama

El Quijote como corpus de entrenamiento

```
library(stringr)
url <- "https://www.gutenberg.org/files/2000/2000-0.txt"
texto <- readLines(url, encoding = "UTF-8", warn = FALSE)
texto <- paste(texto, collapse = " ") |> tolower()
texto <- str_replace_all(texto, "[^\\p{L} ]", " ")
palabras <- str_split(texto, "\\s+")[1]
palabras <- palabras[palabras != ""]
ini <- which(palabras == "lugar")[1] - 2 # "en un lugar..."
palabras <- palabras[ini:(ini + 49999)]

# La "matriz" como lista: palabra -> palabras siguientes
pares <- data.frame(actual = head(palabras, -1),
                    siguiente = palabras[-1])
trans <- split(pares$siguiente, pares$actual)

set.seed(2026)
w <- "en"; frase <- w
for (k in 1:25) { w <- sample(trans[[w]], 1); frase <- c(frase, w) }
paste(frase, collapse = " ")
```

Resultado (semilla 2026)

*"en la más verdadero amor antigua tiranía de
caballería dígame vuestra merced dice parece
que yo de tal quedó de su rueda..."*

Qué observar

Los pares tienen sentido ("vuestra merced",
"de caballería"), la frase no. Después de
"sancho", el 17 % de las veces viene "panza":
eso es una fila de la matriz.

¿Los modelos de lenguaje son cadenas de Markov?

Matemáticamente sí; computacionalmente, no sirve escribirlos así

El resultado formal

Zekri et al. (2024, arXiv:2410.02724) muestran que un LLM autorregresivo con vocabulario de tamaño T y ventana de contexto K es equivalente a una cadena de Markov sobre un espacio de estados de tamaño del orden de T^K , con una matriz de transición muy dispersa.

$\sim 10^5$

Tokens en un vocabulario típico

10^5 a 10^6

Tokens de contexto en modelos recientes

T^K

Tamaño del espacio de estados

Qué aporta

Permite hablar de distribución estacionaria, de por qué a temperatura alta aparecen repeticiones y de cotas teóricas de generalización.

Qué no significa


Que el modelo guarde esa matriz. La red neuronal es una forma compacta de aproximarla; la equivalencia es analítica, no computacional.

HMM en R: detectando regímenes financieros

Datos sintéticos con dos regímenes de volatilidad

```
library(depmixS4)
set.seed(2026)
n <- 600
regimen <- c(rep(1, 250), rep(2, 150), rep(1, 200))
retornos <- ifelse(regimen == 1,
  rnorm(n, 0.001, 0.008), # calmo
  rnorm(n, -0.002, 0.025)) # volatil
mod <- depmix(retornos ~ 1,
  data = data.frame(retornos),
  nstates = 2, family = gaussian())
set.seed(2026)
ajuste <- fit(mod, verbose = FALSE)

est <- posterior(ajuste, type = "viterbi")$state
table(real = regimen, decodificado = est)
##      decodificado
## real      1      2
##      1 450    0
##      2   0 150
```



Lo que hizo el modelo

Nunca vio el régimen real, solo los retornos. Estimó las dos volatilidades (0.008 y 0.024) y una matriz de transición muy persistente (0.998 y 0.993), y Viterbi recuperó los 600 días. Con datos reales, los regímenes se mezclan y el acierto baja.

Caso costarricense: poblaciones con cadenas de Markov

Viquez, Viquez, Campos, Loría y Mendoza (UCR, 2018)

El problema

Proyectar la evolución de la población de un régimen de pensiones costarricense (activos, pensionados y sus transiciones) modelando cada persona con una cadena de Markov cuyos estados combinan situación, edad y tiempo cotizado.

Por qué importa

Es investigación de la UCR, publicada en una revista indexada y aplicada a un problema actuarial real con las mismas herramientas de hoy.

Idea para el proyecto

Un problema costarricense, datos accesibles y una cadena bien definida: migración entre estados de empleo, morosidad crediticia, uso de transporte.

Referencia (APA 7)

Viquez, J. J., Viquez, J. A., Campos, A., Loría, J., & Mendoza, L. A. (2018). Modelación de poblaciones vía cadenas de Markov tridimensionales. *Revista de Matemática: Teoría y Aplicaciones*, 25(2), 185-214.

Una sola idea, escalas muy distintas

La misma matemática del clima, de 3 estados a T^k

Sistema	Estados	Tamaño del espacio	Aplicación
Clima de hoy	S, N, L	3	Pronóstico simple
Cliente de un banco	Activo, Ocasional, Inactivo, Fuga	4	Retención de clientes
Epidemia en una red	S, I o R por persona	3^n	Propagación
Bigrama del Quijote	Cada palabra	$\approx 7\,000$	Texto simple
PageRank	Cada página web	Miles de millones	Búsqueda
LLM	Cada secuencia de K tokens	T^k	Asistentes de IA

Una matriz estocástica, las ecuaciones de Chapman-Kolmogorov y una distribución estacionaria. Lo que cambia es el tamaño del espacio de estados y la representación computacional para no quedarnos sin memoria.

Actividad grupal en salas

Los últimos 40 minutos de clase, con los grupos del proyecto

Cómo funciona

Cada grupo va a una sala virtual con un notebook de R compartido. Una parte a mano y tres en Colab, más la confirmación del tema del proyecto. No se entrega ni se califica; lo que no terminen queda como tarea moral.

1. A mano

Cliente de un banco con cuatro estados: diagrama, lectura de la matriz y distribución a dos meses.

2. R

La misma cadena en markovchain: estacionaria, clasificación y simulación de 1000 meses.

3. R

Una campaña de retención cambia una fila de P .
¿Cuánto cambia π ?

4. R

PageRank de un sitio web de trámites de siete páginas.
¿Qué pasa si se cambia d ?

Antes de salir de la sala: el grupo confirma su carril del proyecto integrador y me lo envía por correo hoy. No se repiten temas: el primero que lo envía, lo gana.

Síntesis de la sesión

Cada idea de hoy y dónde vuelve a aparecer

A mano	En la computadora	Vuelve en
Propiedad de Markov y matriz P	Objeto markovchain	Semana 14: procesos de decisión de Markov
$\pi_{t+1} = \pi_t P$ y potencias P^n	P^n y el heatmap de convergencia	Semana 6: series temporales
Distribución estacionaria	steadyStates() y la simulación de 10 000 días	Semana 4: MCMC
Irreducible y aperiódica	is.irreducible(), period() y el salto de PageRank	Semana 13: grafos
El monje en la cueva	depmixS4 y Viterbi	Presentación grupal 9: LLM y Markov

La pizarra nos dio el significado (qué es π y cuándo existe); la computadora, la escala (7000 palabras, 600 días, miles de millones de páginas).

Para la próxima semana

Clase 4 · jueves 1 de octubre · Monte Carlo y MCMC

Pendientes

- Resolver la tarea moral de los cuatro bloques.
- Terminar las miniexploraciones en R que quedaron abiertas.
- Enviar hoy el carril del proyecto integrador por correo.
- Leer en Murphy, Probabilistic Machine Learning (probml.github.io), la introducción a la inferencia bayesiana.

Tema 4: Monte Carlo y MCMC

- Simulación de Monte Carlo: muestreo, integración y riesgo.
- MCMC: construir una cadena de Markov cuya π sea la distribución que queremos muestrear.
- Metropolis-Hastings y Gibbs.
- Inferencia bayesiana con PyMC, de vuelta en Python.

Si la distribución estacionaria de hoy quedó clara, MCMC va a fluir: es la misma idea, al revés. En lugar de encontrar π de una cadena, diseñamos la cadena para una π dada.

Dudas: jordy.alfaro@ulead.ac.cr

Lo que se llevan de esta sesión

El futuro depende solo del presente

Una simplificación radical que alcanza para el clima, los clientes, las epidemias, la web y los modelos de lenguaje.

π es la huella del sistema

Dice cómo se ve el sistema a largo plazo sin importar dónde empezó, siempre que la cadena sea irreducible y aperiódica.

Lo oculto también se modela

Con dos matrices, P y B , se infiere lo que no se ve a partir de sus señales: del monje en la cueva a los regímenes del mercado.

Nos vemos el próximo jueves con Monte Carlo y MCMC.