

Simulación de Monte Carlo y MCMC

Semana 4: del dado al posterior, con Python

BCD5105 • Modelado matemático

Profesor: Jordy Alfaro Brenes

Lead University • III cuatrimestre 2026 • Modalidad virtual

Jueves 1 de octubre de 2026 • 4:00 a 7:00 p. m.

Ruta de la sesión

Dos mitades: primero a mano, después en Python

Al terminar la sesión usted podrá

- Explicar por qué tirar dados al azar sirve para calcular cosas que no son aleatorias.
- Estimar π , una integral y un VaR con un puñado de puntos, y saber cuánto confiar.
- Dar dos pasos de Metropolis-Hastings a mano y explicar por qué funciona.
- Actualizar una creencia con Bayes y leer un posterior.
- Hacer todo lo anterior en Python, con NumPy y con PyMC.

Bloques y tiempos estimados

1	Monte Carlo y la ley de los grandes números	15 min
2	Monte Carlo como promedio: integrales y VaR	15 min
3	MCMC: Metropolis-Hastings y Gibbs	20 min
4	Bayes a mano	20 min
	<i>Receso</i>	10 min
5	Python: π , integrales y riesgo cambiario	25 min
6	Python: Metropolis, NUTS y PyMC	35 min
7	Actividad en salas	40 min

Parte 1

Monte Carlo y MCMC, a mano

Trabajo conceptual en la pizarra: por qué el azar estima, cuánto se equivoca, cómo se muestrea lo que no sabemos dibujar y cómo se actualiza una creencia.

Hacer estadística con dados

La idea de Monte Carlo en una línea

$$(1/N) \cdot \sum f(X_i) \approx E[f(X)] \text{ para } N \text{ grande}$$

Esperanza

Ley de los grandes números

Más repeticiones, y el promedio se acerca cada vez más al valor esperado.
Es la garantía de que el método funciona.

Cualquier pregunta como promedio

Una probabilidad es el promedio de un "sí o no". Un área, una esperanza y un riesgo también se escriben como promedios.


Por qué "Monte Carlo"

Lo desarrollaron Ulam y von Neumann en Los Álamos a fines de los años cuarenta; Metropolis propuso el nombre por el casino de Mónaco.

Cuando la fórmula no existe o es intratable, generamos muchos números al azar y dejamos que la ley de los grandes números haga el trabajo.

Micro ejemplo: estimar π tirando puntos

Un cuadrado de lado 1 y un cuarto de círculo de radio 1



$$A_{\text{círculo}} = \pi \cdot r^2$$
$$\text{Cuarto} = \frac{\pi \cdot r^2}{4}$$

La idea

Tiramos puntos al azar en el cuadrado y contamos cuántos caen dentro del cuarto de círculo.

Lo construimos juntos

1. Área del cuarto de círculo

2. Fracción de puntos que debería caer dentro


3. Despejar π

4. 20 puntos, 16 dentro: $\pi \approx$

$$\frac{\pi \cdot r^2}{4} = \frac{\pi}{4}$$
$$\frac{\text{puntos dentro}}{\text{puntos totales}} = \frac{\pi/4}{1} = \frac{\pi}{4}$$
$$\frac{P.D.}{P.T.} = \frac{\pi}{4} \Rightarrow \pi = 4 \cdot \frac{P.D.}{P.F.}$$
$$\pi = 4 \cdot \frac{16}{20} = 3,2$$

El error baja como $1/\sqrt{N}$

Cuánto mejora la estimación al agregar puntos



Cómo se lee

Cada punto es el error típico de 200 estimaciones de π con N puntos. Los puntos caen sobre una recta de pendiente $-1/2$.

La regla práctica

Para reducir el error a la mitad hay que cuadruplicar N . Para ganar un decimal, multiplicar N por 100.

La buena noticia

La tasa $1/\sqrt{N}$ no depende de la dimensión del problema.

Ejemplos

Monte Carlo y la ley de los grandes números

Resolvemos juntos en la pizarra

Ejemplo 1

Se tiran 50 puntos en el cuadrado y 41 caen dentro del cuarto de círculo.

- a) Estime π .
- b) ¿Por qué se multiplica por 4?
- c) Con 50 puntos el error típico es ≈ 0.23 . ¿Cuántos puntos necesita para un error de ≈ 0.06 ?

Ejemplo 2

Se simularon 12 lanzamientos de dos dados y sus sumas fueron:

7, 5, 9, 7, 11, 6, 7, 8, 4, 7, 10, 3

- a) Estime $P(\text{suma} = 7)$.
- b) Compare con el valor exacto $6/36$.
- c) ¿Por qué difieren tanto? ¿Qué haría?



	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

Espacio de trabajo

Monte Carlo y la ley de los grandes números

Ejemplo 1

$$a) \pi \approx 4 \cdot \frac{\text{P.D.}}{\text{P.T.}} \approx 4 \cdot \frac{41}{50} \approx 3,28$$

b)

c) Ahorita 0.23 Queremos 0.06

$$\frac{1}{\sqrt{n}} \quad \frac{0,23}{0,06} \approx 3,83 \approx 4$$

$$R / 50 \cdot \overbrace{4 \cdot 4}^{16} = 800$$

6 7 8 9 10 11 12
Regla de oro: Para bajar el error a la mitad

hay que multiplicar por 4 la muestra

Ejemplo 2

7, 5, 9, 7, 11, 6, 7, 8, 4, 7, 10, 3

$$a) P(\text{suma}=7) = \frac{4}{12} \approx 0,33$$

$$b) \text{Valor real} = \frac{6}{36} = \frac{1}{6} \approx 0,16$$

c) 1200 lanzamientos

↓

Error: 0,011

Ejercicios

Monte Carlo y la ley de los grandes números

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Con 30 puntos, 25 caen dentro.

- a) Estime π .
- b) ¿La estimación es "mala" o es lo esperable con 30 puntos? Use la regla $1/\sqrt{N}$.

Ejercicio 2

Una encuesta estima una proporción con error típico de 5 puntos porcentuales.

¿Cuántas veces más grande debe ser la muestra para bajar a 1 punto?

Ejercicio 3

Describa paso a paso, sin calcular, cómo estimaría por simulación la probabilidad de que en un grupo de 23 personas dos cumplan años el mismo día.

Monte Carlo como promedio

Una integral es un promedio disfrazado

$$E[f(X)] \approx (1/N) \cdot \sum f(x_i)$$

$$\int_a^b f(x) dx \approx (b - a)/N \cdot \sum f(x_i)$$

Micro ejemplo: $\int_0^1 x^2 dx$ (valor real 1/3)

El azar nos dio cuatro puntos: 0.2, 0.4, 0.6 y 0.8.


0.2^2 0.04 0.4^2 0.16 0.6^2 0.36 0.8^2 0.64

Suma

1,2

Estimación $(b - a)/N \cdot \text{suma}$

$$\frac{1-0}{4} \cdot 1,2 = 0,3$$



Value at Risk: el percentil de las pérdidas

Monte Carlo como herramienta de riesgo


La pregunta del banco

¿Cuánto podría perder en los próximos 30 días en un mal escenario, pero no en el peor imaginable?

VaR 95 % = percentil 95 de las pérdidas

La receta

- Simular muchos escenarios del factor de riesgo.
- Calcular la pérdida en cada uno.
- Ordenar y leer el percentil: solo el 5 % de los escenarios es peor.




Ejemplos

Monte Carlo como promedio: integrales y VaR

Ejemplo 1

Estime $\int_0^2 x^2 dx$ (valor real $8/3 \approx 2.67$) con los puntos al azar 0.2, 0.7, 1.1 y 1.6.

- Evalúe f en cada punto.
- Aplique la fórmula con $b - a = 2$.
- ¿Por qué la estimación sale baja? ¿Qué haría?



Resolvemos juntos en la pizarra

Ejemplo 2

Una empresa simuló 20 escenarios de pérdida (en millones): 2.1, -0.5, 3.4, 1.2, 0.8, 5.9, -1.3, 2.7, 0.3, 4.1, 1.9, -0.2, 3.0, 7.8, 0.6, 2.2, 1.5, -0.9, 3.8, 1.1

- Encuentre el VaR 95 %.
- Calcule la pérdida promedio.
- ¿Por qué el banco mira el VaR y no el promedio?

Espacio de trabajo

Monte Carlo como promedio: integrales y VaR

Ejemplo 1

a)

x_i	0.2	0.7	1.1	1.6
x_i^2	0.04	0.49	1.21	2.56

b) $\frac{b-a}{n} \cdot \text{suma}$

$$= \frac{2}{4} \cdot 4,3$$

$$= 2,15$$

c) Más puntos.

Ejemplo 2

~~2.1, -0.5, 3.4, 1.2, 0.8, 5.9, -1.3, 2.7, 0.3, 4.1,~~
~~1.9, -0.2, 3, 7.8, 0.6, 2.2, 1.5, -0.9, 3.8, 1.1~~

a) -1.3, -0.9, -0.5, -0.2, 0.3,
0.6, 0.8, 1.1, 1.2, 1.5,
1.9, 2.1, 2.2, 2.7, 3,
3.4, 3.8, 4.1, 5.9, 7.8.

Lectura: Con 95% de confianza, la pérdida en el período no supera 5.9 millones

np.percentile(perdidas, 95)

b) $\frac{39.5}{20} \approx 1.98$ millones

Ejercicios

Monte Carlo como promedio: integrales y VaR

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Estime $\int_0^1 4/(1+x^2) dx$ con los puntos 0.1, 0.4, 0.6 y 0.9.

¿Qué número famoso aparece?

Ejercicio 2

Con los mismos 20 escenarios del ejemplo 2, ¿cuál sería el VaR 99 %?

¿Qué problema aparece y cómo se resuelve?

Ejercicio 3

Una obra tiene tres etapas de duración incierta.

Describa cómo estimaría por simulación la probabilidad de terminar en menos de 120 días.

¿Qué distribución le daría a cada etapa?

¿Y si no sé muestrear?

El problema que MCMC viene a resolver

El límite del Monte Carlo simple

Hasta ahora supusimos que sabemos generar puntos de la distribución: uniformes, normales. En inferencia bayesiana el posterior es una fórmula que solo conocemos salvo una constante, y casi nunca sabemos muestrear de ella directamente.

$$p(x) = c \cdot g(x) \quad \text{con } g(x) \text{ fácil de evaluar y } c \text{ desconocida}$$

La idea de MCMC

Construir una caminata (una cadena de Markov) que pase más tiempo donde $g(x)$ es grande, en la proporción exacta de la densidad.

El puente con la semana 3

La semana pasada: dada una cadena, encontrar su π . Hoy, al revés: dada una π (el posterior), diseñar la cadena. Markov Chain Monte Carlo.

Metropolis-Hastings

Proponer y aceptar o rechazar

$$\frac{e^{g(x')}}{e^{g(x)}} = r$$

1. Estar en x

La posición actual de la cadena.

2. Proponer x'

Un salto al azar cerca: $x' = x + \text{ruido}$.

3. Comparar

Razón $r = g(x') / g(x)$. La constante c se cancela.

4. Decidir

Sortear u entre 0 y 1. Si $u < r$, ir a x' ; si no, quedarse en x .

aceptar con probabilidad $\min(1, g(x') / g(x))$

Si x' es más probable


$r \geq 1$: se acepta siempre. La cadena sube hacia donde hay más densidad.

Si x' es menos probable

Se acepta a veces, con probabilidad r . Por eso la cadena también visita las colas, en la proporción correcta.

Micro ejemplo: dos pasos de Metropolis

Objetivo: $g(x) = e^{-(x^2/2)}$, una normal estándar sin normalizar



$$r = g(x') / g(x) = e^{-(x'^2 - x^2)/2}$$


	x	x'	r	u	Decisión
Paso 1	0	0.8	0.73	0.5	Acepto $u < r: x_1 = 0.8$
Paso 2	0.8	1.6	0.38	0.7	Rechazo $u > r: x_2 = 0.8$

Para pensar mientras calculamos

¿Qué pasa con x si la propuesta se rechaza? ¿Cuenta otra vez como muestra?

Gibbs: una variable a la vez

El otro clásico de MCMC



La idea

Con varios parámetros, en vez de saltar en todas las direcciones a la vez, se actualiza una variable fijando las demás. Como ajustar una perilla a la vez.

Cuándo conviene

Cuando las condicionales son conocidas y fáciles de muestrear. Es un caso de Metropolis-Hastings que acepta siempre.

Su debilidad

Con variables muy correlacionadas avanza en escalones cortos y tarda en recorrer la distribución.

Ejemplos

MCMC: Metropolis-Hastings

Resolvemos juntos en la pizarra

Ejemplo 1

Mismo objetivo $g(x) = e^{(-x^2/2)}$, arrancando en $x_0 = 1$.

Paso 1: $x' = 0.4$, $u = 0.9$

Paso 2: $x' = 1.9$, $u = 0.15$

Paso 3: $x' = 2.6$, $u = 0.5$

a) Complete los tres pasos.

b) ¿Por qué el paso 1 se acepta sin importar u ?

Ejemplo 2

Sin calcular, razone:

a) Si los saltos propuestos son diminutos, ¿cómo será la tasa de aceptación? ¿Y la exploración?


b) ¿Y si son enormes?

c) ¿Por qué no importa que no conozcamos la constante c ?


Espacio de trabajo

MCMC: Metropolis-Hastings

Ejemplo 1



Ejemplo 2



Ejercicios

MCMC: Metropolis-Hastings

Tarea moral · resuélvalos durante la semana

Ejercicio 1

Objetivo $g(x) = e^{(-|x|)}$, con $x_0 = 0$.

Paso 1: $x' = 0.5$, $u = 0.4$

Paso 2: $x' = 1.5$, $u = 0.3$

Paso 3: $x' = 0.2$, $u = 0.9$

Complete los tres pasos.

Ejercicio 2

¿En qué sentido la secuencia $x_0, x_1, x_2, \dots$ es una cadena de Markov?

¿Cuál es su distribución estacionaria?

Ejercicio 3

Explique con un dibujo por qué Gibbs avanza "en escalera".

¿Qué pasaría con la escalera si las dos variables fueran independientes?

Bayes: actualizar creencias con datos

Lo que creo antes, más lo que veo, da lo que creo después

$$\text{posterior} \propto \text{prior} \times \text{verosimilitud}$$

Prior

Lo que creo del parámetro antes de ver los datos.


Verosimilitud

Qué tan compatibles son los datos con cada valor.

Posterior

Mi creencia **actualizada**. Es una distribución completa, no un número. Mañana será el prior de los datos nuevos.

Misma proporción observada (36 %), más datos




Micro ejemplo: una prueba diagnóstica

Prevalencia 1 %, sensibilidad 99 %, falsos positivos 5 %

Datos: $P(E) = 0.01$
 $P(\neg E) = 0.99$
Sensibilidad = $P(+|E) = 0.99$

$P(+|\neg E) = 0.05$

Falsos positivos



$$P(E | +) = P(+|E) \cdot P(E) / [P(+|E) \cdot P(E) + P(+|\neg E) \cdot P(\neg E)]$$

Positivos: 594

Una persona da positivo

¿Qué probabilidad hay de que esté enferma?

$$P(E | +) = \frac{99}{594} \approx 0.17$$

Antes de calcular, su apuesta:

Con el árbol o con la fórmula:

0.17.

¿Se parecen? ¿Qué pesó más de lo que esperaba?

Ejemplos

Bayes a mano

Resolvemos juntos en la pizarra

Ejemplo 1

La misma prueba (sensibilidad 0.99, falsos positivos 0.05):

- a) Si la prevalencia fuera 10 %, ¿cuánto vale $P(E | +)$?
- b) Con prevalencia 1 %, la persona se repite la prueba y vuelve a salir positiva. Use 1/6 como nuevo prior.
- c) ¿Qué enseña b) sobre los segundos exámenes?

Ejemplo 2

La proporción θ de clientes que compran solo puede ser 0.2, 0.4 o 0.6, con prior uniforme.


De 3 clientes, 2 compraron. La verosimilitud es $3\theta^2(1 - \theta)$.

- a) Calcule prior $\times$ verosimilitud.
- b) Normalice para obtener el posterior.
- c) ¿Qué valor de θ ganó y por qué no es el 100 %?


Espacio de trabajo

Bayes a mano

Ejemplo 1



Ejemplo 2



Ejercicios

Bayes a mano

Tarea moral · resuélvalos durante la semana

Ejercicio 1

El 0.5 % de las transacciones son fraude.

La alarma detecta el 95 % de los fraudes y da falsa alarma en el 2 % de las transacciones legítimas.

Suena la alarma: ¿probabilidad de fraude?

Ejercicio 2

θ puede ser 0.1, 0.3 o 0.5, con prior (0.5, 0.3, 0.2).

De 4 intentos hubo 1 éxito; la verosimilitud es $4\theta(1 - \theta)^3$.

Calcule el posterior.

Ejercicio 3

Para el problema de su proyecto, identifique un parámetro desconocido, un prior razonable y qué datos actualizarían esa creencia.

Parte 2

Monte Carlo y MCMC en Python

Correr a millones de muestras lo que hicimos con cuatro puntos, estimar riesgo cambiario y hacer inferencia bayesiana con PyMC.

Volvemos a Python

El stack de la semana, vigente a octubre de 2026

NumPy y SciPy

Monte Carlo clásico. Generador moderno default_rng y las distribuciones de scipy.stats.

PyMC 6

Inferencia bayesiana. Desde la versión 6 (mayo de 2026) usa Numba como motor por defecto.

nutpie

Implementación rápida de NUTS. Si está instalada, PyMC 6 la usa por defecto.

ArviZ 1.0

Diagnóstico y resumen del muestreo. Ahora reporta intervalos de 89 % de colas iguales (ETI) por defecto.

Bambi

Modelos bayesianos con fórmulas estilo R, sobre PyMC. Lo usaremos la próxima semana en regresión.

```
# Celda 1 del notebook (una vez por sesion de Colab)
!pip install -q "pymc>=6" nutpie
import numpy as np, pymc as pm, arviz as az, matplotlib.pyplot as plt
```

¿Para qué sirve Monte Carlo hoy?

Cuatro usos que mueven decisiones reales

FINANZAS

Value at Risk

Bancos y empresas simulan miles de escenarios del mercado para medir cuánto podrían perder. Monte Carlo permite combinar varios factores de riesgo.

GESTIÓN DE PROYECTOS

Costos y plazos

Se da una distribución a cada costo o duración incierta y se simula el proyecto completo: probabilidad de pasarse del presupuesto o de la fecha.

CIENCIA E INGENIERÍA

Integrales en muchas dimensiones

Una cuadrícula con 10 puntos por eje necesita 10^d evaluaciones; Monte Carlo mantiene su error $1/\sqrt{N}$ en cualquier dimensión.

ESTADÍSTICA E IA

Inferencia bayesiana

MCMC muestrea posteriores que solo conocemos salvo una constante. Es el corazón de PyMC y Stan.

Todo se reduce a la misma idea: muchas muestras al azar y un promedio.

El generador aleatorio moderno

default_rng, no np.random.seed

```
import numpy as np

# Forma recomendada: un generador explícito (PCG64)
rng = np.random.default_rng(2026)

rng.normal(0, 1, size=3)      # 3 normales estándar
## array([-0.793,  0.241, -1.896])

rng.integers(1, 7, size=5)    # 5 tiradas de un dado
## array([1, 3, 4, 3, 5])

# Forma legada (evitar): np.random.seed(2026)
```

Por qué importa

La documentación de NumPy recomienda default_rng sobre el RandomState legado: mejores propiedades estadísticas y más velocidad.

Buena práctica

Pasar el objeto rng a las funciones en vez de fijar una semilla global. El código queda reproducible.

En este curso la semilla es siempre 2026: si su salida no coincide con la de la lámina, revise que creó el generador una sola vez y en el mismo orden.

Estimar π con 100 000 puntos

Lo que hicimos con 20 puntos, ahora a escala

```
rng = np.random.default_rng(2026)
N = 100_000


# puntos al azar en el cuadrado [0,1] x [0,1]
pts = rng.random((N, 2))

# ¿caen dentro del cuarto de círculo?
dentro = (pts[:, 0]**2 + pts[:, 1]**2) <= 1

pi_est = 4 * dentro.mean()
print(f"pi estimado: {pi_est:.5f}")
## pi estimado: 3.14704
```

Lectura honesta

Error de 0.0054, justo lo que predice $1.64/\sqrt{N} \approx 0.0052$. Monte Carlo promete un error controlado, no decimales.



Qué muestra la curva

Al principio la estimación salta mucho; conforme crece N se asienta dentro de la banda, que se estrecha como $1/\sqrt{N}$.

Integración por Monte Carlo

De cuatro puntos a cien mil

```
# Estimar la integral de  $x^2$  entre 0 y 1 (real = 1/3)
rng = np.random.default_rng(2026)
x = rng.random(100_000) # uniformes en [0, 1]

integral = (x**2).mean() # (b - a) = 1
print(f"integral: {integral:.4f}")
## 0.3317
```

0.30

4 puntos (a mano)

0.3317

100 000 puntos

Valor real: 0.3333. El error baja de 0.033 a 0.0016.

Cuándo se usa de verdad


Nunca para x^2 : esa la integra cualquiera. Se usa para integrales de 10, 100 o 1000 dimensiones, como las esperanzas de un posterior bayesiano.

La maldición de la dimensión

Una cuadrícula de 10 puntos por eje en 20 dimensiones necesita 10^{20} evaluaciones. Monte Carlo con 10^6 puntos ya da un error de milésimas.

Caso Costa Rica: riesgo cambiario

Un importador debe pagar US\$100 000 dentro de 30 días hábiles



```
tc_hoy, sigma = 458.43, 0.004 # BCCR 30/09/2026; volatilidad supuesta
r = rng.normal(0, sigma, size=(10_000, 30))
tc30 = tc_hoy * np.exp(r.sum(axis=1))
np.percentile(tc30, 95)
## 475.33
```

El VaR en colones

Costo hoy: ₡45.84 millones

Costo en el escenario 95 %: ₡47.53 millones

VaR 95 % ≈ ₡1.69 millones


Los supuestos, a la vista

Tipo de cambio de referencia de venta del BCCR al 30 de setiembre. La volatilidad diaria de 0.4 % es un supuesto: en el proyecto se calibra con la serie histórica del BCCR.

Metropolis-Hastings en código

Lo que hicimos a mano, automatizado: el tamaño del paso lo es todo

```
def metropolis(log_g, x0, pasos, paso, rng):  
    x = x0  
    muestras = np.empty(pasos)  
    for t in range(pasos):  
        xp = x + rng.normal(0, paso)  
        # en log: la constante c  
        # desaparece en la resta  
        a = log_g(xp) - log_g(x)  
        if np.log(rng.random()) < a:  
            x = xp          # acepto  
        muestras[t] = x  
    return muestras  
  
rng = np.random.default_rng(2026)  
m = metropolis(lambda x: -x**2 / 2,  
               0.0, 5000, 2.5, rng)
```



Paso 0.1: acepta casi todo pero avanza lento. Paso 10: casi todo se rechaza. Paso 2.5: buen balance, y el histograma recupera la campana.

Verificar a Bayes con un millón de personas

Monte Carlo también comprueba cuentas a mano

```
rng = np.random.default_rng(2026)
n = 1_000_000
enfermo = rng.random(n) < 0.01
positivo = np.where(enfermo,
                    rng.random(n) < 0.99, # sensibilidad
                    rng.random(n) < 0.05) # falsos positivos

enfermo[positivo].mean()
## 0.1667
```

0.1667

Fracción de enfermos entre los 59 268 positivos simulados

1/6

El resultado exacto que calculamos a mano

Simular la población entera y contar es Bayes sin fórmula. Cuando el modelo se complica (varias pruebas, prevalencia incierta), esta forma de pensar sigue funcionando y la fórmula no.

Lo que domina hoy: HMC y NUTS

Fluir en vez de caminar al azar

Hamiltonian Monte Carlo

Trata el parámetro como una partícula que se desliza por la superficie del menos log-posterior y usa el gradiente para proponer saltos largos que casi siempre se aceptan.

NUTS (No-U-Turn Sampler)

Hoffman y Gelman (2014) eliminan el ajuste manual de la trayectoria: se detiene sola cuando empieza a devolverse. Es el muestreador por defecto de PyMC y Stan.

Método	Cuándo conviene	Debilidad
Metropolis-Hastings	Solo se puede evaluar la densidad	Hay que afinar el paso; camina al azar
Gibbs	Condicionales conocidas y fáciles	Lento con variables correlacionadas
HMC / NUTS	Parámetros continuos con gradiente	No maneja parámetros discretos directamente

PyMC: la sintaxis mínima

18 de 50 hogares tienen cierto atributo. ¿Qué proporción θ hay en la población?

```
import pymc as pm, arviz as az

n, k = 50, 18
with pm.Model() as modelo:
    # prior: lo que creo antes de ver datos
    theta = pm.Beta("theta", alpha=1, beta=1)
    # verosimilitud: los datos observados
    y = pm.Binomial("y", n=n, p=theta, observed=k)
    # inferencia: NUTS automatico
    idata = pm.sample(1000, tune=1000, chains=4,
                      random_seed=2026)

az.summary(idata)
##          mean      sd eti89_lb eti89_ub ess_bulk r_hat
## theta    0.363   0.066      0.26    0.47     1702  1.00
```

El patrón de siempre

with pm.Model(), declarar priors, declarar la verosimilitud con observed= y llamar pm.sample().

Verificado con PyMC 6.3


y ArviZ 1.3, muestreando con nutpie. Cuatro cadenas, 4000 muestras.

Comprobación exacta

Este modelo tiene solución cerrada: Beta(19, 33), media 0.365. MCMC coincide.

Leer el posterior

El resultado no es un número: es una distribución de valores plausibles



Lo que dice

θ está cerca de 0.36, y con 89 % de probabilidad entre 0.26 y 0.47.

Una pregunta directa



¿Probabilidad de que θ supere 0.5? Basta contar muestras: 2.3 % (exacto: 2.4 %).

Prior plano

Beta(1, 1) dice "cualquier θ es igual de creíble". Los datos hacen el resto.

Diagnóstico: ¿confiamos en el muestreo?

Cuatro cadenas del mismo Metropolis, arrancando en -4 , -1.5 , 1.5 y 4



$R\text{-hat} \leq 1.01$

Compara la variación entre cadenas y dentro de ellas. Lejos de 1: no convergieron.

$ESS \text{ alto } (> 400)$

Muestras efectivas: cuántas muestras independientes valen las que tenemos.

Trazas "peludas"

Cadenas superpuestas y sin tendencia. Si se ven separadas, no reporte nada.

Credibilidad vs. confianza

El punto de oro del tema

Intervalo de credibilidad (bayesiano)

"Dados los datos y el prior, hay 89 % de probabilidad de que θ esté entre 0.26 y 0.47." Es una afirmación directa sobre el parámetro.

Intervalo de confianza (frecuentista)

"Si repitiéramos el muestreo muchas veces, el 95 % de los intervalos contruidos así contendría el valor real." No es una probabilidad sobre este intervalo.

El gancho

La lectura intuitiva que casi todo el mundo le da al intervalo de confianza es, en realidad, la del intervalo de credibilidad. Quien dice "hay 95 % de probabilidad de que esté aquí" está hablando como bayesiano sin saberlo.

¿Por qué 89 % y no 95 %? ArviZ 1.0 lo cambió para recordar que ningún nivel es sagrado: es una convención, no una ley.

Caso Costa Rica: dengue bayesiano

UCR y colaboradores, 2023

El estudio

Chou-Chen, Barboza, Vásquez, García, Calvo, Hidalgo y Sánchez modelaron los casos de dengue de 32 cantones entre 2000 y 2021 con un modelo bayesiano espacio-temporal de conteo (binomial negativa), usando lluvia, temperatura de superficie, vegetación y los índices climáticos ENSO y TNA con rezagos.

Lo bayesiano

Cada cantón tiene su propio riesgo, pero "toma prestada" información de sus vecinos. El resultado es un riesgo con incertidumbre, no un número suelto.

Un matiz importante

No usaron MCMC sino INLA, una aproximación determinista mucho más rápida para este tipo de modelos. Bayes no es sinónimo de MCMC.

Referencia (APA 7)

Chou-Chen, S.-W., Barboza, L. A., Vásquez, P., García, Y. E., Calvo, J. G., Hidalgo, H. G., & Sánchez, F. (2023). Bayesian spatio-temporal model with INLA for dengue fever risk prediction in Costa Rica. *Environmental and Ecological Statistics*, 30(4), 687-713. <https://doi.org/10.1007/s10651-023-00580-9>

Actividad grupal en salas

Los últimos 40 minutos de clase, con los grupos del proyecto

Cómo funciona

Cada grupo va a una sala virtual con un notebook de Colab compartido. Una parte a mano y tres en Python. No se entrega ni se califica; lo que no terminen queda como tarea moral.

1. A mano

Un VaR con 20 escenarios, dos pasos de Metropolis y un Bayes de morosidad.

2. Python

Riesgo de plazo de una obra: probabilidad de pasarse de 120 días y percentil 90.

3. Python

Metropolis propio para la tasa de morosidad, comparado con la solución exacta.

4. PyMC

El mismo modelo en PyMC: diagnóstico, intervalo y efecto del prior.

Al cerrar, cada grupo piensa qué parte de su carril del proyecto tiene incertidumbre que valdría la pena simular.

Síntesis de la sesión

Cada idea de hoy y dónde vuelve a aparecer

A mano	En la computadora	Vuelve en
π con 20 puntos y el error $1/\sqrt{N}$	100 000 puntos y la banda de error	Todo el curso: cualquier simulación
Integral con 4 puntos y VaR con 20 escenarios	Integral y VaR del colón-dólar con 10 000	Proyecto: carriles de riesgo
Dos pasos de Metropolis	Metropolis con 5000 pasos y tres tamaños de paso	Semana 12: recocido simulado
Bayes de la prueba diagnóstica	Un millón de personas simuladas	Semana 14: bandidos y muestreo de Thompson
Prior $\times$ verosimilitud	PyMC, NUTS y ArviZ	Semana 5: Ridge y Lasso como priors

Todo arranca en la misma intuición: generar muestras al azar y promediar. Lo único que cambia es qué tan inteligente es la forma de generarlas.

Para la próxima semana

Clase 5 · jueves 8 de octubre · Regresión clásica y regularizada

Pendientes

- Resolver la tarea moral de los cuatro bloques.
- Terminar las partes de la actividad que quedaron abiertas.
- Repasar mínimos cuadrados y la idea de sobreajuste.
- Leer en Murphy, Probabilistic Machine Learning (probml.github.io), la introducción a la regresión lineal.

Tema 5: regresión

- Mínimos cuadrados ordinarios con scikit-learn.
- Regularización: Ridge, Lasso y Elastic Net.
- Validación cruzada y selección de modelos.
- Regresión bayesiana con PyMC y Bambi.

Si la idea de prior quedó clara hoy, la semana 5 va a fluir: Ridge y Lasso equivalen a poner un prior sobre los coeficientes.

Dudas: jordy.alfaro@ulead.ac.cr

Lo que se llevan de esta sesión

El azar calcula

Muchas muestras y un promedio estiman π , integrales y riesgos. El error baja como $1/\sqrt{N}$, en cualquier dimensión.

MCMC muestrea lo que no sabemos dibujar

Una cadena de Markov diseñada para que su π sea el posterior. Metropolis es la idea; NUTS, la herramienta.

Bayes actualiza creencias

Prior $\times$ verosimilitud da un posterior: una distribución completa, que responde directamente lo que queremos preguntar.

Nos vemos el próximo jueves con regresión clásica y regularizada.