LEAD UNIVERSITY

Series temporales modernas

Semana 7: Prophet, NeuralProphet y modelos de fundación, en Python

BCD5105 · Modelado matemático

Profesor: Jordy Alfaro Brenes

Lead University · III cuatrimestre 2026 · Modalidad virtual

Jueves 22 de octubre de 2026 · 4:00 a 7:00 p. m.

Un formato nuevo para la clase

Lo pidieron ustedes: menos escuchar, más hacer

4:00 a 5:30	5:30 a 6:00	6:00 a 7:00
Clase	**Receso**	**Práctica**
90 minutos: ideas y demostración en Python	30 minutos	60 minutos en salas, con su grupo

En la clase

Lo esencial de cada tema y el código corriendo en vivo. Sin pausas largas de lectura.

En la práctica

Cada grupo trabaja la actividad de la semana en su sala: una parte a mano y otra en Colab. El profesor rota entre salas.

Lo que no terminen

Queda como tarea moral. No se entrega ni se califica, pero entra en la prueba parcial y sirve para el proyecto.

LEAD

Ruta de la sesión

Del modelo aditivo a los modelos de fundación

Al terminar la sesión usted podrá

- Distinguir un modelo local de uno global.
- Leer un modelo aditivo tipo Prophet: tendencia, estacionalidad y festivos.
- Explicar qué es un modelo de fundación y qué significa zero-shot.
- Ajustar Prophet y Chronos-2 en Python e interpretar su salida.
- Comparar modelos con MASE en varias ventanas y elegir con criterio.

Bloques y tiempos estimados

1	Local contra global	10 min
2	Prophet: descomponer es la idea	20 min
3	Modelos de fundación y MASE	20 min
4	Python: Prophet y Chronos-2	25 min
5	¿Quién gana? Cuándo usar cada uno	15 min
	Receso	30 min
6	Práctica en salas	60 min

LEAD

LEAD UNIVERSITY

Parte 1

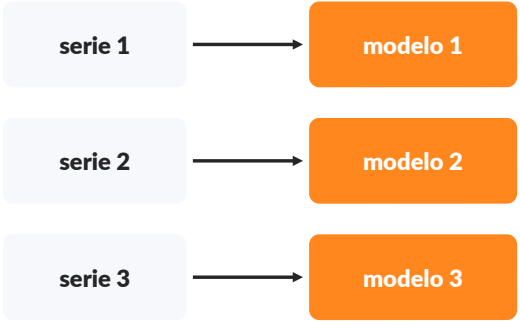
Las ideas

Qué cambió en el pronóstico moderno, cómo piensa Prophet y qué hace un modelo de fundación. Conceptos, no fórmulas pesadas.

El cambio de paradigma: local contra global

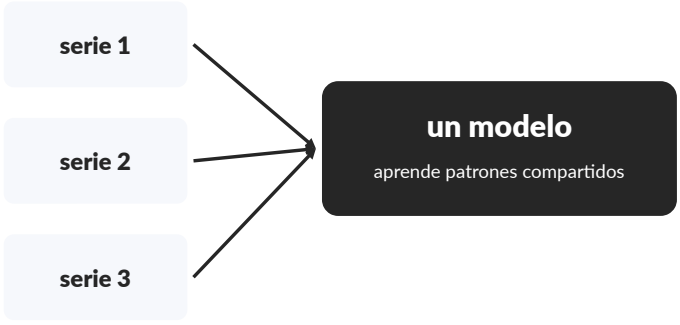
Por qué la industria dejó de ajustar un modelo por serie

Local: un modelo por serie



100 000 series → 100 000 modelos

Global: un modelo, muchas series



lo que aprende de una serie ayuda a las demás

ARIMA, ETS y Prophet son locales. LightGBM con lags, las redes profundas y los modelos de fundación son globales.

LEAD

El mapa de los modelos modernos

Cuatro familias que conviven en 2026

Aditivos

Prophet, NeuralProphet

Separan tendencia, estacionalidad y festivos. Interpretables. Hoy son línea base, no campeones.

Gradient boosting

LightGBM, XGBoost

Con variables de calendario y rezagos. Ganaron la competencia M5. El caballo de batalla de la industria.

Aprendizaje profundo

N-HiTS, TFT, DeepAR

Potentes, pero piden muchos datos y cómputo.

Modelos de fundación

Chronos-2, TimesFM, Toto

Preentrenados a gran escala: pronostican series que nunca vieron. La frontera de hoy.

El hilo conductor: del SARIMA de la semana pasada al modelo de fundación más nuevo, todos intentan separar tendencia, estacionalidad y resto. Cambia cómo estiman cada parte y de cuántas series aprenden.

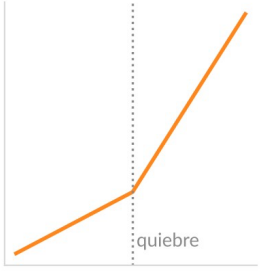
LEAD

Prophet: descomponer es la idea

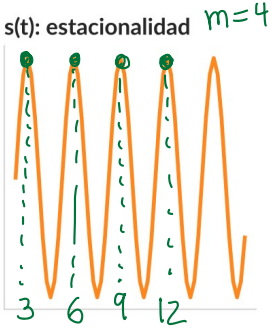
Un modelo aditivo interpretable, pariente del STL

$$\hat{y}(t) = g(t) + s(t) + h(t) + \varepsilon(t)$$

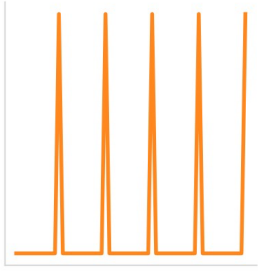
g(t): tendencia por tramos



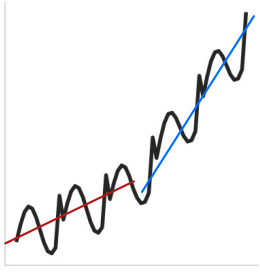
s(t): estacionalidad



h(t): festivos



ŷ(t) = suma



g(t)

Recta por tramos: cambia de pendiente en los quiebres.

s(t)

Ondas de Fourier (senos y cosenos) que se repiten.

h(t)

Picos en fechas especiales: feriados, Semana Santa.

ε(t)

Lo que sobra: debe parecer ruido.

LEAD

Micro ejemplo: armar el pronóstico a mano

Tendencia por tramos más estacionalidad trimestral

m = 4 m = 2 m = 12 m = 1

La tendencia g(t)

Si t ≤ 4: g(t) = 50 + 2t

Si t > 4: g(t) = 58 + 5(t − 4)

El quiebre está en t = 4.

La estacionalidad s(t)

T1: +6 T2: −2 T3: −8 T4: +4 = +6 −2 −8 +4 = 0

Preguntas

- ¿Cuánto crece por trimestre antes y después del quiebre?
- ¿Por qué las cuatro s(t) suman cero?

t	Trim.	g(t)	s(t)	ŷ(t)
1	T1	50+2·1 = 52	+6	58
2	T2	50+2·2 = 54	−2	52
3	T3	50+2·3 = 56	−8	48
4	T4	50+2·4 = 58	+4	62
5	T1	58+5(5−4) = 63	+6	69
6	T2	58+5(6−4) = 68	−2	66
7	T3	58+5(7−4) = 73	−8	65
8	T4	58+5(8−4) = 78	+4	82

Año 1 → Año 2

LEAD

Modelos de fundación: pronosticar sin entrenar

Preentrenar una vez, aplicar mil veces



Zero-shot

Se le pasa la historia de la serie como contexto y pronostica, sin ajustar ningún parámetro con nuestros datos.

Es la misma idea de un LLM: predice el siguiente valor como GPT predice la siguiente palabra.

La conexión con el curso

Un LLM se puede ver como una cadena de Markov enorme (semana 3).

El Chronos original convertía los valores en fichas (tokens) y trataba la serie como un idioma.

Igual que todos, se juzga con MASE contra el ingenuo.

LEAD

El árbitro no cambia: MASE

Repaso de la semana 6, ahora para comparar familias distintas

MASE = error medio del modelo ÷ error medio del ingenuo estacional en el entrenamiento

MASE < 1

El modelo le gana al ingenuo. Es la condición mínima para que valga la pena.

MASE ≈ 1

Empata con repetir el año anterior. Toda la sofisticación no aportó.

MASE > 1

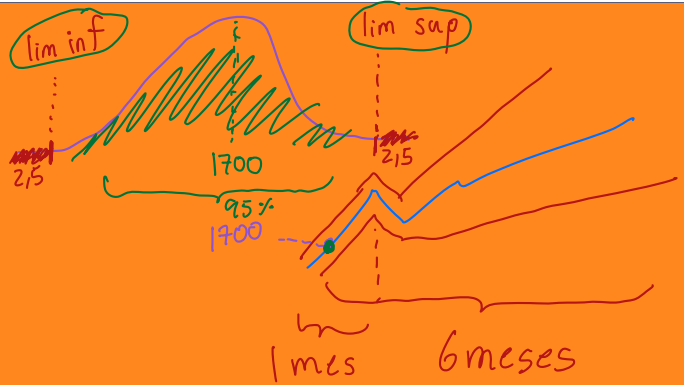
Peor que el ingenuo. Pasa más seguido de lo que parece.

No tiene unidades: sirve igual para turistas, colones o casos de dengue. Por eso es la métrica de los benchmarks como GIFT-Eval y la que vamos a usar para comparar Prophet, Chronos-2 y los clásicos.

LEAD

LEAD UNIVERSITY

Ejemplos



Resolvemos juntos en la pizarra

Las ideas

Ejemplo 1

Ventas trimestrales de entrenamiento: 20, 30, 25, 35, 24, 34, 29, 39. Valores reales de prueba: 28, 38, 33, 43.

Modelo A: 27, 39, 32, 41. Modelo B: 30, 37, 35, 42.

a) Calcule la escala /error del ingenuo estacional en el entrenamiento).

b) Calcule el MASE de A, de B y del ingenuo. ¿Cuál elige? Modelo A.

Ejemplo 2

Elija el enfoque y justifique en una frase:

a) Una tienda nueva con dos meses de ventas.

b) 30 000 productos de un supermercado, con promociones y feriados.

c) Una serie mensual de 10 años y un gerente que pide entender el pronóstico.

d) El tipo de cambio diario, casi sin estacionalidad.

Promedio de tiendas similares. / No hay historia para estimar / Modelo Fundación Zero-shot Chronos-2

Modelo global Light GBM

Piezas legibles → Tendencia, estacionalidad → Prophet / ETS, ARIMA (Auto.)

Parecido Caminata aleatoria, la sofisticación casi nunca importa

Empezar el ingenuo

Cualquier modelo deseable a usar lo debe Superar

Espacio de trabajo

Las ideas

Ejemplo 1

a) $m = 4$

T1	20
T2	30
T3	25
T4	35
T1	24
T2	34
T3	29
T4	39

$|24-20| = 4$

$|34-30| = 4$

$|29-25| = 4$

$|39-35| = 4$

Escalaes 4.

V.R.P: 28, 38, 33, 43

b) MASE

Modelo	Pronóstico	E.A	E.M	MASE
A	27, 39, 32, 41	1, 1, 1, 2	1.25	$\frac{1.25}{4} = 0.3125$ ✓
B	30, 37, 35, 42	2, 1, 2, 1	1.5	$\frac{1.5}{4} = 0.375$
Ingenuo	24, 34, 29, 39	4, 4, 4, 4	4	$\frac{4}{4} = 1$

Ejemplo 2



LEAD

LEAD UNIVERSITY

Ejercicios

Tarea moral · resuélvalos durante la semana

Las ideas

Ejercicio 1

Tendencia g(t) = 100 + 3t hasta t = 6 y pendiente 1 después. Estacionalidad trimestral +10, 0, −15, +5.

Calcule $\hat{y}(t)$ para t = 5, …, 10.

Ejercicio 2

Un modelo tiene MASE 1.15 en la prueba.

a) ¿Qué significa?

b) ¿Qué haría antes de descartarlo?

Ejercicio 3

Explique con sus palabras la diferencia entre un modelo local, uno global y uno de fundación.

Dé un ejemplo costarricense donde convenga cada uno.

LEAD UNIVERSITY

Parte 2

Series modernas en Python

La misma serie de turismo de la semana pasada, ahora con Prophet y Chronos-2. Todo el código corre en Colab con el kernel de Python.

El stack de Python a octubre de 2026

Qué está vivo, qué está congelado y qué está estancado

Librería	Versión	Estado	Para qué
prophet	1.5.0	Mantenido, sin cambios grandes	Línea base aditiva interpretable
neuralprophet	0.9.0 (2024)	Estancado	Puente conceptual a lo neuronal
chronos-forecasting	2.3.2	Muy activo	Chronos-2, sin entrenar
statsforecast (Nixtla)	2.1.1	Muy activo	AutoARIMA y AutoETS rapidísimos
mlforecast (Nixtla)	—	Activo	LightGBM con rezagos
autogluon.timeseries	1.6.3	Muy activo	Combina todo lo anterior

```
!pip install -q prophet chronos-forecasting statsforecast   # Colab ya trae pandas y matplotlib
```

Versiones verificadas en PyPI el 22 de octubre de 2026.

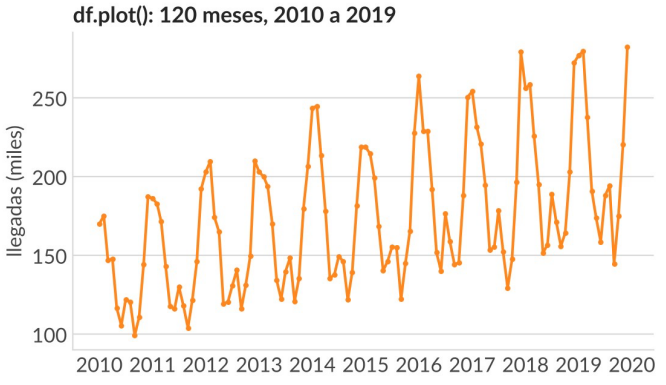
LEAD

La serie de hoy: turismo, ahora en Python

Mismo diseño que la semana 6, con numpy y semilla 2026

```
import numpy as np, pandas as pd
rng = np.random.default_rng(2026)
n = 120
t = np.arange(1, n + 1)
# tendencia + estacionalidad multiplicativa
tendencia = 130000 + 650 * t
patron = np.array([1.35, 1.32, 1.22, 1.05, 0.85, 0.80,
                   0.92, 0.88, 0.74, 0.82, 1.02, 1.33])
estacional = patron[(t - 1) % 12]
ruido = rng.normal(0, 0.045, n)
llegadas = np.round(tendencia * estacional * (1 + ruido))

# Prophet exige columnas ds (fecha) y y (valor)
df = pd.DataFrame({
    "ds": pd.date_range("2010-01-01", periods=n, freq="MS"),
    "y": llegadas})
df.plot(x="ds", y="y")
```



Conocemos la verdad: +650 turistas por mes y un patrón fijo con pico en enero y valle en setiembre. Así podemos ver si cada modelo la recupera.

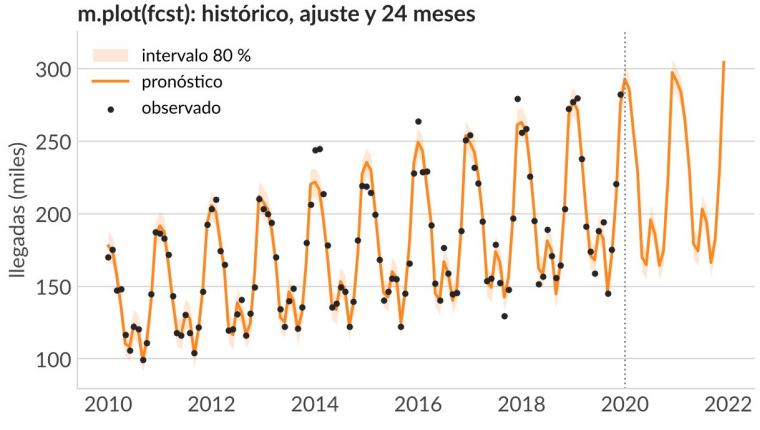
Prophet en cinco líneas

fit, predict y plot

```
from prophet import Prophet

m = Prophet(yearly_seasonality=True,
            seasonality_mode="multiplicative",
            changepoint_prior_scale=0.05)
m.fit(df)

futuro = m.make_future_dataframe(
    periods=24, freq="MS")
fcst = m.predict(futuro)
fig = m.plot(fcst)
```



multiplicative

La oscilación crece con el nivel, como en el turismo.

changepoint_prior_scale

Cuánto puede doblarse la tendencia. Más alto: más flexible y más riesgo de sobreajuste.

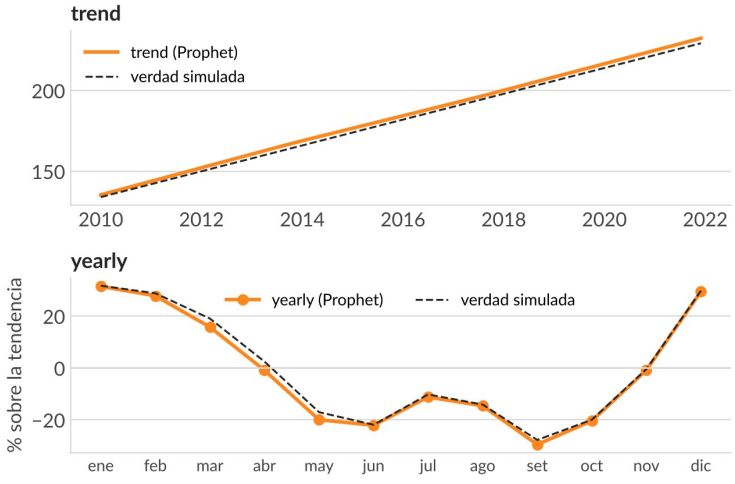
LEAD

plot_components: la receta por dentro

Prophet recupera la tendencia y el patrón que simulamos

```
fig2 = m.plot_components(fcst)

fcst[["ds", "trend", "yearly"]].tail(3)
##            ds     trend  yearly
## 141 2021-10-01  230917   -0.211
## 142 2021-11-01  231617   -0.004
## 143 2021-12-01  232293    0.310
```



Lectura

- La tendencia sube unos 676 por mes; la verdad era 650 × 1.025 ≈ 666.
- yearly = 0.310 en diciembre: 31 % sobre la tendencia. Setiembre queda 30 % abajo.

Prophet no es el estado del arte

Útil como línea base interpretable, no como campeón

En mantenimiento

Recibe arreglos y versiones nuevas (1.5.0 en octubre de 2026), pero el modelo no cambia desde hace años.

Rinde regular en comparaciones

En el libro fpp3 y en estudios independientes suele quedar detrás de ETS y ARIMA bien ajustados.

Su creador lo matiza

Sean Taylor, coautor, reconoció en 2021 que suele haber mejores enfoques y que «no hay sustituto para la evaluación».

Cuándo sí usarlo

Series de negocio con estacionalidad fuerte y varios años de historia, cuando explicar pesa más que el último punto de precisión.

Popularidad no es precisión: un gráfico bonito no es un buen modelo.

NeuralProphet: Prophet más autorregresión

Buena idea, proyecto estancado

Qué agrega

- Las mismas piezas de Prophet, reescritas sobre PyTorch.
- La pieza nueva: autorregresión con una red (AR-Net). Es la "AR" de ARIMA, estimada con descenso por gradiente.
- Sin rezagos rinde casi igual que Prophet; con rezagos mejora.

```
# Lo que pasa hoy al instalarlo (0.9.0)
m = NeuralProphet(n_lags=12, n_forecasts=12)
m.fit(df, freq="MS")

# con pandas 3:
## AttributeError: 'Series' object has no attribute 'view'
# con pandas 2 y PyTorch 2.6 o más:
## UnpicklingError: Weights only load failed
```

Lección de modelador: la última versión estable es de junio de 2024 y ya no corre con las librerías actuales sin parches. Por eso hoy no lo usamos: nos quedamos con la idea (autorregresión dentro de un modelo interpretable). Antes de elegir una herramienta para el proyecto, revisen si está viva.

Chronos-2 en Colab, sin entrenar

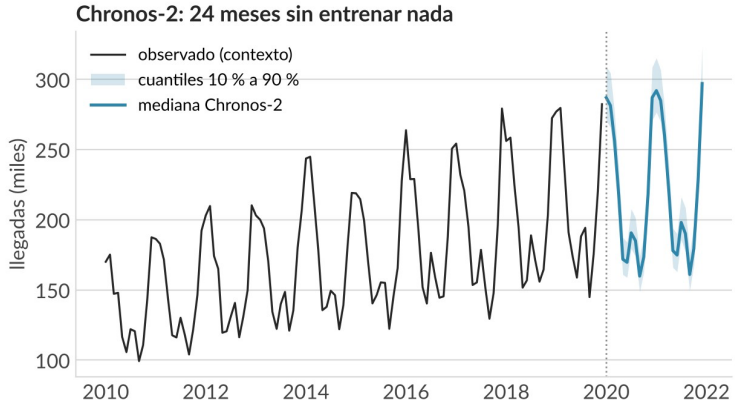
Amazon, octubre de 2025 · 120 millones de parámetros · Apache 2.0

```
from chronos import Chronos2Pipeline

pipeline = Chronos2Pipeline.from_pretrained(
    "amazon/chronos-2", device_map="cpu")

contexto = df.assign(id="turismo_cr").rename(
    columns={"ds": "timestamp", "y": "target"})

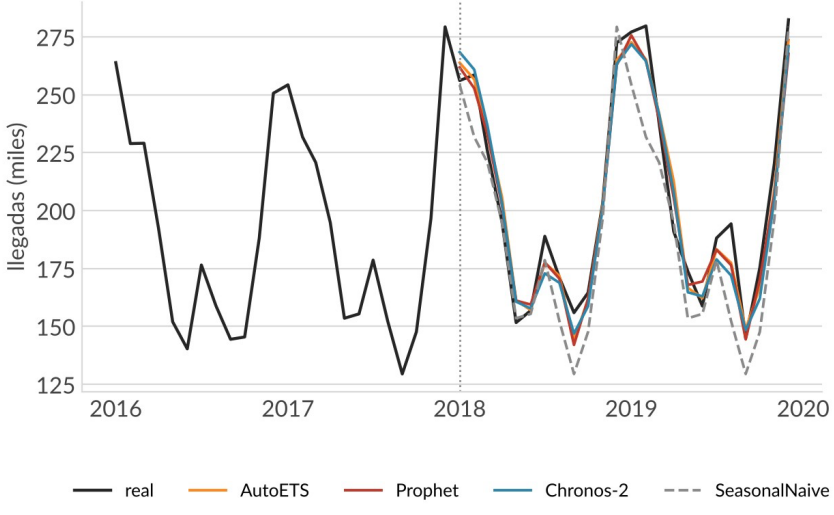
pred = pipeline.predict_df(contexto,
    prediction_length=24,
    quantile_levels=[0.1, 0.5, 0.9],
    id_column="id", timestamp_column="timestamp",
    target="target")
```



No hay fit: el modelo ya viene entrenado. Lee los 120 meses como contexto y devuelve cuantiles. En CPU tarda unos segundos.

Clásico contra fundación, en el mismo gráfico

Entrenan hasta 2017 y pronostican 2018 y 2019



Modelo	MASE	MAPE
AutoETS	0.66	3.8 %
Prophet	0.66	3.8 %
Chronos-2	0.78	4.5 %
AutoARIMA	0.81	4.6 %
SeasonalNaive	1.29	7.4 %

Los cuatro le ganan al ingenuo. Chronos-2 queda cerca sin haber visto nunca esta serie. Pero esto es un solo corte.

LEAD

Nadie gana siempre

Cuatro años de prueba, uno a la vez (ventana expansiva)

MASE por año de prueba (negrita: el mejor de la columna)

	2016	2017	2018	2019	promedio
AutoETS	**0.80**	0.80	**0.53**	**0.72**	**0.71**
Chronos-2	0.93	0.78	0.63	0.77	0.78
AutoARIMA	0.93	0.82	0.68	0.91	0.84
Prophet	1.38	0.81	0.56	0.72	0.86
SeasonalNaive	1.72	**0.71**	0.88	1.13	1.11

Lo que muestra

- AutoETS gana en promedio (0.71); Chronos-2 es segundo sin entrenar (0.78).
- Prophet pierde feo en 2016, con poca historia, y casi empata en 2018 y 2019.

La regla

Un solo corte puede engañar. Antes de elegir, prueben varios años: es la ventana expansiva de la semana 6.

LEAD

El zoológico de modelos de fundación

El liderazgo rota cada pocos meses

Chronos-2

Amazon · oct 2025

120 M parámetros. Univariado, multivariado y con covariables. Apache 2.0.

Moirai 2.0

Salesforce · nov 2025

Más pequeño y rápido que su versión anterior.

Toto 2.0

Datadog · jun 2026

De 4 M a 2 500 M parámetros. Primer lugar en GIFT-Eval al publicarse. Apache 2.0.

TimesFM-3

Google · ago 2026

330 M parámetros, con covariables. Pesos solo para uso no comercial.

GIFT-Eval y fev-bench

Los dos tableros de referencia. Miden con MASE y CRPS sobre cientos de series de varios dominios.

Con asterisco

Algunos modelos vieron datos de prueba al entrenar, y las cifras de cada empresa son propias. Ganar en promedio no es ganar en su serie.

LEAD

¿Cuándo usar cada enfoque?

Empezar siempre por una línea base

Situación	Enfoque recomendado
Siempre, como primer paso	Ingenuo estacional + AutoETS o AutoARIMA. Si no lo superan, paran ahí.
Pocas series, hay que explicar el pronóstico	Prophet o ETS: piezas legibles.
Muchas series, promociones, feriados, variables externas	LightGBM con rezagos (mlforecast).
Serie nueva o con poca historia, sin tiempo de entrenar	Modelo de fundación zero-shot (Chronos-2).
Producción a escala en una empresa	Combinaciones automáticas (AutoGluon).

El mejor modelo no es el más sofisticado: es el más simple que le gana al ingenuo de forma consistente en varias ventanas.

LEAD

Para el proyecto integrador

El avance se entrega la próxima semana

Si su tema es una serie

Turismo, demanda eléctrica, dengue o tipo de cambio: un clásico (semana 6) y un modelo moderno (hoy) ya son los dos métodos de la entrega final.

El primer modelo

Para el avance basta uno, comparado contra el ingenuo con MASE. El segundo puede quedar en "próximos pasos".

Ojo con los datos reales

Las series del ICT y del Ministerio de Salud tienen el quiebre de 2020. Decidan cómo tratarlo y escríbanlo como supuesto.

Recordatorio: el avance se sube a Moodle antes de las 4:00 p. m. del jueves 29 de octubre. Revisen la rúbrica del instructivo antes de entregar.

LEAD

Para la próxima semana

Clase 8 · jueves 29 de octubre · Repaso integrador

Pendientes

- Subir el avance del proyecto antes de las 4:00 p. m. del jueves.
- Terminar las partes de la práctica que quedaron abiertas.
- Resolver la tarea moral de la parte de ideas.

Clase 8

- Repaso de las semanas 1 a 7.
- Un ejemplo muy parecido a la prueba parcial.
- Se asigna la prueba parcial grupal: se empieza en clase y se entrega antes de la sesión del 5 de noviembre.

Traigan dudas de todo el cuatrimestre: el repaso es para eso.

Dudas: jordy.alfaro@ulead.ac.cr

LEAD

LEAD UNIVERSITY

Lo que se llevan de esta sesión

Local contra global

Un modelo por serie o un modelo que aprende de miles. El modelo de fundación es el caso extremo.

Prophet descompone

Tendencia por tramos más estacionalidad más festivos. Interpretable, pero no campeón.

El árbitro no cambió

Clásico, neuronal o de fundación: varias ventanas y MASE contra el ingenuo.

Ahora: 30 minutos de receso y luego la práctica en salas.

LEAD UNIVERSITY

Práctica en salas

6:00 a 7:00 p. m. · con su grupo del proyecto · kernel de Python

1. A mano

15 min

Un modelo aditivo de visitas a un parque nacional y un MASE.

2. Prophet

20 min

Ajustar, leer los componentes y pronosticar.

3. Chronos-2

15 min

Zero-shot y comparación con MASE contra el ingenuo.

4. Decisión

10 min

¿Qué modelo usarían y por qué?

Al entrar a la sala, corran primero la celda de instalación: tarda un par de minutos.